BỘ GIÁO DỤC VÀ ĐÀO TẠO

ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN

_____ o0o _____

BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN: [CẦN XÁC NHẬN]

ĐỀ TÀI: HAI MÔ HÌNH KHUYẾN NGHỊ DỰA TRÊN LỊCH SỬ TƯƠNG TÁC VÀ ĐÁNH GIÁ TRÊN AMAZON ELECTRONICS

Đặng Anh Tuyền — **MSSV:** 23010912, **Lớp:** K17-KHMT(AI&KHDL)_1

Phạm Văn Sự — **MSSV:** 23010523, **Lớp:** K17-KHMT(AI&KHDL)_1

GVHD: TS. Trần Đình Tân

Hà Nội, Năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC PHENIKAA
TRƯỜNG CÔNG NGHỆ THÔNG TIN

_____ o0o _____

Đặng Anh Tuyền — **MSSV:** 23010912, **Lớp:** K17-KHMT(AI&KHDL)_1

Phạm Văn Sự — **MSSV:** 23010523, **Lớp:** K17-KHMT(AI&KHDL)_1

Nguyễn Chí Tài — **MSSV:** 23010523, **Lớp:** K17-KHMT(AI&KHDL)_1

BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN: [CẦN XÁC NHẬN]

HAI MÔ HÌNH KHUYẾN NGHỊ DỰA TRÊN LỊCH SỬ TƯƠNG TÁC VÀ ĐÁNH GIÁ TRÊN AMAZON ELECTRONICS

GVHD: TS. Trần Đình Tân

Hà Nội, Năm 2026

BẢNG PHÂN CHIA CÔNG VIỆC

STT	Họ và tên	Vai trò	Nội dung công việc	Tỷ lệ
1	Đặng Anh Tuyền	**Trưởng nhóm**	[CẦN NHÓM ĐIỀN: nội dung công việc]	**[?]**
2	Phạm Văn Sự	Thành viên	[CẦN NHÓM ĐIỀN: nội dung công việc]	**[?]**

Repository dự án: github.com/tuyenda2011/GRNR-DFHF-RecSys

Mục lục

1 Giới thiệu **5**
1.1 Đặt vấn đề 5
1.2 Mục tiêu và phạm vi nghiên cứu 5
1.3 Đóng góp của dự án 6

2 Cơ sở lý thuyết và nghiên cứu liên quan **7**
2.1 Khuyến nghị từ phản hồi ngầm 7
2.2 Nhóm mô hình giải trực tiếp 7
2.3 Nhóm mô hình cần huấn luyện 8
2.4 Tổng hợp và định hướng đề xuất 9

3 Phương pháp và thuật toán đề xuất **12**
3.1 Mô hình bài toán 12
3.2 Graph-Regularized Neighborhood Regression 12
3.2.1 Lựa chọn láng giềng và đồ thị sản phẩm 13
3.2.2 Hàm mục tiêu và phương pháp giải 14
3.2.3 Thuật toán huấn luyện và suy luận 15
3.3 Diffusion-Filtered History Factorization 16
3.3.1 Biểu diễn lịch sử và bộ lọc khuếch tán 16
3.3.2 Hàm mục tiêu và phương pháp tối ưu 17
3.3.3 Thuật toán huấn luyện và suy luận 18
3.4 Phân tích tính chất và chi phí tính toán 18

4 Thực nghiệm và phân tích kết quả **20**
4.1 Dữ liệu và tiền xử lý 20
4.1.1 Nguồn dữ liệu 20
4.1.2 Quy trình tiền xử lý 20
4.1.3 Chia tập theo thời gian 21
4.1.4 Tạo các mức giảm tương tác 22
4.1.5 Vai trò của từng phần dữ liệu 22
4.2 Thiết lập và giao thức đánh giá 23
4.3 Graph-Regularized Neighborhood Regression so với các mô hình giải trực tiếp 24
4.3.1 Chất lượng xếp hạng 24
4.3.2 Ảnh hưởng của mức độ thưa và nhóm người dùng 26
4.3.3 Chi phí tính toán 27

4.4 Diffusion-Filtered History Factorization so với các mô hình cần huấn luyện 30
4.4.1 Chất lượng xếp hạng 30
4.4.2 Ảnh hưởng của mức độ thưa và nhóm người dùng 30
4.4.3 Quá trình huấn luyện và chi phí tính toán 34
4.5 Hệ thống demo 35
4.6 Thảo luận và hạn chế 37

5 Kết luận và hướng phát triển **39**
5.1 Kết luận 39
5.2 Hướng phát triển 39

TÀI LIỆU THAM KHẢO **41**

Danh sách hình ảnh

3.1 Sơ đồ hoạt động của Graph-Regularized Neighborhood Regression . . 13
3.2 Sơ đồ hoạt động của Diffusion-Filtered History Factorization 17
4.1 Quy trình tiền xử lý dữ liệu 20
4.2 NDCG@20 của các mô hình giải trực tiếp theo tỉ lệ dữ liệu huấn luyện được giữ lại 26
4.3 Mức giữ chất lượng của các mô hình giải trực tiếp khi giảm dữ liệu huấn luyện 27
4.4 NDCG@20 của các mô hình giải trực tiếp theo nhóm người dùng . . . 28
4.5 Thời gian huấn luyện của các mô hình giải trực tiếp 29
4.6 Dung lượng lưu trữ của các mô hình giải trực tiếp 29
4.7 NDCG@20 của các mô hình cần huấn luyện theo tỉ lệ dữ liệu huấn luyện được giữ lại 32
4.8 Mức giữ chất lượng của các mô hình cần huấn luyện khi giảm dữ liệu huấn luyện 32
4.9 NDCG@20 của các mô hình cần huấn luyện theo nhóm người dùng . 33
4.10 Đường học của các mô hình cần huấn luyện 34
4.11 Thời gian huấn luyện của các mô hình cần huấn luyện 35
4.12 Thời gian suy luận của các mô hình cần huấn luyện 36
4.13 Luồng xử lý của hệ thống demo 36

Danh sách bảng

2.1 So sánh các phương pháp trong nhóm giải trực tiếp 10
2.2 So sánh các phương pháp trong nhóm cần huấn luyện 10
3.1 Hai nhóm phương pháp và mô hình đề xuất tương ứng 13
3.2 Siêu tham số của Graph-Regularized Neighborhood Regression 16
3.3 Siêu tham số của Diffusion-Filtered History Factorization 19
3.4 Tính chất của mỗi mô hình đề xuất so với đại diện cùng nhóm 19
4.1 Số tương tác qua từng bước tiền xử lý 21
4.2 Thống kê dữ liệu sau tiền xử lý 21
4.3 Kết quả chia tập theo thời gian 21
4.4 Tập huấn luyện ở các mức giảm tương tác 22
4.5 Vai trò của từng phần dữ liệu 23
4.6 Cấu hình và môi trường chạy của các mô hình 23
4.7 Chất lượng xếp hạng của các mô hình giải trực tiếp 25
4.8 Kiểm định chênh lệch NDCG@20 trong nhóm giải trực tiếp 25
4.9 Chất lượng xếp hạng của các mô hình cần huấn luyện 30
4.10 Kiểm định chênh lệch NDCG@20 trong nhóm cần huấn luyện 31
4.11 NDCG@20 của các mô hình cần huấn luyện theo số tương tác còn lại 33
4.12 Quá trình huấn luyện và chi phí của các mô hình cần huấn luyện . . . 34

1 Giới thiệu

1.1 Đặt vấn đề

Các sàn thương mại điện tử có hàng chục nghìn đến hàng triệu sản phẩm, trong khi mỗi người dùng chỉ xem và mua một phần rất nhỏ. Hệ thống khuyến nghị giúp thu hẹp lựa chọn bằng cách đề xuất một danh sách ngắn những sản phẩm người dùng có khả năng quan tâm. Trong thực tế, dữ liệu sẵn có thường là *phản hồi ngầm*: hệ thống chỉ biết người dùng đã tương tác với sản phẩm nào, chứ không có điểm số cho mọi sản phẩm.

Dữ liệu này có hai khó khăn. Thứ nhất, nó cực kỳ thưa: trong bộ dữ liệu Amazon Electronics của dự án, mỗi người dùng trung bình chỉ có khoảng 8,6 tương tác trên hơn 44 nghìn sản phẩm. Thứ hai, người dùng mới hoặc người dùng có lịch sử thay đổi liên tục; một mô hình gán vector riêng cho mỗi người dùng phải huấn luyện lại mới phục vụ được họ.

Báo cáo này xét bài toán khuyến nghị top-K: từ lịch sử tương tác của một người dùng, xếp hạng các sản phẩm chưa tương tác và chọn ra K sản phẩm có điểm cao nhất. Trọng tâm là các mô hình biểu diễn người dùng hoàn toàn bằng lịch sử, để vừa khai thác được cấu trúc giữa các sản phẩm, vừa phục vụ được lịch sử mới mà không cần huấn luyện lại.

1.2 Mục tiêu và phạm vi nghiên cứu

Dự án đề xuất hai mô hình thuộc hai nhóm phương pháp khác nhau. Graph-Regularized Neighborhood Regression (GRNR) thuộc nhóm giải trực tiếp và được so sánh với EASE và GF-CF. Diffusion-Filtered History Factorization (DFHF) thuộc nhóm cần huấn luyện và được so sánh với LightGCN, XSimGCL và DirectAU. Hai mô hình được đánh giá độc lập, không so sánh với nhau. Báo cáo trả lời bốn câu hỏi:

RQ1. Trong nhóm của mình, mỗi mô hình đề xuất xếp hạng tốt đến đâu so với các baseline cùng nhóm?

RQ2. Khi chỉ giữ lại 75%, 50% hoặc 25% tương tác huấn luyện, chất lượng của mỗi mô hình thay đổi thế nào so với baseline cùng nhóm?

RQ3. Chi phí tính toán (thời gian huấn luyện, suy luận, dung lượng lưu trữ) của mỗi mô hình so với nhóm của nó ra sao?

RQ4. Hệ thống phục vụ lịch sử mới và giải thích gợi ý như thế nào?

Phạm vi đánh giá được giới hạn rõ. Mọi kết quả đo trên tập validation của một bộ dữ liệu (Amazon Electronics), với một seed và cho những người dùng có sản phẩm

mục tiêu nằm trong tập ứng viên. Chất lượng được đo bằng thước đo xếp hạng offline; báo cáo không đánh giá doanh thu, mức hài lòng hay hành vi của người dùng thật. Vì các câu hỏi được đặt sau khi đã có kết quả thực nghiệm, mọi phân tích đều mang tính khám phá.

1.3 Đóng góp của dự án

Dự án có ba đóng góp:

1. **Hai mô hình biểu diễn người dùng bằng lịch sử.** GRNR giải một hồi quy nhỏ có điều chuẩn đồ thị cho mỗi sản phẩm, không cần vòng lặp huấn luyện. DFHF học hai bảng embedding sản phẩm được lọc khuếch tán, huấn luyện bằng softmax trên toàn danh mục. Cả hai đều chấm điểm lịch sử mới mà không cần huấn luyện lại.
2. **Đánh giá có kiểm soát trong từng nhóm.** Mỗi mô hình được so với các baseline cùng nhóm trên cùng dữ liệu, cùng tập ứng viên và cùng nhóm người dùng, ở bốn mức giảm tương tác, kèm kiểm định bootstrap ghép cặp. Báo cáo trình bày cả kết quả bất lợi và đối chiếu với một mốc xếp hạng theo độ phổ biến.
3. **Hệ thống có thể truy nguyên và demo.** Mọi số liệu trong báo cáo truy được về tệp kết quả và script sinh ra chúng; ứng dụng demo cho phép thử gợi ý với lịch sử tùy ý và xem giải thích của GRNR.

Phần còn lại của báo cáo được tổ chức như sau. Chương 2 trình bày cơ sở lý thuyết và hai nhóm phương pháp liên quan. Chương 3 mô tả chi tiết hai mô hình đề xuất. Chương 4 trình bày dữ liệu, giao thức, kết quả của từng nhóm, hệ thống demo và các hạn chế. Chương 5 kết luận và nêu hướng phát triển.

2 Cơ sở lý thuyết và nghiên cứu liên quan

Chương này trình bày bài toán khuyến nghị từ phản hồi ngầm và hai nhóm phương pháp làm nền cho hai mô hình đề xuất. Mỗi phương pháp được trình bày theo thứ tự: nguyên lý, liên hệ với mô hình đề xuất cùng nhóm, điểm khác biệt và giới hạn.

2.1 Khuyến nghị từ phản hồi ngầm

Trong nhiều hệ thống, người dùng không cho điểm số rõ ràng cho mọi sản phẩm. Dữ liệu chỉ ghi nhận những gì người dùng đã làm, chẳng hạn đã mua, đã xem hay đã đánh giá tốt. Loại dữ liệu này gọi là *phản hồi ngầm* (implicit feedback) và được biểu diễn bằng ma trận nhị phân $X \in \{0,1\}^{|\mathcal{U}|\times|\mathcal{I}|}$. Một ô bằng 1 cho biết có tương tác; một ô bằng 0 không có nghĩa người dùng không thích sản phẩm, mà có thể họ chỉ chưa biết đến nó. Ma trận thường cực kỳ thưa: trong dữ liệu của dự án, chỉ khoảng 0,02% ô khác 0.

Hu, Koren và Volinsky [1] xử lý tính bất định này bằng cách coi mọi ô là quan sát nhưng gán độ tin cậy khác nhau: ô bằng 1 có trọng số lớn, ô bằng 0 có trọng số nhỏ, rồi khớp mô hình bằng bình phương tối thiểu có trọng số trên toàn bộ ma trận. GRNR dùng đúng nguyên tắc này cho bài toán hồi quy của từng sản phẩm (Mục 3.2.2).

Một hướng khác là học thứ tự. Bayesian Personalized Ranking (BPR) [2] tối ưu xác suất một sản phẩm đã tương tác được xếp trên một sản phẩm chưa tương tác lấy mẫu ngẫu nhiên. BPR là hàm mất mát mặc định của nhiều mô hình đồ thị, trong đó có LightGCN.

Nhiệm vụ trong báo cáo là *top-K*: với mỗi người dùng, chọn K sản phẩm chưa tương tác có điểm cao nhất. Chất lượng được đo bằng việc sản phẩm người dùng thực sự tương tác tiếp theo có nằm trong danh sách hay không và nằm ở vị trí nào (Mục 4.2).

2.2 Nhóm mô hình giải trực tiếp

Các mô hình trong nhóm này tính tham số bằng một công thức đóng hoặc một phép lọc tuyến tính, không có vòng lặp tối ưu bằng gradient. Ưu điểm chung là không có siêu tham số về số epoch hay tốc độ học, và kết quả xác định cho mỗi tập dữ liệu.

Mô hình láng giềng sản phẩm. Cách đơn giản nhất là chấm điểm sản phẩm i bằng tổng độ tương tự giữa i và các sản phẩm trong lịch sử người dùng: $s(u,i) = \sum_{j \in H_u} w_{ji}$. Ma trận w có thể là một độ đo cố định như cosine, hoặc được học từ dữ liệu.

SLIM. Sparse Linear Methods (SLIM) [4] học ma trận trọng số sản phẩm–sản phẩm W bằng cách khớp $X \approx XW$ với phạt ℓ_1 và ℓ_2, ràng buộc $W \geq 0$ và đường chéo

bằng 0 để một sản phẩm không tự dự đoán chính nó. Bài toán tách được theo từng cột, mỗi cột là một hồi quy riêng. GRNR kế thừa cấu trúc "một hồi quy cho mỗi sản phẩm" này.

EASE. Embarrassingly Shallow Autoencoders (EASE) [9] bỏ ràng buộc không âm và phạt ℓ_1 của SLIM, chỉ giữ phạt ℓ_2 và ràng buộc đường chéo bằng 0:

$$\min_{B} \|X - XB\|_F^2 + \lambda \|B\|_F^2 \quad \text{với} \quad \operatorname{diag}(B) = 0. \tag{2.1}$$

Bài toán có nghiệm đóng $B = I - P \operatorname{diagMat}(\mathbf{1} \oslash \operatorname{diag}(P))$ với $P = (X^\top X + \lambda I)^{-1}$. EASE thường là một baseline rất mạnh, nhưng cần nghịch đảo một ma trận đầy đủ cỡ $|\mathcal{I}| \times |\mathcal{I}|$, nên chi phí bộ nhớ tăng theo bình phương số sản phẩm. GRNR giữ ý tưởng hồi quy giữa các sản phẩm của EASE, nhưng giới hạn mỗi sản phẩm vào tối đa 128 láng giềng, dùng trọng số khác nhau cho mẫu dương và mẫu âm, và thêm điều chuẩn theo đồ thị.

GF-CF. Shen và cộng sự [14] phân tích các mô hình tích chập đồ thị dưới góc nhìn xử lý tín hiệu và đề xuất GF-CF, một bộ lọc không cần huấn luyện. Với ma trận chuẩn hóa $\tilde{R} = D_U^{-1/2} X D_I^{-1/2}$, điểm của người dùng là

$$s_u = x_u \, \tilde{R}^\top \tilde{R} + \alpha \, x_u \, D_I^{-1/2} V_k V_k^\top D_I^{1/2}, \tag{2.2}$$

trong đó số hạng đầu là bộ lọc thông thấp tuyến tính, số hạng sau là bộ lọc thông thấp lý tưởng dựng từ k vector kỳ dị phải lớn nhất V_k của $\tilde{R}$. Dự án dùng $k = 256$ và $\alpha = 0{,}3$ theo bài gốc. GF-CF cùng nhóm với GRNR vì đều không có vòng lặp huấn luyện, nhưng GF-CF lọc tín hiệu trên toàn đồ thị, còn GRNR học hệ số riêng cho từng cặp sản phẩm láng giềng.

2.3 Nhóm mô hình cần huấn luyện

Các mô hình trong nhóm này học embedding bằng tối ưu gradient qua nhiều epoch. Chúng linh hoạt hơn về hàm mất mát và kiến trúc, nhưng phụ thuộc vào số epoch, tốc độ học và cách chọn checkpoint.

Biểu diễn người dùng bằng lịch sử. Phân rã ma trận chuẩn gán cho mỗi người dùng một vector riêng. Koren [3] đề xuất biểu diễn người dùng thêm bằng tổng các vector sản phẩm trong lịch sử, chuẩn hóa theo $|H_u|^{-1/2}$. FISM [5] đi xa hơn: bỏ hẳn vector người dùng, học hai bảng embedding sản phẩm và chấm điểm

$$s(u, i) = b_i + \frac{1}{(n_u - 1)^\alpha} \sum_{j \in H_u \setminus \{i\}} p_j^\top q_i, \tag{2.3}$$

trong đó sản phẩm đích i được loại khỏi tổng khi huấn luyện. DFHF kế thừa trực tiếp ba ý tưởng từ hướng này: không có vector người dùng, hai bảng embedding nguồn và

đích tách biệt, và ngữ cảnh loại bỏ sản phẩm dương. Ưu điểm chung của hướng này là mô hình chấm điểm được một lịch sử mới mà không cần huấn luyện lại.

Softmax trên toàn danh mục. Mult-VAE [8] mô hình hóa lịch sử của người dùng bằng phân phối đa thức trên toàn bộ danh mục và cho thấy likelihood dạng softmax phù hợp với thước đo xếp hạng top-K hơn likelihood Gauss hay logistic. DFHF dùng hàm mất mát cùng dạng: cross-entropy của softmax trên toàn bộ sản phẩm ứng viên.

LightGCN. LightGCN [11] học embedding $e_u^{(0)}, e_i^{(0)}$ cho mọi người dùng và sản phẩm, rồi lan truyền trên đồ thị hai phía bằng phép trung bình chuẩn hóa, bỏ biến đổi phi tuyến và ma trận trọng số:

$$e_u^{(l+1)} = \sum_{i \in H_u} \frac{1}{\sqrt{|H_u|}\sqrt{|\mathcal{N}_i|}} e_i^{(l)}, \qquad e_u = \frac{1}{L+1} \sum_{l=0}^{L} e_u^{(l)}, \tag{2.4}$$

và tương tự cho sản phẩm; điểm là $e_u^\top e_i$, huấn luyện bằng BPR. Cả LightGCN và DFHF đều làm trơn embedding trên đồ thị, nhưng LightGCN lan truyền trên đồ thị người dùng–sản phẩm với vector người dùng riêng, còn DFHF chỉ lọc bảng sản phẩm bằng bước đi hai bước sản phẩm $\to$ người dùng $\to$ sản phẩm.

XSimGCL. XSimGCL [17] thêm học tương phản vào LightGCN. Thay vì tạo hai đồ thị tăng cường, mô hình cộng nhiễu ngẫu nhiên có độ lớn ϵ vào embedding ở các lớp trung gian, rồi kéo hai biểu diễn có nhiễu của cùng một nút lại gần nhau bằng hàm InfoNCE với nhiệt độ τ. Hàm mục tiêu là BPR cộng số hạng tương phản nhân với một trọng số.

DirectAU. Wang và cộng sự [15] cho rằng chất lượng biểu diễn trong lọc cộng tác phụ thuộc vào hai tính chất: *căn chỉnh* (cặp người dùng–sản phẩm có tương tác nằm gần nhau) và *đồng đều* (các embedding phân bố đều trên mặt cầu). DirectAU tối ưu trực tiếp hai đại lượng này thay cho BPR. Trong dự án, DirectAU dùng encoder LightGCN, nên khác LightGCN chủ yếu ở hàm mục tiêu chứ không ở kiến trúc.

2.4 Tổng hợp và định hướng đề xuất

Bảng 2.1 và Bảng 2.2 tổng hợp các phương pháp trong từng nhóm và vị trí của mô hình đề xuất.

Từ hai bảng có thể thấy mỗi mô hình đề xuất là một tổ hợp có chủ đích của các thành phần đã biết. GRNR lấy cấu trúc hồi quy từng sản phẩm của SLIM và EASE, trọng số cho dữ liệu ngầm của Hu và cộng sự, rồi thêm giới hạn láng giềng theo đồng xuất hiện vượt kỳ vọng và điều chuẩn theo Laplacian của đồ thị sản phẩm. DFHF lấy cách biểu diễn người dùng bằng lịch sử của FISM, hàm mất mát softmax toàn danh mục của Mult-VAE, và thêm bộ lọc khuếch tán đa thức lên bảng embedding. Trong

Bảng 2.1: So sánh các phương pháp trong nhóm giải trực tiếp.

	SLIM [4]	EASE [9]	GRNR
Biểu diễn người dùng	Lịch sử	Lịch sử	Lịch sử chuẩn hóa $n_u^{-1/2}$
Tham số	W thưa, ≥ 0	B đầy đủ $\lvert\mathcal{I}\rvert^2$	$\leq$ 128 láng giềng mỗi sản phẩm
Mục tiêu	Bình phương, $\ell_1 + \ell_2$	Bình phương, ℓ_2	Bình phương có trọng số, ridge thích nghi và điều chuẩn đồ thị
Cách giải	Tối ưu theo cột	Một phép nghịch đảo	$\lvert\mathcal{I}\rvert$ hệ Cholesky nhỏ

Bảng 2.2: So sánh các phương pháp trong nhóm cần huấn luyện.

	FISM [5]	LightGCN [11]	DirectAU [15]	DFHF
Vector người dùng	Không	Có	Có	Không
Lan truyền đồ thị	Không	Người dùng–sản phẩm	Người dùng–sản phẩm	Lọc bảng sản phẩm bằng T, T^2
Hàm mất mát	Bình phương hoặc BPR	BPR	Căn chỉnh và đồng đều	Softmax toàn danh mục
Lịch sử mới	Chấm ngay	Huấn luyện lại	Huấn luyện lại	Chấm ngay

phạm vi tài liệu đã đọc, nhóm thực hiện chưa thấy công trình nào kết hợp đồng thời đúng các thành phần như hai mô hình này. Tuy vậy, việc tìm kiếm tài liệu chưa đầy đủ, nên báo cáo không khẳng định đây là những đóng góp hoàn toàn mới. Đóng góp chính của dự án nằm ở việc cài đặt, đánh giá có kiểm soát và phân tích trung thực hai tổ hợp này trên cùng một giao thức.

3 Phương pháp và thuật toán đề xuất

Chương này trình bày hai mô hình đề xuất. Graph-Regularized Neighborhood Regression (GRNR) thuộc nhóm giải trực tiếp: mỗi sản phẩm được mô tả bằng một bài toán hồi quy có nghiệm đóng, không có vòng lặp huấn luyện. Diffusion-Filtered History Factorization (DFHF) thuộc nhóm cần huấn luyện: các bảng embedding sản phẩm được học bằng gradient. Hai mô hình được thiết kế và đánh giá độc lập; mỗi mô hình chỉ được so sánh với các phương pháp cùng nhóm ở Chương 4. Mọi công thức trong chương được viết theo đúng mã nguồn và cấu hình đã khóa của dự án.

3.1 Mô hình bài toán

Gọi $\mathcal{U}$ là tập người dùng và $\mathcal{I}$ là tập sản phẩm. Dữ liệu huấn luyện là ma trận tương tác nhị phân $X \in \{0,1\}^{|\mathcal{U}|\times|\mathcal{I}|}$, trong đó $X_{ui} = 1$ nếu người dùng u đã đánh giá tích cực sản phẩm i. Lịch sử của người dùng u là $H_u = \{i : X_{ui} = 1\}$ với độ dài $n_u = |H_u|$; số tương tác của sản phẩm i là $c_i = \sum_u X_{ui}$. Với mỗi người dùng, mô hình gán điểm $s(u, i)$ cho các sản phẩm chưa thấy và trả về K sản phẩm có điểm cao nhất.

Khi đánh giá, cần phân biệt bốn đối tượng. *Tập huấn luyện gốc* là toàn bộ tương tác train và chỉ dùng để loại các sản phẩm người dùng đã tương tác khỏi danh sách gợi ý. *Tập huấn luyện giữ lại* ở tỉ lệ $d \in \{1; 0{,}75; 0{,}5; 0{,}25\}$ là đầu vào thực sự của mô hình. *Tập ứng viên* gồm các sản phẩm có ít nhất một tương tác trong tập giữ lại. *Nhóm người dùng warm* gồm những người dùng có sản phẩm mục tiêu trong validation thuộc tập ứng viên. Tỉ lệ d là phần cạnh được giữ lại, khác với mật độ tuyệt đối $|E|/(|\mathcal{U}||\mathcal{I}|)$ của ma trận.

Điểm chung của hai mô hình là không có vector riêng cho từng người dùng: người dùng được biểu diễn hoàn toàn bằng lịch sử H_u. Vì vậy, khi có một lịch sử mới, mô hình chấm điểm được ngay mà không cần huấn luyện lại. Ngoài điểm chung này, hai mô hình khác nhau về cách học tham số và thuộc hai nhóm phương pháp khác nhau (Bảng 3.1).

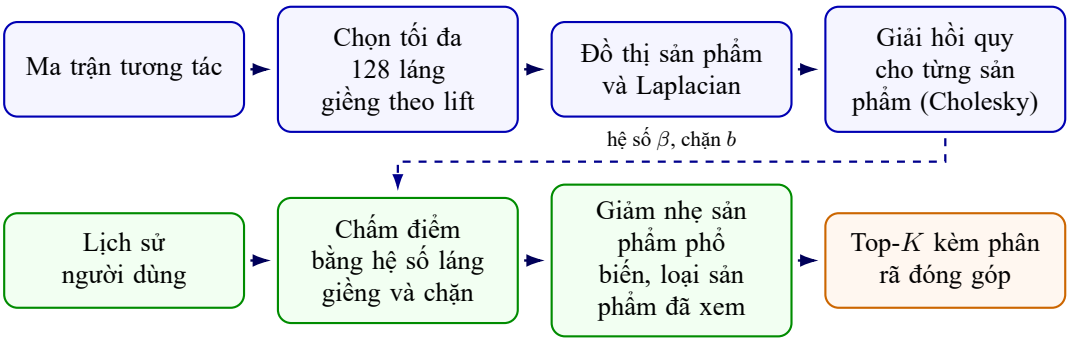
3.2 Graph-Regularized Neighborhood Regression

Graph-Regularized Neighborhood Regression (GRNR) dự đoán khả năng người dùng thích sản phẩm i bằng một tổ hợp tuyến tính của các sản phẩm láng giềng của i có trong lịch sử người dùng. Mỗi sản phẩm có một bài toán hồi quy riêng, nhỏ, giải được chính xác. Ý tưởng hồi quy giữa các sản phẩm kế thừa từ SLIM [4] và EASE [9]; khác biệt của GRNR nằm ở việc giới hạn láng giềng, trọng số cho dữ liệu ngầm và

Bảng 3.1: Hai nhóm phương pháp và mô hình đề xuất tương ứng.

Nhóm	Mô hình đề xuất	Baseline cùng nhóm	Cách học tham số
Giải trực tiếp	GRNR	EASE, GF-CF	Nghiệm đóng hoặc lọc tuyến tính, không có epoch
Cần huấn luyện	DFHF	LightGCN, XSimGCL, DirectAU	Tối ưu bằng gradient trong 200 epoch

các thành phần điều chuẩn theo đồ thị được mô tả dưới đây. Hình 3.1 tóm tắt hai giai đoạn của mô hình.



Hình 3.1: Sơ đồ hoạt động của Graph-Regularized Neighborhood Regression. Hàng trên (xanh dương) chạy một lần khi fit; hàng dưới (xanh lá) chạy cho mỗi người dùng, kể cả người dùng có lịch sử mới.

3.2.1 Lựa chọn láng giềng và đồ thị sản phẩm

Gọi $C = X^\top X$ là ma trận đồng xuất hiện (đường chéo đặt bằng 0). Với sản phẩm đích i, đặt xác suất nền đã làm trơn

$$p_i = \frac{c_i + 1}{|\mathcal{U}| + 2}. \tag{3.1}$$

Với mỗi sản phẩm nguồn j, mức đồng xuất hiện *vượt kỳ vọng* và độ nâng (lift) được tính bởi

$$e_{ij} = C_{ji} - c_j\, p_i, \qquad \text{lift}_{ij} = \frac{e_{ij}}{c_j + \alpha}, \quad \alpha = 10. \tag{3.2}$$

Tập láng giềng N_i gồm tối đa $k = 128$ nguồn có $\text{lift}_{ij} > 0$, xếp theo e_{ij} giảm dần (hòa thì theo chỉ số sản phẩm). Như vậy chỉ những sản phẩm xuất hiện cùng i nhiều hơn mức ngẫu nhiên mới được dùng làm đặc trưng.

Từ các trọng số lift dương, xây dựng đồ thị sản phẩm có hướng $W^{\text{dir}}_{ij} = \text{lift}_{ij}$ với $j \in N_i$, đối xứng hóa bằng $W = \max(W^{\text{dir}}, W^{\text{dir}\top})$ và lấy Laplacian chuẩn hóa

$$L = I - D_W^{-1/2}\, W\, D_W^{-1/2}, \tag{3.3}$$

trong đó D_W là ma trận bậc của W. Laplacian này được dùng làm điều chuẩn ở mục tiếp theo, để các sản phẩm láng giềng có liên hệ mạnh với nhau nhận hệ số gần nhau.

3.2.2 Hàm mục tiêu và phương pháp giải

Với sản phẩm i, mỗi người dùng u được mô tả bởi vector đặc trưng gồm các láng giềng có trong lịch sử, chuẩn hóa theo độ dài lịch sử, và một hệ số chặn:

$$\phi_u^{(i)} = \left[\frac{X_{u,N_i}}{\sqrt{\max(n_u - X_{ui},\, 1)}} \;;\; 1 \right] \in \mathbb{R}^{|N_i|+1}. \tag{3.4}$$

Mẫu số dùng $n_u - X_{ui}$: khi người dùng đã tương tác với i, chính i được loại khỏi độ dài lịch sử, để đặc trưng giống với lúc dự đoán một sản phẩm chưa thấy. Tham số $\theta_i = [\beta_i; b_i]$ gồm hệ số láng giềng β_i và hệ số chặn b_i, được ước lượng bằng bình phương tối thiểu có trọng số trên *toàn bộ* người dùng, theo tinh thần của mô hình phản hồi ngầm [1]:

$$\min_{\theta_i} \; \frac{1}{2} \sum_{u \in \mathcal{U}} w_{ui} \big(X_{ui} - \phi_u^{(i)\top} \theta_i \big)^2 \; + \; \frac{1}{2} (\theta_i - \theta_i^0)^\top M P_i \, (\theta_i - \theta_i^0), \tag{3.5}$$

với $w_{ui} = 10$ nếu $X_{ui} = 1$ và $w_{ui} = 1$ trong trường hợp ngược lại, $M = |\mathcal{U}|$. Ma trận phạt có dạng khối

$$P_i = \begin{bmatrix} \eta\, \text{diag}(s_j)_{j \in N_i} + \lambda_g \big(L_{N_i N_i} - (1-\beta) B_i \big) & 0 \\ 0 & \eta_b \end{bmatrix}, \tag{3.6}$$

trong đó $\eta = 10^{-5}$, $\eta_b = 10^{-3}$, $\lambda_g = 10^{-3}$, $\beta = 0{,}5$. Hệ số $s_j = \min\big((c_j/(c_j+2))^{-2},\, 10 \big)$ phạt nặng hơn các láng giềng có ít dữ liệu. $L_{N_i N_i}$ là khối con của Laplacian trên các láng giềng, còn B_i là ma trận đường chéo đo phần năng lượng "biên" của mỗi láng giềng, tức phần liên kết đồ thị trỏ ra ngoài N_i; hệ số β giữ lại một nửa phần biên này. Điểm neo θ_i^0 có hệ số láng giềng bằng 0 và hệ số chặn bằng nghiệm của bài toán chỉ có hằng số:

$$b_i^0 = \frac{w\, p_i}{1 + (w-1)\, p_i}, \qquad w = 10. \tag{3.7}$$

Hàm (3.5) là toàn phương và lồi chặt khi P_i xác định dương, nên nghiệm duy nhất thỏa phương trình chuẩn

$$\big(\Phi_i^\top W_i \Phi_i + M P_i \big)\, \theta_i = \Phi_i^\top W_i\, x_i + M P_i\, \theta_i^0, \tag{3.8}$$

với Φ_i là ma trận xếp các hàng $\phi_u^{(i)}$, $W_i = \mathrm{diag}(w_{ui})$ và x_i là cột i của X. Hệ (3.8) có kích thước $(|N_i|+1) \times (|N_i|+1) \le 129 \times 129$ và được giải bằng phân rã Cholesky ở độ chính xác float64. Cài đặt kiểm tra sai số dư tương đối $\|A\theta_i - r\|/\|r\| < 10^{-8}$ cho từng sản phẩm. Sản phẩm không có tương tác nào trong tập giữ lại nhận nghiệm $\theta_i = \theta_i^0$.

3.2.3 Thuật toán huấn luyện và suy luận

Ma trận Gram $\Phi_i^\top W_i \Phi_i$ được tính hiệu quả nhờ nhận xét: phần lớn người dùng có $X_{ui} = 0$ và trọng số 1, nên có thể dùng chung ma trận Gram toàn cục $G = \tilde{X}^\top \tilde{X}$ của lịch sử chuẩn hóa $\tilde{X}_{uj} = X_{uj}/\sqrt{\max(n_u, 1)}$, rồi chỉ thay chính xác các hàng của người dùng dương tính (đặc trưng loại i khỏi mẫu số, trọng số 10). Thuật toán 1 tóm tắt quá trình.

Thuật toán 1: Huấn luyện và chấm điểm Graph-Regularized Neighborhood Regression.

Đầu vào: Ma trận tương tác giữ lại X; siêu tham số ở Bảng 3.2
Đầu ra: Ma trận hệ số thưa $\mathcal{B} \in \mathbb{R}^{|\mathcal{I}| \times |\mathcal{I}|}$, vector chặn b

Tính c, p, $C = X^\top X$, lịch sử chuẩn hóa $\tilde{X}$ và Gram toàn cục $G = \tilde{X}^\top \tilde{X}$;
với mỗi *sản phẩm* i **thực hiện**
    Chọn N_i theo (3.2); ghi trọng số lift vào đồ thị W;
kết thúc
Tính Laplacian chuẩn hóa L của đồ thị W;
với mỗi *sản phẩm* i **thực hiện**
    nếu $c_i = 0$ **thì**
        $\theta_i \leftarrow \theta_i^0$;
    ngược lại
        Lấy khối Gram của N_i từ G, thay chính xác các hàng của người dùng có $X_{ui} = 1$;
        Lập P_i theo (3.6); giải (3.8) bằng Cholesky; kiểm tra sai số dư;
    kết thúc
    Ghi β_i vào cột i của $\mathcal{B}$ và b_i vào b;
kết thúc
Chấm điểm: $s(u,i) = \tilde{X}_{u,:}\,\mathcal{B}_{:,i} + b_i$; khi xếp hạng dùng $s(u,i) \cdot (1+c_i)^{-0{,}1}$;

Khi suy luận, điểm của người dùng u cho sản phẩm i là

$$s(u,i) = \sum_{j \in H_u \cap N_i} \beta_{ij}/\sqrt{n_u} + b_i. \tag{3.9}$$

Riêng ở bước xếp hạng, điểm được nhân với hệ số $(1+c_i)^{-0{,}1}$ để giảm nhẹ ưu thế của sản phẩm phổ biến; hệ số này không tham gia vào bài toán (3.5). Phép nhân chỉ giữ

đúng chiều khi điểm dương. Kiểm tra trên 3.000 người dùng ngẫu nhiên ở $d = 1$ cho thấy không có điểm âm nào trong top-20, nên trong thực nghiệm chiều tác động của hệ số này không bị đảo.

Vì điểm là tổng tuyến tính, có thể phân rã $s(u, i)$ thành đóng góp $\beta_{ij}/\sqrt{n_u}$ của từng sản phẩm j trong lịch sử. Hệ thống demo (Mục 4.5) dùng phân rã này để giải thích gợi ý. Đây là phân rã đại số của điểm số, không phải giải thích nhân quả về lý do người dùng thích sản phẩm.

Bảng 3.2: Siêu tham số của Graph-Regularized Neighborhood Regression. Cấu hình đã khóa của mô hình.

Ký hiệu	Ý nghĩa	Giá trị
k	Số láng giềng tối đa	128
α	Làm trơn mẫu số của lift	10
w	Trọng số mẫu dương	10
η	Phạt ridge cho hệ số láng giềng	10^{-5}
α_s, giới hạn	Làm trơn và giới hạn trên của hệ số s_j	2; 10
λ_g	Trọng số điều chuẩn đồ thị	10^{-3}
β	Phần năng lượng biên được giữ	0,5
η_b	Phạt cho hệ số chặn	10^{-3}
γ	Số mũ của hệ số độ phổ biến khi xếp hạng	$-0{,}1$

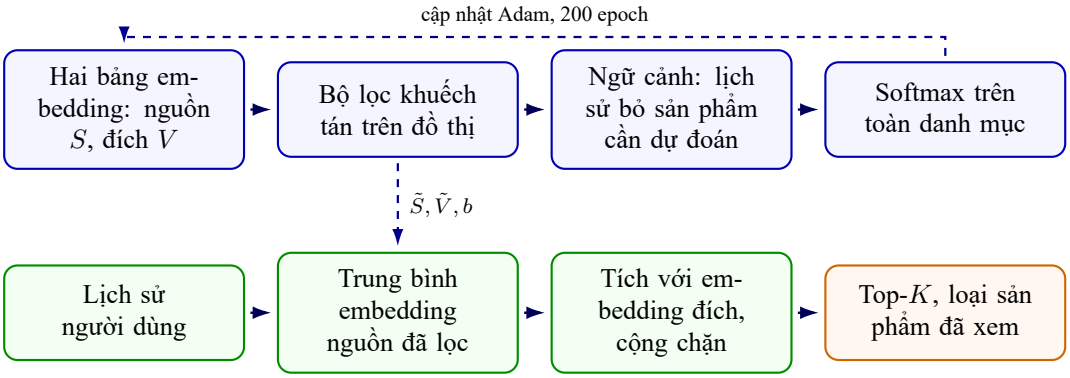
3.3 Diffusion-Filtered History Factorization

Diffusion-Filtered History Factorization (DFHF) biểu diễn người dùng bằng trung bình các embedding sản phẩm trong lịch sử, tương tự ý tưởng của FISM [5] và mô hình bất đối xứng của Koren [3]. Khác biệt của DFHF là các bảng embedding được làm trơn bằng một bộ lọc khuếch tán trên đồ thị người dùng–sản phẩm trước khi dùng, và mô hình được huấn luyện bằng softmax trên toàn bộ danh mục. Hình 3.2 tóm tắt quá trình huấn luyện và gợi ý.

3.3.1 Biểu diễn lịch sử và bộ lọc khuếch tán

DFHF có hai bảng embedding sản phẩm không ràng buộc với nhau, mỗi bảng có 64 chiều: bảng nguồn $S \in \mathbb{R}^{|\mathcal{I}|\times 64}$ dùng để mô tả lịch sử và bảng đích $V \in \mathbb{R}^{|\mathcal{I}|\times 64}$ dùng để mô tả sản phẩm được chấm điểm, cùng một vector chặn $b \in \mathbb{R}^{|\mathcal{I}|}$. Gọi D_U, D_I là ma trận bậc người dùng và sản phẩm của X. Toán tử chuyển

$$T = D_I^{-1} X^\top D_U^{-1} X \tag{3.10}$$



Hình 3.2: Sơ đồ hoạt động của Diffusion-Filtered History Factorization. Hàng trên (xanh dương) là vòng huấn luyện; hàng dưới (xanh lá) là bước gợi ý, dùng toàn bộ lịch sử. Người dùng chỉ có một tương tác nhận vector lịch sử bằng 0 và được xếp hạng bằng chặn b.

lấy trung bình một vector trên các người dùng đã tương tác với sản phẩm, sau đó trên các sản phẩm của những người dùng đó; T là ma trận ngẫu nhiên theo hàng của một bước đi ngẫu nhiên hai bước sản phẩm $\to$ người dùng $\to$ sản phẩm. Bộ lọc đa thức

$$F = \tfrac{1}{2} I + \tfrac{1}{4} T + \tfrac{1}{4} T^2 \tag{3.11}$$

được áp dụng cho cả hai bảng: $\tilde{S} = FS$, $\tilde{V} = FV$. Sản phẩm không có tương tác giữ nguyên vector gốc. Biểu diễn người dùng và điểm số là

$$q_u = \frac{1}{n_u^{1/2}} \sum_{j \in H_u} \tilde{S}_j, \qquad s(u,i) = q_u^{\top} \tilde{V}_i + b_i. \tag{3.12}$$

Theo cấu hình đã khóa, người dùng có đúng một tương tác trong tập giữ lại nhận $q_u = 0$ (trọng số lịch sử đơn bằng 0), cả khi huấn luyện lẫn khi suy luận. Với những người dùng này, DFHF xếp hạng chỉ bằng b_i, tức một thứ tự độ phổ biến đã học. Hệ quả này rất quan trọng khi tập huấn luyện bị giảm mạnh: ở $d = 0{,}25$, 68% người dùng warm chỉ còn một tương tác (Mục 4.1.4).

3.3.2 Hàm mục tiêu và phương pháp tối ưu

Mỗi cặp (u, i) trong tập giữ lại là một truy vấn huấn luyện. Ngữ cảnh của truy vấn là lịch sử bỏ đi chính sản phẩm dương (*leave-one-out*):

$$q_{u \setminus i} = \frac{1}{(n_u - 1)^{1/2}} \Big(\sum_{j \in H_u} \tilde{S}_j - \tilde{S}_i \Big). \tag{3.13}$$

Hàm mất mát là cross-entropy của softmax trên toàn bộ danh mục, với các sản phẩm khác đã có trong lịch sử và các sản phẩm không có tương tác bị loại khỏi mẫu số,

giống như cách đánh giá loại chúng khỏi danh sách gợi ý:

$$\ell(u,i) = -\log \frac{\exp\left(q_{u\setminus i}^{\top}\tilde{V}_i + b_i\right)}{\sum_{i' \in \mathcal{C}_u \cup \{i\}} \exp\left(q_{u\setminus i}^{\top}\tilde{V}_{i'} + b_{i'}\right)}, \tag{3.14}$$

trong đó $\mathcal{C}_u$ là tập ứng viên trừ lịch sử của u. Dạng likelihood đa thức trên toàn danh mục này tương tự Mult-VAE [8]. Hàm mục tiêu cộng thêm phạt ridge có trọng số theo mức xuất hiện π_i của sản phẩm trong các truy vấn ($\sum_i \pi_i = 1$):

$$\mathcal{L} = \frac{1}{|E|}\sum_{(u,i)\in E} \ell(u,i) + \frac{\lambda}{2}\sum_i \pi_i \frac{\|V_i\|^2 + \|S_i\|^2}{2} + \frac{\lambda_b}{2}\|b\|^2, \tag{3.15}$$

với $\lambda = 0{,}1$ và $\lambda_b = 10^{-4}$. Sau mỗi bước cập nhật, mỗi hàng của S và V được chiếu về hình cầu bán kính 100; ràng buộc này hiếm khi có hiệu lực.

3.3.3 Thuật toán huấn luyện và suy luận

DFHF được tối ưu bằng Adam với tốc độ học $3 \cdot 10^{-4}$, lô 2.048 truy vấn, trong đúng 200 epoch. Sau mỗi epoch, mô hình được đánh giá NDCG@20 trên validation và checkpoint có giá trị cao nhất được giữ lại. Đây là lựa chọn checkpoint chứ không phải dừng sớm: quá trình luôn chạy đủ 200 epoch. Khi huấn luyện, ngữ cảnh bỏ đi sản phẩm dương; khi suy luận, q_u dùng toàn bộ lịch sử giữ lại theo (3.12).

Thuật toán 2: Huấn luyện Diffusion-Filtered History Factorization.

Đầu vào: Tập cạnh giữ lại E; siêu tham số ở Bảng 3.3
Đầu ra: Checkpoint (S, V, b) có NDCG@20 validation cao nhất

Khởi tạo $V \sim \mathcal{N}(0, 1/64)$, $S \leftarrow V$ (sau đó cập nhật độc lập), $b \leftarrow 0$;
với *epoch* $= 1, \ldots, 200$ **thực hiện**
    với mỗi *lô* $\mathcal{Q} \subset E$ *gồm 2.048 truy vấn* **thực hiện**
        Tính $\tilde{S} = FS$, $\tilde{V} = FV$ theo (3.11);
        Tính ngữ cảnh $q_{u\setminus i}$ và mất mát (3.14) cộng phạt;
        Cập nhật Adam; chiếu các hàng của S, V về bán kính 100;
    kết thúc
    Đánh giá NDCG@20 trên validation; lưu checkpoint nếu tốt hơn;
kết thúc

3.4 Phân tích tính chất và chi phí tính toán

Mỗi mô hình được phân tích so với đại diện cùng nhóm, không so hai mô hình đề xuất với nhau (Bảng 3.4).

Bảng 3.3: Siêu tham số của Diffusion-Filtered History Factorization. Cấu hình đã khóa của mô hình.

Ký hiệu	Ý nghĩa	Giá trị
—	Số chiều embedding	64
—	Tốc độ học Adam; kích thước lô	$3 \cdot 10^{-4}$; 2.048
λ	Phạt ridge cho embedding	0,1
λ_b	Phạt cho vector chặn	10^{-4}
—	Bán kính chiếu	100
—	Số mũ chuẩn hóa lịch sử	0,5
—	Trọng số lịch sử đơn	0
—	Nhiệt độ softmax	1
—	Số epoch	200

GRNR so với EASE. EASE [9] cần nghịch đảo một ma trận $|\mathcal{I}| \times |\mathcal{I}|$ đầy đủ, tốn $O(|\mathcal{I}|^3)$ phép tính và $O(|\mathcal{I}|^2)$ bộ nhớ; với 44.843 sản phẩm, riêng ma trận float32 đã chiếm khoảng 7,5 GiB. GRNR thay bằng $|\mathcal{I}|$ hệ nhỏ kích thước tối đa 129×129, tốn $O(|\mathcal{I}|k^3)$ cho phần giải và lưu tối đa $k|\mathcal{I}|$ hệ số khác 0. Chi phí chính còn lại là ma trận đồng xuất hiện, cài đặt giới hạn tối đa $5 \cdot 10^7$ phần tử. Khi suy luận, cả hai đều là tích một vector lịch sử thưa với ma trận hệ số.

DFHF so với LightGCN. LightGCN [11] học một embedding cho mỗi người dùng và mỗi sản phẩm, tức $64(|\mathcal{U}| + |\mathcal{I}|)$ tham số. DFHF chỉ học $2 \cdot 64|\mathcal{I}| + |\mathcal{I}|$ tham số, không phụ thuộc số người dùng. Đổi lại, mỗi epoch của DFHF tốn thêm chi phí cho softmax trên toàn bộ danh mục, $O(|E| \cdot |\mathcal{I}| \cdot 64)$, và hai lần áp toán tử T trên mỗi bảng, $O(|E| \cdot 64)$ mỗi lần.

Bảng 3.4: Tính chất của mỗi mô hình đề xuất so với đại diện cùng nhóm. Phân tích lý thuyết; số đo thực tế ở Mục 4.3 và 4.4.

	GRNR	EASE	DFHF	LightGCN
Vector người dùng	Không	Không	Không	Có
Số tham số	$\leq 129\|\mathcal{I}\|$	$\|\mathcal{I}\|^2$	$129\|\mathcal{I}\|$	$64(\|\mathcal{U}\| + \|\mathcal{I}\|)$
Cách học	$\|\mathcal{I}\|$ hệ Cholesky $\leq 129^2$	Nghịch đảo $\|\mathcal{I}\| \times \|\mathcal{I}\|$	Adam, 200 epoch	Adam, 200 epoch
Lịch sử mới	Chấm ngay	Chấm ngay	Chấm ngay	Cần huấn luyện lại

4 Thực nghiệm và phân tích kết quả

Chương này đánh giá hai mô hình đề xuất trên bộ dữ liệu Amazon Electronics. Mục 4.1 mô tả dữ liệu và tiền xử lý, Mục 4.2 trình bày giao thức đánh giá. Hai mục kết quả được tách theo nhóm: Mục 4.3 so GRNR với các mô hình giải trực tiếp, Mục 4.4 so DFHF với các mô hình cần huấn luyện. Mục 4.5 giới thiệu hệ thống demo và Mục 4.6 thảo luận các giới hạn. Mọi kết quả đều đo trên tập validation, với một seed (42).

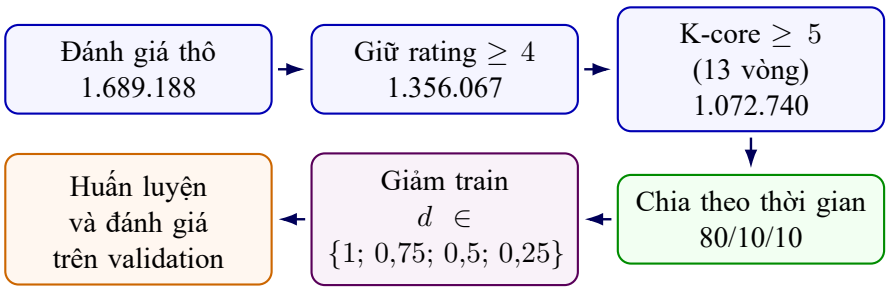
4.1 Dữ liệu và tiền xử lý

4.1.1 Nguồn dữ liệu

Dữ liệu là danh mục Electronics của bộ Amazon product data do McAuley và cộng sự công bố [6, 7]. Dự án dùng tệp đánh giá bản 5-core (mỗi người dùng và sản phẩm có ít nhất 5 đánh giá) và tệp metadata của danh mục này từ trang SNAP. Từ tệp đánh giá, dự án lấy mã người đánh giá (`reviewerID`), mã sản phẩm (`asin`), số sao (`overall`) và thời điểm (`unixReviewTime`); từ tệp metadata, dự án lấy tên, thương hiệu và danh mục sản phẩm. Đây là các đánh giá công khai, không phải nhật ký mua hàng; một đánh giá từ 4 sao trở lên chỉ được xem là tín hiệu gián tiếp cho sở thích.

4.1.2 Quy trình tiền xử lý

Hình 4.1 tóm tắt các bước biến dữ liệu thô thành các tập dùng cho thực nghiệm; Bảng 4.1 ghi số tương tác còn lại sau mỗi bước, lấy từ sổ ghi nhận quá trình lọc của bộ dữ liệu.



Hình 4.1: Quy trình tiền xử lý dữ liệu. Số trong mỗi ô là số tương tác còn lại sau bước đó.

Đầu tiên, các đánh giá có rating từ 4 trở lên được giữ làm phản hồi tích cực. Sau đó các cặp (người dùng, sản phẩm) trùng lặp được khử, giữ bản mới nhất và rating cao nhất; trên dữ liệu này không có cặp trùng. Dù tệp nguồn đã là 5-core, việc bỏ các đánh giá thấp làm nhiều người dùng và sản phẩm rơi xuống dưới 5 tương tác, nên bộ lọc K-core hai phía được áp lại cho đến khi hội tụ. Vòng đầu loại 213.614 tương tác,

Bảng 4.1: Số tương tác qua từng bước tiền xử lý.

Bước	Còn lại	Bị loại
Đánh giá thô	1.689.188	—
Giữ đánh giá có rating ≥ 4	1.356.067	333.121
Khử trùng cặp (người dùng, sản phẩm)	1.356.067	0
K-core hai phía (≥ 5 cho người dùng và sản phẩm)	1.072.740	283.327

các vòng sau giảm dần, và quá trình dừng sau 13 vòng. Cuối cùng, người dùng và sản phẩm được đánh lại chỉ số liên tục theo thứ tự mã gốc, nên kết quả tái lập được.

Bảng 4.2: Thống kê dữ liệu sau tiền xử lý. Tính trên toàn bộ tương tác, trước khi chia tập.

Thống kê	Giá trị
Số người dùng	124.895
Số sản phẩm	44.843
Số tương tác	1.072.740
Mật độ	0,0192%
Số tương tác mỗi người dùng: trung bình / trung vị / lớn nhất	8,59 / 6 / 354
Số tương tác trung bình mỗi sản phẩm	23,9

4.1.3 Chia tập theo thời gian

Lịch sử của mỗi người dùng được sắp theo thời điểm đánh giá; các tương tác cùng thời điểm được sắp theo một hàm băm có seed của cặp (người dùng, sản phẩm), rồi theo mã sản phẩm. Sau đó 107.274 người dùng được chọn ngẫu nhiên (seed 42) trong số người dùng có ít nhất 3 tương tác; sau K-core, mọi người dùng đều thỏa điều kiện này. Với mỗi người dùng được chọn, tương tác cuối cùng đưa vào test, tương tác áp cuối đưa vào validation, phần còn lại vào train. 17.621 người dùng còn lại chỉ có trong train. Tỉ lệ 80/10/10 vì vậy được tính trên *tổng số tương tác*, không phải trên từng người dùng, và không có một mốc thời gian chung cho cả tập dữ liệu (Bảng 4.3).

Bảng 4.3: Kết quả chia tập theo thời gian.

	Train	Validation	Test
Số tương tác	858.192	107.274	107.274
Tỉ lệ	80%	10%	10%
Mục tiêu có sản phẩm không xuất hiện trong train	—	59	187

Kiểm tra sau khi chia không tìm thấy cặp (người dùng, sản phẩm) nào xuất hiện ở hai tập, và không có vi phạm thứ tự thời gian. Tuy nhiên, toàn bộ thời điểm trong dữ liệu đều nằm đúng nửa đêm, tức chỉ chính xác đến ngày. Do đó có 45.431 người dùng có tương tác validation cùng ngày với tương tác train cuối cùng, và 42.592 người dùng có tương tác test cùng ngày với tương tác validation. Thứ tự thời gian vì thế chỉ là "không giảm"; giao thức này không bảo đảm mô phỏng việc dự đoán tương lai một cách nghiêm ngặt [16]. Để giữ thứ tự thời gian, dự án không chuyển tương tác của sản phẩm chưa xuất hiện sang train. 40 sản phẩm không có trong train; 59 mục tiêu validation thuộc các sản phẩm này bị loại khỏi phép đo.

4.1.4 Tạo các mức giảm tương tác

Để khảo sát ảnh hưởng của độ thưa, tập train được giảm xuống bốn tỉ lệ $d = 1$; $0{,}75$; $0{,}5$ và $0{,}25$; validation và test giữ nguyên. Thuật toán giảm (seed 42) gán cho mỗi cạnh một số ngẫu nhiên, rồi xây dựng một *lõi phủ*: cạnh đầu tiên (theo thứ tự ngẫu nhiên) của mỗi sản phẩm, sau đó cạnh đầu tiên của mỗi người dùng chưa được phủ. Các cạnh còn lại được thêm theo thứ tự ngẫu nhiên cho đến khi đủ $\text{round}(d \cdot |E|)$ cạnh. Nhờ lõi phủ, mọi người dùng và sản phẩm vẫn còn ít nhất một tương tác ở mọi mức d.

Bảng 4.4: Tập huấn luyện ở các mức giảm tương tác. Người dùng bậc 1 là người dùng có sản phẩm mục tiêu trong tập ứng viên nhưng chỉ còn đúng một tương tác huấn luyện.

d	1	0,75	0,5	0,25
Số cạnh	858.192	643.644	429.096	214.548
Số cạnh trung bình mỗi người dùng	6,87	5,15	3,44	1,72
Người dùng warm bậc 1	0	6.657	28.555	72.944
Tỉ lệ người dùng warm bậc 1	0%	6,2%	26,6%	68,0%

Ở mọi mức, số cạnh đúng bằng số yêu cầu (Bảng 4.4). Cần lưu ý hai hệ quả. Thứ nhất, việc giảm *không ngẫu nhiên đều*: người dùng ít tương tác được lõi phủ bảo vệ, nên người dùng nhiều tương tác mất tỉ lệ lớn hơn. Thứ hai, ở $d = 0{,}25$ có tới 68% người dùng warm chỉ còn một tương tác. Ở mức này, bài toán gần với việc gợi ý từ một sản phẩm duy nhất, và một xếp hạng theo độ phổ biến trở nên rất cạnh tranh (Mục 4.6). Mỗi mức d chỉ được lấy mẫu một lần và dùng chung cho mọi mô hình.

4.1.5 Vai trò của từng phần dữ liệu

Bảng 4.5 tổng kết phần dữ liệu nào được dùng ở đâu. Tập test không được dùng trong báo cáo. Kiểm kê các tệp kết quả không tìm thấy điểm test nào được lưu, nhưng kiểm

kê này không chứng minh được rằng tập test chưa từng được xem.

Bảng 4.5: Vai trò của từng phần dữ liệu.

Phần dữ liệu	Vai trò
Train giữ lại theo d	Đầu vào huấn luyện của mọi mô hình; xác định tập ứng viên
Train gốc ($d = 1$)	Loại các sản phẩm đã tương tác khỏi danh sách gợi ý ở mọi d; định nghĩa nhóm người dùng theo số tương tác
Validation	Chọn cấu hình và checkpoint, *đồng thời* dùng để báo cáo kết quả
Test	Không dùng
Metadata sản phẩm	Chỉ hiển thị trong demo; không mô hình nào dùng để xếp hạng

Metadata có 888 sản phẩm thiếu tên (2,0%) và 7.351 sản phẩm thiếu thương hiệu (16,4%). Vì metadata không tham gia xếp hạng, các thiếu sót này chỉ ảnh hưởng đến phần hiển thị của demo. Pipeline còn tạo embedding văn bản và tập tương tác bị đánh giá thấp (rating dưới 4), nhưng không mô hình nào trong báo cáo sử dụng chúng.

4.2 Thiết lập và giao thức đánh giá

Mô hình và cấu hình. Bảng 4.6 liệt kê các mô hình trong hai nhóm. DirectAU dùng encoder LightGCN theo cấu hình tham chiếu của tác giả. EASE có hai biến thể: EASE đầy đủ dùng toàn bộ ma trận trọng số $|\mathcal{I}| \times |\mathcal{I}|$, còn EASE top-128 chỉ giữ 128 trọng số lớn nhất mỗi cột để lưu trữ. Các baseline neural dùng embedding 64 chiều, 3 lớp, Adam với tốc độ học $3 \cdot 10^{-4}$, lô 2.048 và chạy đủ 200 epoch.

Bảng 4.6: Cấu hình và môi trường chạy của các mô hình.

Nhóm	Mô hình	Cấu hình chính	Phần cứng
Giải trực tiếp	GRNR	Bảng 3.2	Cholesky CPU, 1 luồng
	EASE đầy đủ [9]	$\lambda = 300$	CPU
	EASE top-128	EASE đầy đủ, cắt 128 trọng số/cột	CPU
	GF-CF [14]	256 vector kỳ dị, trọng số lọc lý tưởng 0,3	CPU
Cần huấn luyện	DFHF	Bảng 3.3	GPU Tesla T4
	LightGCN [11]	64 chiều, 3 lớp, BPR	GPU Tesla T4
	XSimGCL [17]	Trọng số tương phản 0,1; $\tau = 0{,}2$; $\epsilon = 0{,}1$	GPU Tesla T4
	DirectAU [15]	Encoder LightGCN; $\gamma = 1$	GPU Tesla T4

Cách xếp hạng. Với mỗi người dùng, mô hình chấm điểm mọi sản phẩm trong tập ứng viên (44.803 sản phẩm ở $d = 1$), loại các sản phẩm đã có trong train gốc, rồi

lấy top-K. Dự án không dùng cách lấy mẫu một số sản phẩm âm để so, vì các thước đo tính trên mẫu có thể cho thứ tự mô hình khác với xếp hạng đầy đủ [12]. Phép đo chỉ tính trên 107.215 người dùng warm; tập này giống nhau cho mọi mô hình ở mọi d.

Thước đo. Mỗi người dùng warm có đúng một sản phẩm mục tiêu trong validation. Với r_u là vị trí của sản phẩm mục tiêu trong danh sách gợi ý,

$$\text{Recall@}K = \frac{1}{|\mathcal{U}_w|}\sum_u \mathbb{1}[r_u \le K], \qquad \text{NDCG@}K = \frac{1}{|\mathcal{U}_w|}\sum_u \frac{\mathbb{1}[r_u \le K]}{\log_2(r_u+1)}. \quad (4.1)$$

Báo cáo dùng $K = 10$ và $K = 20$, trong đó NDCG@20 là thước đo chính.

Chọn cấu hình và checkpoint. Trong nhóm cần huấn luyện, mọi mô hình đều chạy đủ 200 epoch và giữ checkpoint có NDCG@20 validation cao nhất. Cách chọn giống nhau trong nhóm, nhưng vì cùng tập validation vừa dùng để chọn vừa dùng để báo cáo, giá trị tuyệt đối của mọi mô hình trong nhóm đều bị nâng lên một cách lạc quan. Trong nhóm giải trực tiếp, cấu hình GRNR được chọn qua quá trình thử nghiệm của dự án, còn EASE và GF-CF dùng cấu hình cố định; ngân sách tinh chỉnh vì vậy không cân bằng [10].

Kiểm định thống kê. Với mỗi cặp (mô hình đề xuất, baseline cùng nhóm), lấy hiệu NDCG@20 của từng người dùng rồi bootstrap ghép cặp theo người dùng 10.000 lần để có khoảng tin cậy 95% (phân vị) và giá trị p một phía cho giả thuyết mô hình đề xuất tốt hơn. Ở mỗi mức d, mỗi nhóm có 3 so sánh; giá trị p được hiệu chỉnh Holm trong nhóm 3 so sánh đó. Với 10.000 lần lặp, p nhỏ nhất đo được là $(0+1)/(10^4+1) \approx 10^{-4}$, nên báo cáo viết $p \le 10^{-4}$. Khoảng tin cậy chưa được hiệu chỉnh đồng thời. Vì chỉ có một seed, khoảng tin cậy chỉ phản ánh biến động do tập người dùng, không phản ánh biến động giữa các lần huấn luyện.

4.3 Graph-Regularized Neighborhood Regression so với các mô hình giải trực tiếp

4.3.1 Chất lượng xếp hạng

Bảng 4.7 cho kết quả của nhóm giải trực tiếp ở cả bốn mức d. Ở $d = 1$, GRNR có NDCG@20 cao nhất nhóm (0,03829), tiếp theo là EASE đầy đủ (0,03796), EASE top-128 (0,03679) và GF-CF (0,01886). Theo Bảng 4.8, GRNR hơn EASE top-128 ($\Delta = +0{,}00150$, KTC 95% $[0{,}00111;\ 0{,}00189]$) và GF-CF ($\Delta = +0{,}01943$) với khoảng tin cậy không chứa 0. Tuy nhiên, chênh lệch với EASE đầy đủ rất nhỏ ($\Delta = +0{,}00033$, KTC $[-0{,}00007;\ 0{,}00073]$, $p_{\text{Holm}} = 0{,}051$): chưa đủ bằng chứng để kết luận GRNR tốt hơn EASE đầy đủ theo phép so sánh này. Kết quả này cũng không chứng minh hai mô hình tương đương.

Bảng 4.7: Chất lượng xếp hạng của các mô hình giải trực tiếp. Đo trên tập validation, seed 42; giá trị cao nhất ở mỗi mức d được in đậm.

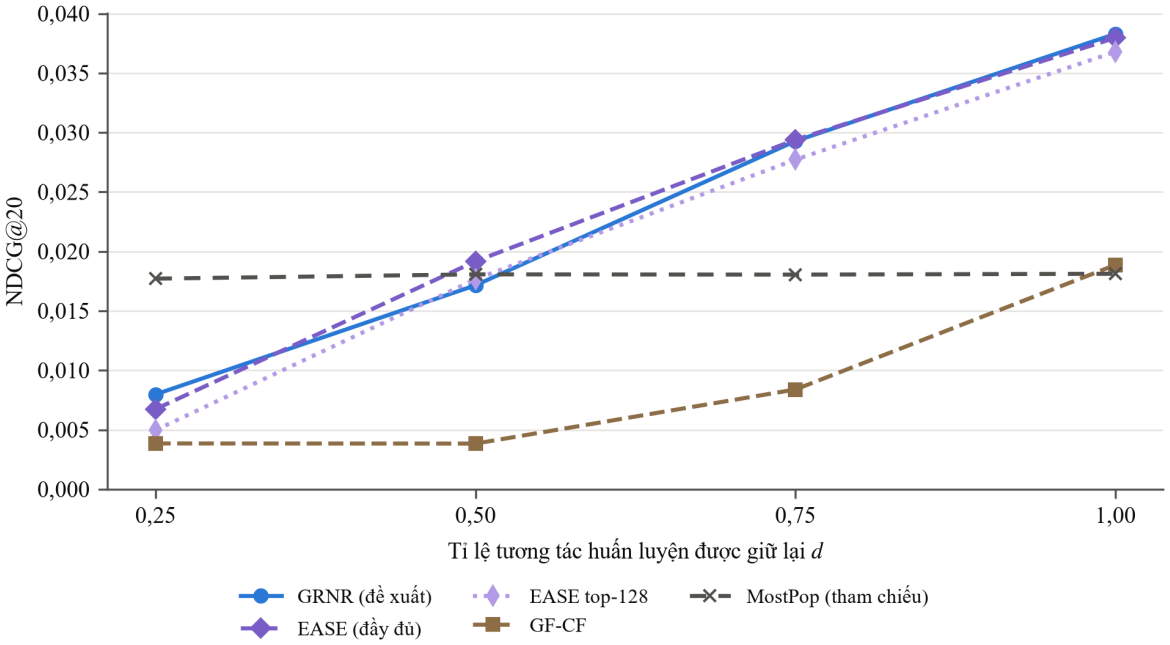
d	Mô hình	NDCG@10	NDCG@20	Recall@10	Recall@20
1	GRNR	**0,03292**	**0,03829**	**0,05629**	**0,07757**
	EASE đầy đủ	0,03287	0,03796	0,05607	0,07629
	EASE top-128	0,03206	0,03679	0,05413	0,07290
	GF-CF	0,01573	0,01886	0,02788	0,04035
0,75	GRNR	**0,02545**	0,02928	**0,04319**	0,05836
	EASE đầy đủ	**0,02545**	**0,02939**	0,04303	**0,05867**
	EASE top-128	0,02448	0,02772	0,04068	0,05345
	GF-CF	0,00668	0,00839	0,01237	0,01916
0,5	GRNR	0,01465	0,01715	0,02417	0,03410
	EASE đầy đủ	**0,01658**	**0,01917**	**0,02710**	**0,03736**
	EASE top-128	0,01564	0,01766	0,02496	0,03294
	GF-CF	0,00268	0,00384	0,00547	0,01009
0,25	GRNR	**0,00573**	**0,00798**	**0,01113**	**0,02017**
	EASE đầy đủ	0,00534	0,00674	0,00956	0,01513
	EASE top-128	0,00438	0,00497	0,00703	0,00936
	GF-CF	0,00205	0,00385	0,00511	0,01235

Bảng 4.8: Kiểm định chênh lệch NDCG@20 trong nhóm giải trực tiếp. Hiệu của GRNR trừ từng baseline; bootstrap ghép cặp theo người dùng 10.000 lần ($n = 107.215$); giá trị p một phía, hiệu chỉnh Holm trong mỗi mức d.

d	So sánh	Δ NDCG@20	KTC 95%	p_{Holm} (một phía)
1	GRNR − EASE đầy đủ	$+0{,}00033$	$[-0{,}00007;\ +0{,}00073]$	0,051
	GRNR − EASE top-128	$+0{,}00150$	$[+0{,}00111;\ +0{,}00189]$	$\leq 3 \cdot 10^{-4}$
	GRNR − GF-CF	$+0{,}01943$	$[+0{,}01874;\ +0{,}02010]$	$\leq 3 \cdot 10^{-4}$
0,75	GRNR − EASE đầy đủ	$-0{,}00011$	$[-0{,}00049;\ +0{,}00028]$	0,721
	GRNR − EASE top-128	$+0{,}00157$	$[+0{,}00121;\ +0{,}00193]$	$\leq 3 \cdot 10^{-4}$
	GRNR − GF-CF	$+0{,}02089$	$[+0{,}02023;\ +0{,}02159]$	$\leq 3 \cdot 10^{-4}$
0,5	GRNR − EASE đầy đủ	$-0{,}00202$	$[-0{,}00237;\ -0{,}00167]$	1,000
	GRNR − EASE top-128	$-0{,}00051$	$[-0{,}00082;\ -0{,}00021]$	1,000
	GRNR − GF-CF	$+0{,}01331$	$[+0{,}01276;\ +0{,}01386]$	$\leq 3 \cdot 10^{-4}$
0,25	GRNR − EASE đầy đủ	$+0{,}00124$	$[+0{,}00095;\ +0{,}00154]$	$\leq 3 \cdot 10^{-4}$
	GRNR − EASE top-128	$+0{,}00301$	$[+0{,}00274;\ +0{,}00330]$	$\leq 3 \cdot 10^{-4}$
	GRNR − GF-CF	$+0{,}00413$	$[+0{,}00383;\ +0{,}00444]$	$\leq 3 \cdot 10^{-4}$

4.3.2 Ảnh hưởng của mức độ thưa và nhóm người dùng

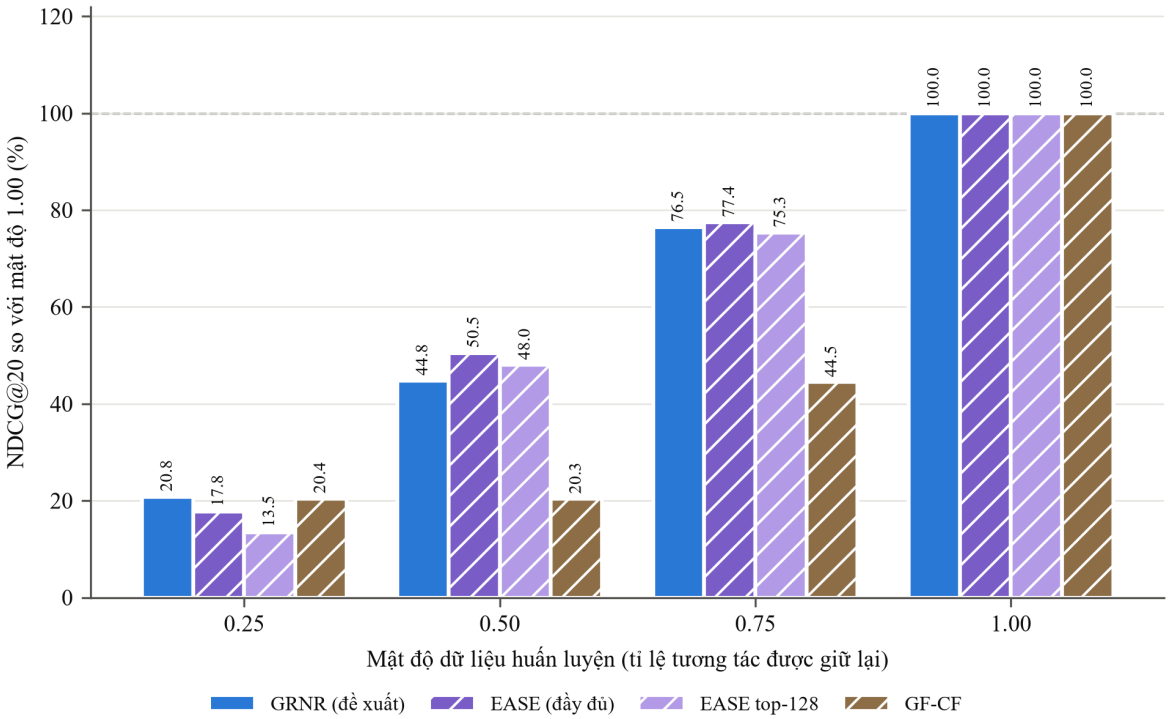
Hình 4.2 và Bảng 4.8 cho thấy so sánh giữa GRNR và EASE đầy đủ *không đơn điệu* theo d. Ở $d = 0{,}25$, GRNR cao hơn EASE đầy đủ với khoảng tin cậy không chứa 0. Ở $d = 0{,}75$, hai mô hình gần như bằng nhau. Ở $d = 0{,}5$, *EASE đầy đủ tốt hơn GRNR rõ ràng* ($\Delta = -0{,}00202$, KTC $[-0{,}00237; -0{,}00167]$); GRNR cũng thấp hơn EASE top-128 ở mức này. Đây là kết quả bất lợi cho GRNR. Kiểm định một phía không phát hiện được chiều ngược này, nên cần đọc khoảng tin cậy. Hình cũng cho thấy một mốc quan trọng: ở $d \geq 0{,}75$ cả GRNR và EASE đều vượt xa xếp hạng theo độ phổ biến (MostPop), nhưng ở $d = 0{,}5$ GRNR chỉ xấp xỉ mốc này, còn ở $d = 0{,}25$ *mọi mô hình trong nhóm đều thấp hơn MostPop*. Khi dữ liệu quá thưa, các quan hệ giữa sản phẩm mà nhóm này khai thác không còn đủ tín hiệu (Mục 4.6).



Hình 4.2: NDCG@20 của các mô hình giải trực tiếp theo tỉ lệ dữ liệu huấn luyện được giữ lại. Đường nét đứt là mốc MostPop, xếp hạng theo độ phổ biến trong tập huấn luyện giữ lại, không thuộc nhóm nào. Đo trên tập validation, seed 42, 107.215 người dùng có sản phẩm mục tiêu nằm trong tập ứng viên.

Hình 4.3 biểu diễn mức giữ chất lượng của mỗi mô hình so với chính nó ở $d = 1$. Khi chỉ còn 25% tương tác, GRNR giữ 20,8% NDCG@20 so với $d = 1$, GF-CF 20,4%, EASE đầy đủ 17,8% và EASE top-128 13,5%. Cả nhóm đều suy giảm mạnh. Giá trị tỉ lệ cần đọc cùng giá trị tuyệt đối: tỉ lệ của GF-CF không giảm từ $d = 0{,}5$ xuống $0{,}25$ vì NDCG@20 của GF-CF ở hai mức gần như bằng nhau (0,00384 và 0,00385). Hiện tượng này, cùng việc thời gian chạy GF-CF không tăng đều theo d, chưa được giải

thích; các run GF-CF dùng cùng cấu hình ở mọi mức.

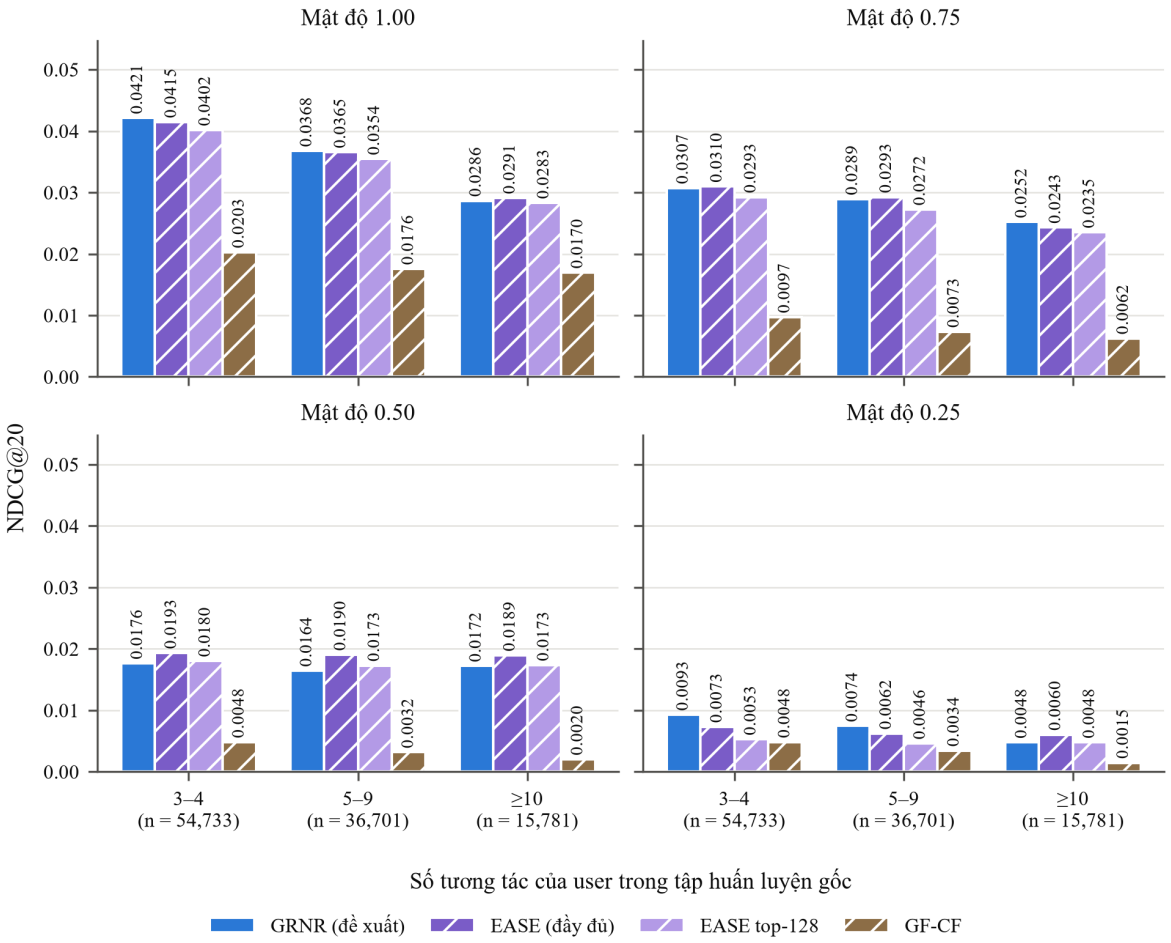


Hình 4.3: Mức giữ chất lượng của các mô hình giải trực tiếp khi giảm dữ liệu huấn luyện. NDCG@20 ở mỗi mức d chia cho NDCG@20 của chính mô hình đó ở $d = 1$, tính theo phần trăm.

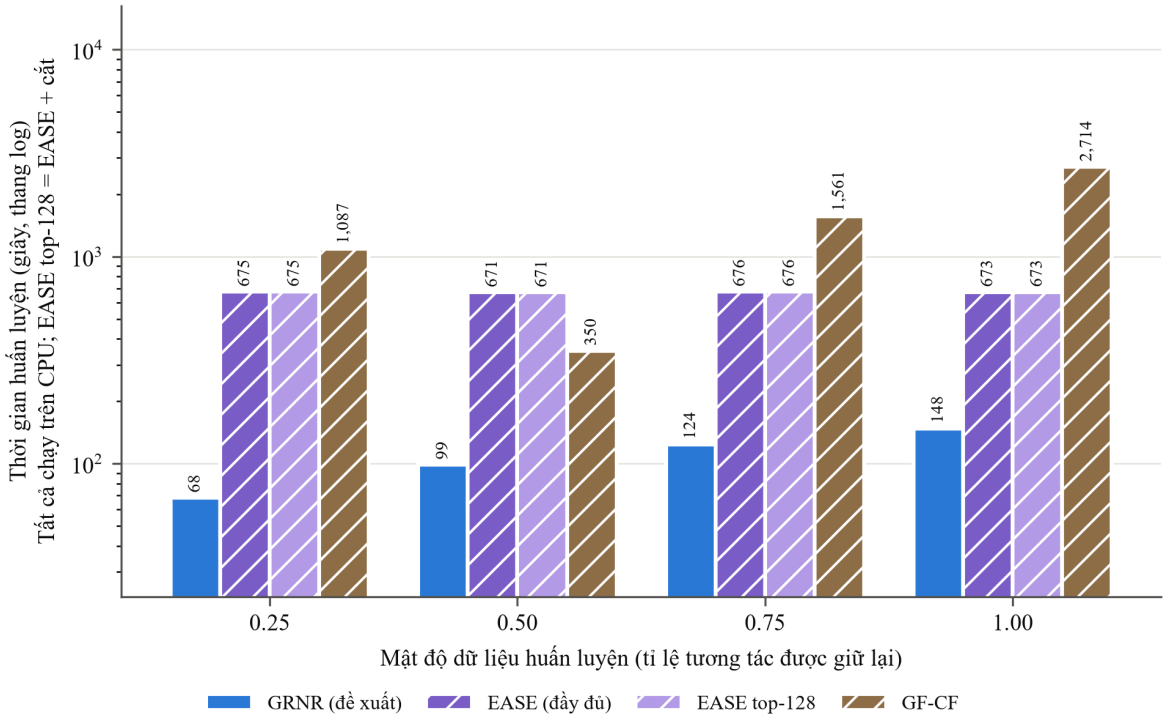
Hình 4.4 chia người dùng theo số tương tác trong train gốc (3–4, 5–9, ≥ 10). Nhóm được định nghĩa theo train gốc nên giống nhau ở mọi mức d, và kích thước mỗi nhóm được ghi dưới trục hoành.

4.3.3 Chi phí tính toán

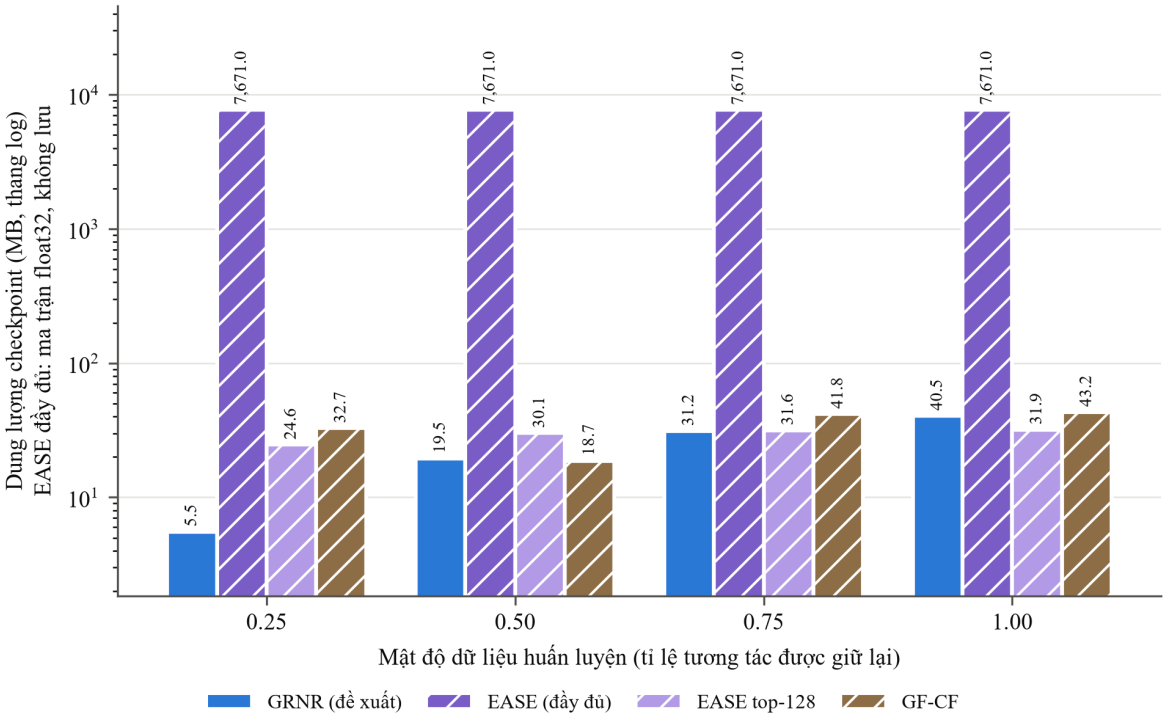
Ở $d = 1$, GRNR mất 2,5 phút để fit và lưu checkpoint 40,5 MiB. EASE mất 11,2 phút; ma trận trọng số đầy đủ ở dạng float32 chiếm khoảng 7.671 MiB (con số ước tính, ma trận này không được lưu), còn bản cắt top-128 chiếm 31,9 MiB. GF-CF mất 45,2 phút và 43,2 MiB (Hình 4.5, Hình 4.6). Các run không chạy trên cùng một máy: GRNR giải trên CPU một luồng của máy có GPU, còn EASE và GF-CF chạy trên máy chỉ có CPU. Vì vậy các con số này mô tả chi phí trong môi trường của dự án, không phải so sánh tốc độ về bản chất thuật toán.



Hình 4.4: NDCG@20 của các mô hình giải trực tiếp theo nhóm người dùng. Người dùng được chia theo số tương tác trong tập huấn luyện gốc; mỗi ô con ứng với một mức d.



Hình 4.5: Thời gian huấn luyện của các mô hình giải trực tiếp. Trục tung theo thang log, đơn vị giây; các mô hình không chạy trên cùng một máy.



Hình 4.6: Dung lượng lưu trữ của các mô hình giải trực tiếp. Trục tung theo thang log, đơn vị MiB. Với EASE đầy đủ, đây là kích thước ước tính của ma trận float32, không phải tệp đã lưu.

4.4 Diffusion-Filtered History Factorization so với các mô hình cần huấn luyện

4.4.1 Chất lượng xếp hạng

Bảng 4.9 cho kết quả của nhóm cần huấn luyện. Ở $d = 1$, DFHF đạt NDCG@20 bằng 0,03519, cao hơn XSimGCL (0,03292), DirectAU (0,03205) và LightGCN (0,02655). Theo Bảng 4.10, cả ba chênh lệch đều dương với khoảng tin cậy không chứa 0: so với XSimGCL $\Delta = +0{,}00228$ (KTC $[0{,}00172;\ 0{,}00284]$), so với DirectAU $\Delta = +0{,}00314$, so với LightGCN $\Delta = +0{,}00864$.

Bảng 4.9: Chất lượng xếp hạng của các mô hình cần huấn luyện. Đo trên tập validation, seed 42; giá trị cao nhất ở mỗi mức d được in đậm.

d	Mô hình	NDCG@10	NDCG@20	Recall@10	Recall@20
1	DFHF	**0,02946**	**0,03519**	**0,05217**	**0,07500**
	LightGCN	0,02173	0,02655	0,03998	0,05912
	XSimGCL	0,02721	0,03292	0,04905	0,07173
	DirectAU	0,02666	0,03205	0,04781	0,06925
0,75	DFHF	**0,02400**	**0,02901**	**0,04269**	**0,06261**
	LightGCN	0,01814	0,02261	0,03346	0,05122
	XSimGCL	0,02288	0,02759	0,04077	0,05948
	DirectAU	0,02238	0,02698	0,03960	0,05789
0,5	DFHF	**0,01824**	**0,02266**	**0,03377**	**0,05133**
	LightGCN	0,01455	0,01839	0,02764	0,04298
	XSimGCL	0,01596	0,01933	0,02881	0,04223
	DirectAU	0,01700	0,02050	0,03022	0,04418
0,25	DFHF	**0,01359**	**0,01766**	**0,02608**	**0,04220**
	LightGCN	0,00676	0,00842	0,01199	0,01857
	XSimGCL	0,00913	0,01117	0,01725	0,02535
	DirectAU	0,00849	0,01029	0,01517	0,02235

Các chênh lệch này cần được đọc cùng hai giới hạn của giao thức. Thứ nhất, mọi mô hình trong nhóm đều được chọn checkpoint trên chính tập validation dùng để báo cáo. Thứ hai, DirectAU đạt điểm cao nhất ở epoch cuối cùng (200/200) tại $d = 1$, và ở epoch 195 và 181 tại $d = 0{,}5$ và $d = 0{,}25$, nên có thể chưa hội tụ trong giới hạn 200 epoch; chênh lệch giữa DFHF và DirectAU vì thế có thể bị phóng đại.

4.4.2 Ảnh hưởng của mức độ thưa và nhóm người dùng

DFHF có NDCG@20 cao nhất nhóm ở cả bốn mức d (Hình 4.7), và theo Bảng 4.10 chênh lệch với cả ba baseline đều có khoảng tin cậy không chứa 0 ở mọi mức. Chênh

Bảng 4.10: Kiểm định chênh lệch NDCG@20 trong nhóm cần huấn luyện. Hiệu của DFHF trừ từng baseline; bootstrap ghép cặp theo người dùng 10.000 lần ($n = 107.215$); giá trị p một phía, hiệu chỉnh Holm trong mỗi mức d. Phân tích được thực hiện sau khi đã xem điểm trung bình, nên mang tính khám phá.

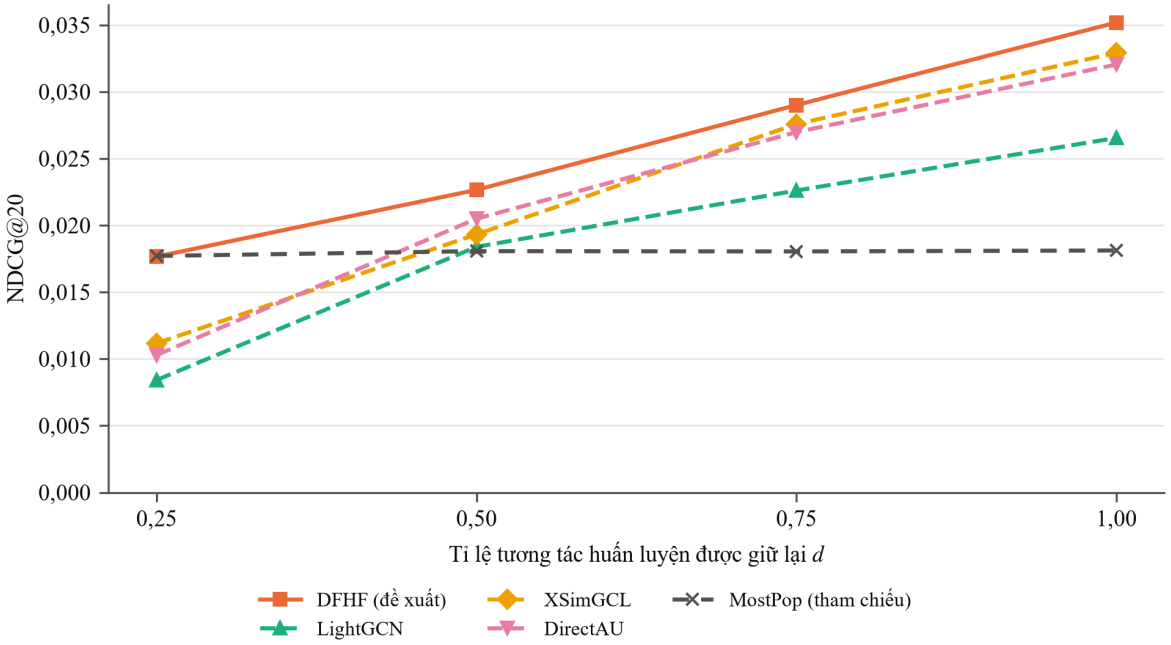
d	So sánh	Δ NDCG@20	KTC 95%	p_{Holm} (một phía)
1	DFHF − LightGCN	+0,00864	[+0,00802; +0,00928]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00228	[+0,00172; +0,00284]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00314	[+0,00251; +0,00378]	$\leq 3 \cdot 10^{-4}$
0,75	DFHF − LightGCN	+0,00640	[+0,00582; +0,00699]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00142	[+0,00086; +0,00201]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00203	[+0,00142; +0,00266]	$\leq 3 \cdot 10^{-4}$
0,5	DFHF − LightGCN	+0,00427	[+0,00376; +0,00479]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00333	[+0,00273; +0,00392]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00216	[+0,00152; +0,00281]	$\leq 3 \cdot 10^{-4}$
0,25	DFHF − LightGCN	+0,00924	[+0,00867; +0,00982]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00649	[+0,00596; +0,00706]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00737	[+0,00674; +0,00802]	$\leq 3 \cdot 10^{-4}$

lệch lớn nhất ở $d = 0{,}25$: 0,01766 so với 0,01117 của XSimGCL. Tuy nhiên, đường MostPop trong hình cho thấy ở $d = 0{,}25$ DFHF chỉ ngang xếp hạng theo độ phổ biến, còn ba baseline đều thấp hơn mốc này; ở $d = 0{,}5$, LightGCN cũng chỉ xấp xỉ MostPop. Phần cuối mục này giải thích vì sao.

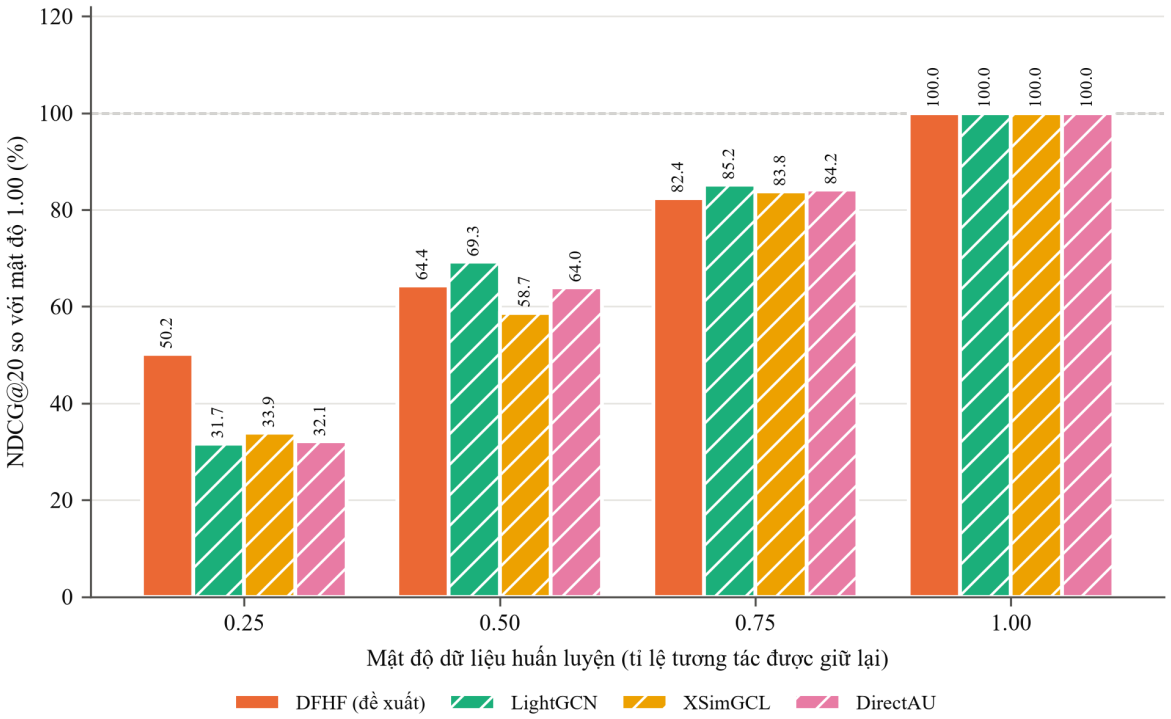
Về mức giữ chất lượng (Hình 4.8), ở $d = 0{,}25$ DFHF giữ 50,2% NDCG@20 so với $d = 1$, cao hơn XSimGCL (33,9%), DirectAU (32,1%) và LightGCN (31,7%). Tuy nhiên DFHF không giữ chất lượng tốt nhất ở mọi mức: ở $d = 0{,}5$, LightGCN giữ 69,3%, cao hơn DFHF (64,4%), DirectAU (64,0%) và XSimGCL (58,7%).

Kết quả ở $d = 0{,}25$ cần được diễn giải thận trọng. Như đã nêu ở Mục 3.3.1, DFHF xếp hạng những người dùng chỉ còn một tương tác bằng vector chặn b, tức một thứ tự độ phổ biến đã học. Ở $d = 0{,}25$, nhóm này chiếm 68% người dùng warm. Tách kết quả theo bậc người dùng (Bảng 4.11) cho thấy DFHF đạt 0,01787 trên người dùng bậc 1, gần như trùng với một xếp hạng theo độ phổ biến thuần túy (0,01789). Mục 4.6 phân tích hệ quả của quan sát này.

Hình 4.9 chia người dùng theo số tương tác trong train gốc. Ở $d = 1$, DFHF cao nhất ở nhóm 3–4 và 5–9 tương tác, còn ở nhóm ≥ 10 tương tác XSimGCL nhỉnh hơn (0,0235 so với 0,0230).



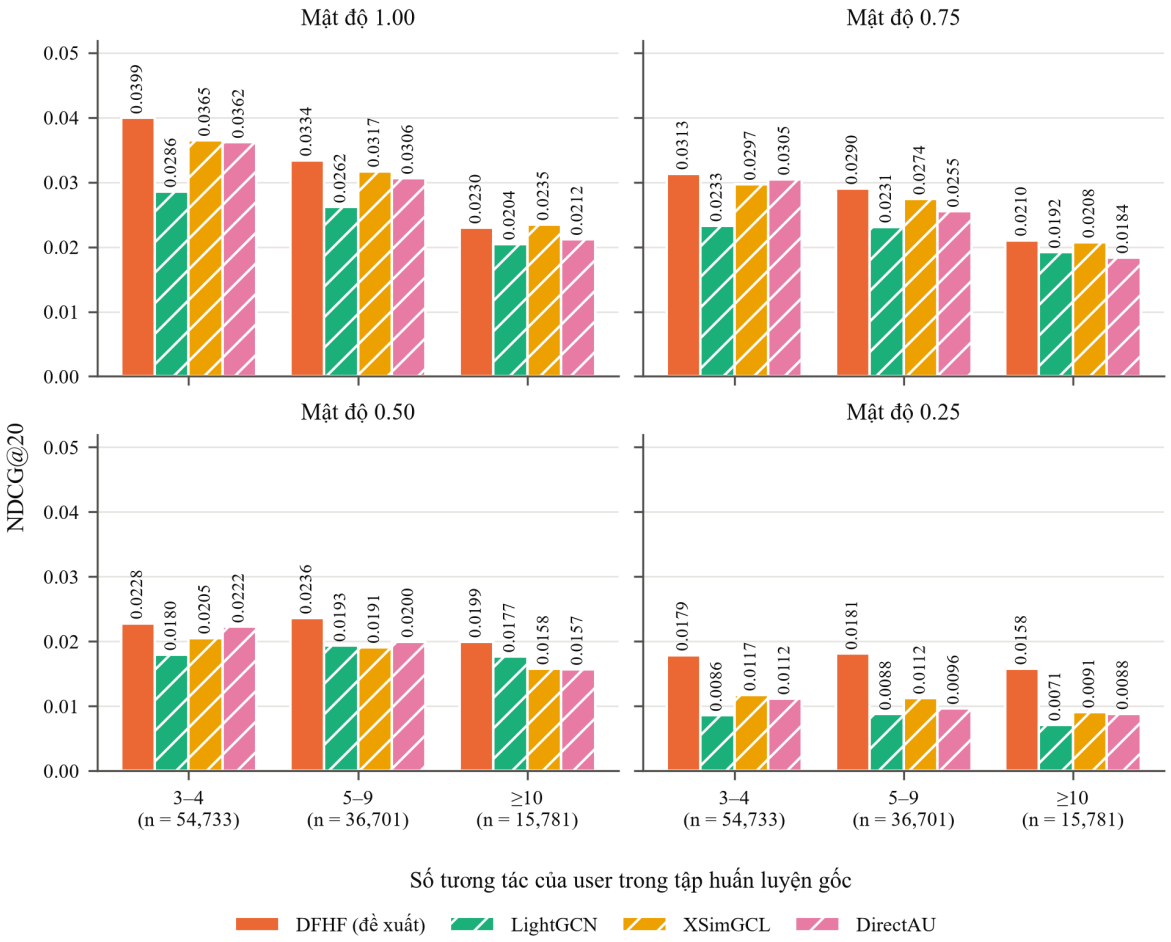
Hình 4.7: NDCG@20 của các mô hình cần huấn luyện theo tỉ lệ dữ liệu huấn luyện được giữ lại. Đường nét đứt là mốc MostPop, xếp hạng theo độ phổ biến trong tập huấn luyện giữ lại, không thuộc nhóm nào. Đo trên tập validation, seed 42, 107.215 người dùng có sản phẩm mục tiêu nằm trong tập ứng viên.



Hình 4.8: Mức giữ chất lượng của các mô hình cần huấn luyện khi giảm dữ liệu huấn luyện. NDCG@20 ở mỗi mức d chia cho NDCG@20 của chính mô hình đó ở $d = 1$, tính theo phần trăm.

Bảng 4.11: NDCG@20 của các mô hình cần huấn luyện theo số tương tác còn lại. Ở mức $d = 0{,}25$. MostPop là mốc tham chiếu xếp hạng theo độ phổ biến, không thuộc nhóm nào.

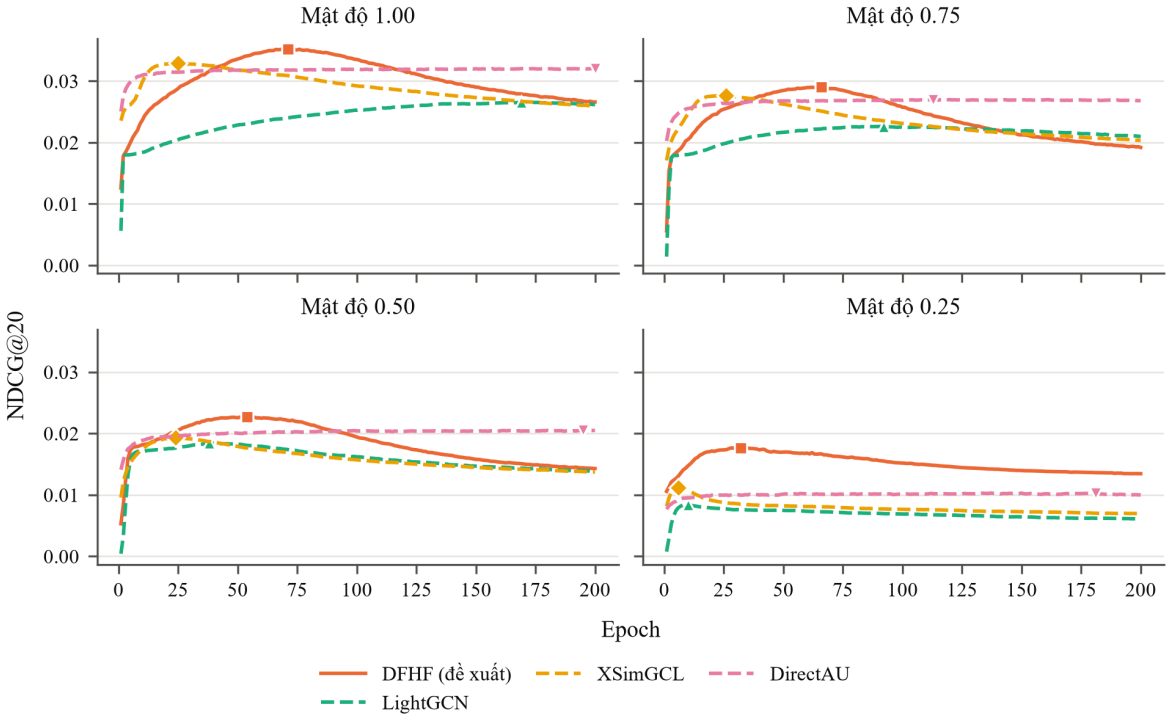
Mô hình	Bậc 1 ($n = 72.944$)	Bậc ≥ 2 ($n = 34.271$)	Tất cả
DFHF	0,01787	0,01720	0,01766
LightGCN	0,00849	0,00826	0,00842
XSimGCL	0,01132	0,01084	0,01117
DirectAU	0,01023	0,01043	0,01029
MostPop (tham chiếu)	0,01789	0,01733	0,01771



Hình 4.9: NDCG@20 của các mô hình cần huấn luyện theo nhóm người dùng. Người dùng được chia theo số tương tác trong tập huấn luyện gốc; mỗi ô con ứng với một mức d.

4.4.3 Quá trình huấn luyện và chi phí tính toán

Hình 4.10 vẽ NDCG@20 validation theo epoch; dấu đánh dấu là epoch được chọn. DFHF đạt đỉnh ở epoch 71 tại $d = 1$ rồi giảm dần, đến epoch 200 còn 0,02658, thấp hơn đỉnh 24,5% (Bảng 4.12). XSimGCL có hiện tượng tương tự (giảm 21,4%), trong khi LightGCN và DirectAU gần như không giảm. Như vậy kết quả của DFHF và XSimGCL phụ thuộc nhiều vào việc chọn checkpoint trên validation.



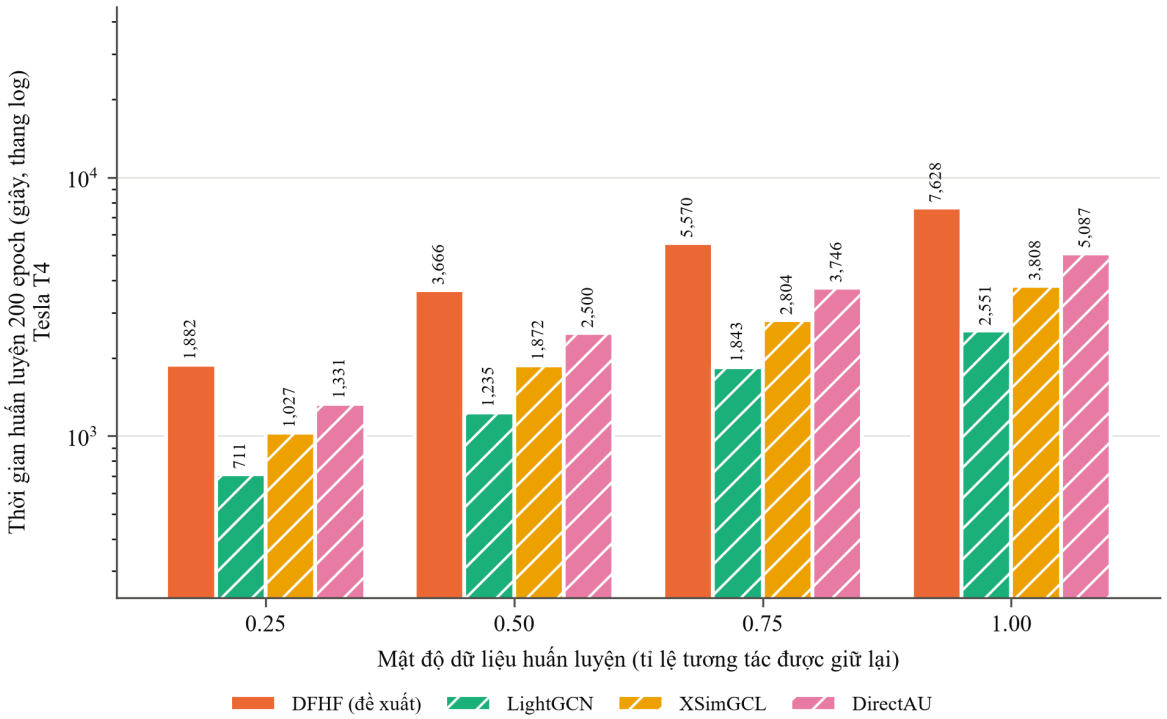
Hình 4.10: Đường học của các mô hình cần huấn luyện. NDCG@20 trên tập validation theo epoch ở bốn mức d; dấu đánh dấu là epoch được chọn làm checkpoint.

Bảng 4.12: Quá trình huấn luyện và chi phí của các mô hình cần huấn luyện. Ở mức $d = 1$: epoch được chọn làm checkpoint, mức giảm NDCG@20 đến epoch cuối và thời gian mỗi epoch trên GPU Tesla T4.

Mô hình	Epoch chọn	NDCG@20 chọn	NDCG@20 cuối	Giảm	Giây/epoch
DFHF	71	0,03519	0,02658	24,5%	37,9
LightGCN	169	0,02655	0,02617	1,4%	11,2
XSimGCL	25	0,03292	0,02587	21,4%	17,7
DirectAU	200	0,03205	0,03205	0%	24,1

Về chi phí, DFHF là mô hình chậm nhất nhóm: 37,9 giây mỗi epoch, tổng khoảng 127 phút cho 200 epoch ở $d = 1$, so với 24,1 giây của DirectAU, 17,7 giây của

XSimGCL và 11,2 giây của LightGCN (Hình 4.11). Phần lớn chi phí đến từ softmax trên toàn bộ danh mục và hai lần áp toán tử khuếch tán ở mỗi bước. Khi suy luận, cả bốn mô hình đều mất khoảng 0,01 ms cho mỗi người dùng theo lô trên GPU (Hình 4.12). Đây là trung bình theo lô, không phải độ trễ của một dịch vụ thực tế.

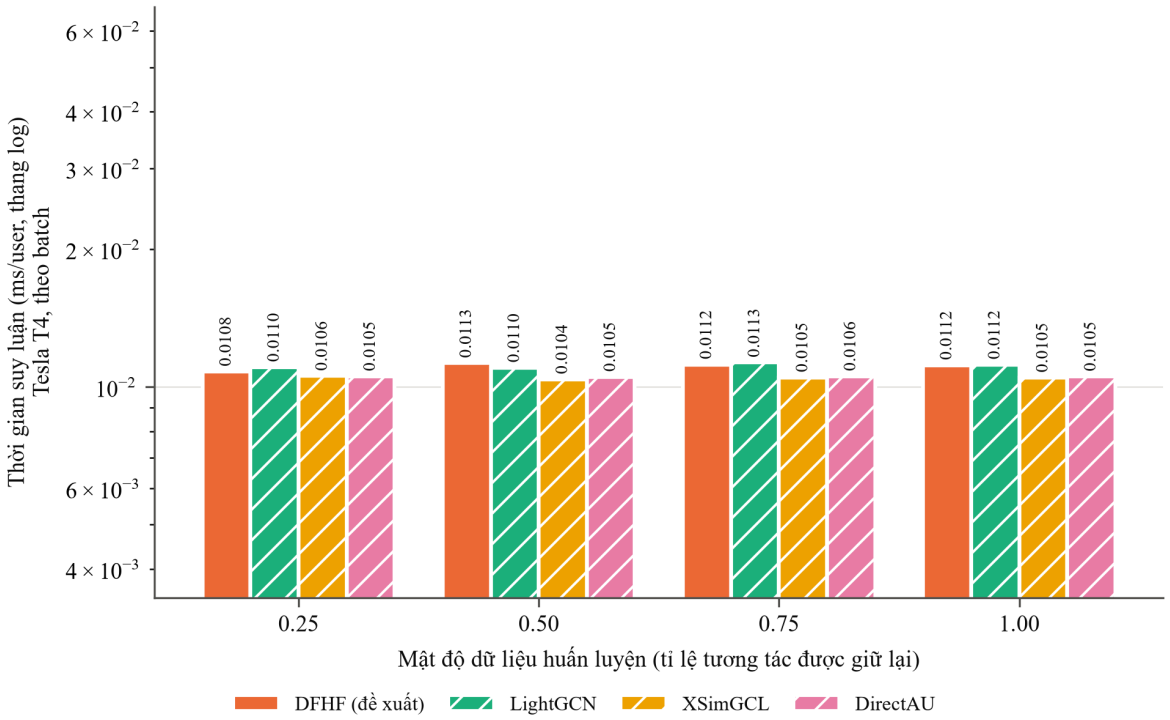


Hình 4.11: Thời gian huấn luyện của các mô hình cần huấn luyện. Tổng thời gian 200 epoch trên GPU Tesla T4; trục tung theo thang log, đơn vị giây.

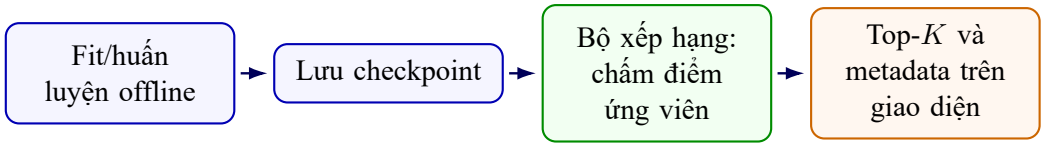
4.5 Hệ thống demo

Dự án xây dựng một ứng dụng Streamlit để minh họa cách các mô hình phục vụ gợi ý. Luồng xử lý gồm bốn bước (Hình 4.13): mô hình được fit hoặc huấn luyện offline và lưu checkpoint; ứng dụng nạp checkpoint vào một bộ xếp hạng dùng chung cho mọi mô hình; bộ xếp hạng chấm điểm các sản phẩm ứng viên; cuối cùng ứng dụng loại các sản phẩm đã có trong lịch sử và hiển thị top-K kèm metadata.

Ứng dụng có ba tab. Tab *Gợi ý cho khách* chọn một người dùng có sẵn và hiển thị gợi ý của mô hình được chọn. Tab *Khách mới* cho phép nhập một lịch sử sản phẩm tùy ý; vì cả GRNR lẫn DFHF đều biểu diễn người dùng bằng lịch sử, lịch sử mới được chấm điểm ngay mà không cần huấn luyện lại. Với GRNR, đặc trưng của lịch sử mới được tính giống hệt một hàng train (mỗi sản phẩm có trọng số $1/\sqrt{n}$). Tab *Đánh giá mô hình* hiển thị bảng, kiểm định và biểu đồ, tách riêng nhóm cần huấn luyện và nhóm



Hình 4.12: Thời gian suy luận của các mô hình cần huấn luyện. Thời gian trung bình cho mỗi người dùng khi chấm điểm theo lô trên GPU Tesla T4; trục tung theo thang log, đơn vị ms.



Hình 4.13: Luồng xử lý của hệ thống demo.

giải trực tiếp như trong báo cáo.

Riêng GRNR, ứng dụng hiển thị lý do gợi ý: với mỗi sản phẩm được gợi ý i, liệt kê các sản phẩm j trong lịch sử có đóng góp $\beta_{ij}/\sqrt{n}$ dương, xếp theo đóng góp giảm dần. Đây là phân rã đại số của điểm GRNR (Mục 3.2.3). DFHF không có cơ chế giải thích tương đương.

Hệ thống demo có ba giới hạn. Chưa có đánh giá với người dùng thật, nên không thể kết luận về mức độ hữu ích của gợi ý hay của phần giải thích. Tab *Khách mới* chỉ để minh họa, không phải một benchmark cho người dùng mới. Thời gian phản hồi trong demo cũng không phải số đo của một dịch vụ thực tế.

4.6 Thảo luận và hạn chế

Tóm tắt theo nhóm. Trong nhóm giải trực tiếp, GRNR có điểm cao nhất ở $d = 1$ và $d = 0{,}25$, hơn EASE top-128 và GF-CF ở $d = 1$, nhưng chưa đủ bằng chứng để nói GRNR tốt hơn EASE đầy đủ ở $d = 1$, và thua EASE đầy đủ rõ ràng ở $d = 0{,}5$. Ưu điểm rõ nhất của GRNR là chi phí: fit nhanh hơn và lưu trữ nhỏ hơn EASE đầy đủ nhiều lần, với chất lượng gần bằng. Trong nhóm cần huấn luyện, DFHF có điểm cao nhất ở cả bốn mức d với khoảng tin cậy không chứa 0, đổi lại thời gian mỗi epoch dài nhất nhóm và kết quả phụ thuộc mạnh vào việc chọn checkpoint.

Độ phổ biến ở mức thưa nhất. Để đặt các kết quả vào bối cảnh, dự án tính thêm một mốc tham chiếu MostPop: xếp các sản phẩm ứng viên theo số tương tác trong train giữ lại, loại các sản phẩm đã có trong lịch sử. MostPop không thuộc nhóm nào và không phải mô hình đề xuất; nó chỉ cho biết một xếp hạng không cá nhân hóa đạt được bao nhiêu. NDCG@20 của MostPop gần như không đổi theo d (0,0181 ở $d = 1$; 0,0177 ở $d = 0{,}25$). Ở $d = 1$, mọi mô hình trừ GF-CF đều vượt xa mốc này. Ở $d = 0{,}25$ thì khác: *không mô hình nào vượt MostPop*. DFHF ngang MostPop ($\Delta = -0{,}00005$, KTC $[-0{,}00029; +0{,}00018]$), các mô hình còn lại thấp hơn rõ, kể cả GRNR ($\Delta = -0{,}00973$). Ở $d = 0{,}5$, GRNR vẫn thấp hơn MostPop một chút ($\Delta = -0{,}00092$, KTC $[-0{,}00163; -0{,}00022]$), còn DFHF cao hơn ($\Delta = +0{,}00459$) (so sánh mang tính mô tả, không hiệu chỉnh đa so sánh). Như vậy, ưu thế của DFHF ở $d = 0{,}25$ so với các baseline cùng nhóm phản ánh chủ yếu việc DFHF rơi về thứ tự độ phổ biến cho người dùng chỉ còn một tương tác, trong khi các baseline học vector người dùng từ một tương tác duy nhất và xếp hạng kém hơn cả độ phổ biến. Ưu thế này không nên được hiểu là DFHF học được tín hiệu cá nhân hóa tốt hơn khi dữ liệu rất thưa.

Các giải thích cạnh tranh. Báo cáo chưa có thí nghiệm loại bỏ từng thành phần (ablation), nên mọi giải thích cơ chế dưới đây đều là giả thuyết. (i) Việc DFHF vượt các

baseline cùng nhóm ở $d \geq 0{,}5$ có thể do bộ lọc khuếch tán và softmax toàn danh mục, nhưng cũng có thể do các baseline chưa được tinh chỉnh tối ưu, chẳng hạn DirectAU chưa hội tụ; muốn phân biệt cần ablation với $F = I$ và tinh chỉnh baseline với cùng ngân sách. (ii) Việc GRNR hơn EASE ở $d = 0{,}25$ nhưng thua ở $d = 0{,}5$ có thể do giới hạn 128 láng giềng và điều chuẩn theo độ hỗ trợ có lợi khi dữ liệu rất thưa nhưng bó hẹp ở mức trung bình; cũng có thể chỉ là nhiễu của một lần lấy mẫu ở mỗi mức d. Lặp lại việc lấy mẫu với nhiều seed sẽ giúp phân biệt. (iii) Việc GRNR gần bằng EASE đầy đủ ở $d = 1$ phù hợp với việc cả hai cùng là hồi quy giữa các sản phẩm, nhưng cần thêm bộ dữ liệu để xác nhận.

Hạn chế. Theo thứ tự ảnh hưởng đến kết luận:

1. *Chọn trên validation.* Checkpoint và cấu hình được chọn trên chính tập validation dùng để báo cáo, nên mọi giá trị tuyệt đối đều lạc quan. Tập test chưa được dùng để xác nhận.
2. *Một seed.* Mỗi mô hình và mỗi mức d chỉ được chạy một lần; khoảng tin cậy không phản ánh biến động giữa các lần huấn luyện hay giữa các lần lấy mẫu train.
3. *Một bộ dữ liệu.* Mọi kết luận chỉ áp dụng cho Amazon Electronics với giao thức đã mô tả.
4. *Tinh chỉnh không cân bằng.* GRNR và DFHF được tinh chỉnh trong quá trình phát triển, còn các baseline dùng cấu hình mặc định hoặc cố định; DirectAU có dấu hiệu chưa hội tụ [10, 13].
5. *Thời gian chỉ chính xác đến ngày.* Có nhiều tương tác validation cùng ngày với tương tác train cuối, nên giao thức không mô phỏng chặt chẽ việc dự đoán tương lai [16].
6. *Khác biệt phần cứng.* Các nhóm và một số mô hình chạy trên các máy khác nhau, nên số đo thời gian chỉ mang tính tham khảo.
7. *Bất thường của GF-CF.* Kết quả và thời gian chạy của GF-CF không thay đổi đều theo d và chưa được giải thích; GF-CF chỉ ngang MostPop ở $d = 1$.

5 Kết luận và hướng phát triển

5.1 Kết luận

Báo cáo đã trình bày và đánh giá hai mô hình khuyến nghị biểu diễn người dùng bằng lịch sử tương tác, mỗi mô hình trong nhóm phương pháp của nó, trên bộ dữ liệu Amazon Electronics.

Nhóm giải trực tiếp. Graph-Regularized Neighborhood Regression có NDCG@20 cao nhất nhóm ở $d = 1$ (0,03829) và hơn EASE top-128 và GF-CF với khoảng tin cậy không chứa 0. Tuy nhiên chưa đủ bằng chứng để nói GRNR tốt hơn EASE đầy đủ ở $d = 1$, và EASE đầy đủ tốt hơn GRNR rõ ràng ở $d = 0{,}5$. Ưu điểm nổi bật của GRNR là chi phí: thời gian fit và dung lượng lưu trữ nhỏ hơn nhiều so với EASE đầy đủ, với chất lượng gần tương đương ở phần lớn các mức d (RQ1–RQ3).

Nhóm cần huấn luyện. Diffusion-Filtered History Factorization có NDCG@20 cao nhất nhóm ở cả bốn mức d, với khoảng tin cậy không chứa 0 so với LightGCN, XSimGCL và DirectAU. Đổi lại, DFHF có thời gian mỗi epoch dài nhất nhóm và kết quả phụ thuộc mạnh vào việc chọn checkpoint trên validation. Ở mức thưa nhất ($d = 0{,}25$), ưu thế của DFHF chủ yếu đến từ việc rơi về thứ tự độ phổ biến cho người dùng chỉ còn một tương tác: ở mức này DFHF chỉ ngang một xếp hạng theo độ phổ biến, và không mô hình nào trong báo cáo vượt được mốc đó (RQ1–RQ3).

Hệ thống. Cả hai mô hình đều chấm điểm được lịch sử mới mà không cần huấn luyện lại; hệ thống demo minh họa điều này và hiển thị phân rã đại số của điểm GRNR làm lời giải thích cho gợi ý (RQ4).

Các kết luận trên chỉ đúng trong phạm vi một bộ dữ liệu, một seed, kết quả trên validation đã dùng để chọn checkpoint và cấu hình, và ngân sách tinh chỉnh không cân bằng giữa mô hình đề xuất và baseline.

5.2 Hướng phát triển

Theo thứ tự ưu tiên:

1. **Xác nhận trên dữ liệu chưa dùng để chọn.** Đánh giá các cấu hình đã khóa trên tập test, hoặc trên một nửa validation chưa tham gia vào việc chọn, để có ước lượng không bị nâng lạc quan.
2. **Nhiều seed.** Lặp lại việc huấn luyện và việc lấy mẫu train với nhiều seed để ước lượng biến động giữa các lần chạy.
3. **Thí nghiệm loại bỏ thành phần.** Với DFHF: thay bộ lọc khuếch tán bằng

$F = I$, và gán trọng số khác 0 cho lịch sử đơn. Với GRNR: bỏ điều chuẩn đồ thị, bỏ hệ số độ phổ biến khi xếp hạng. Mục tiêu là kiểm tra các giả thuyết cơ chế ở Mục 4.6.

4. **Tinh chỉnh baseline cân bằng.** Cho các baseline cùng ngân sách tinh chỉnh với mô hình đề xuất và đủ số epoch để hội tụ, đặc biệt với DirectAU.
5. **Mở rộng dữ liệu.** Thêm bộ dữ liệu khác và thiết kế một đánh giá riêng cho người dùng mới, thay cho tab minh họa trong demo.

TÀI LIỆU THAM KHẢO

[1] Y. Hu, Y. Koren, C. Volinsky. Collaborative Filtering for Implicit Feedback Datasets. In *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, trang 263–272, 2008. DOI: 10.1109/ICDM.2008.22.

[2] S. Rendle, C. Freudenthaler, Z. Gantner, L. Schmidt-Thieme. BPR: Bayesian Personalized Ranking from Implicit Feedback. In *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)*, 2009. arXiv: 1205.2618.

[3] Y. Koren. Factorization Meets the Neighborhood: A Multifaceted Collaborative Filtering Model. In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, trang 426–434, 2008. DOI: 10.1145/1401890.1401944.

[4] X. Ning, G. Karypis. SLIM: Sparse Linear Methods for Top-N Recommender Systems. In *2011 IEEE 11th International Conference on Data Mining (ICDM)*, trang 497–506, 2011. DOI: 10.1109/ICDM.2011.134.

[5] S. Kabbur, X. Ning, G. Karypis. FISM: Factored Item Similarity Models for Top-N Recommender Systems. In *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, trang 659–667, 2013. DOI: 10.1145/2487575.2487589.

[6] J. McAuley, C. Targett, Q. Shi, A. van den Hengel. Image-Based Recommendations on Styles and Substitutes. In *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval*, trang 43–52, 2015. DOI: 10.1145/2766462.2767755.

[7] R. He, J. McAuley. Ups and Downs: Modeling the Visual Evolution of Fashion Trends with One-Class Collaborative Filtering. In *Proceedings of the 25th International Conference on World Wide Web (WWW)*, 2016. DOI: 10.1145/2872427.2883037.

[8] D. Liang, R. G. Krishnan, M. D. Hoffman, T. Jebara. Variational Autoencoders for Collaborative Filtering. In *Proceedings of the 2018 World Wide Web Conference (WWW)*, trang 689–698, 2018. DOI: 10.1145/3178876.3186150.

[9] H. Steck. Embarrassingly Shallow Autoencoders for Sparse Data. In *The World Wide Web Conference (WWW)*, 2019. DOI: 10.1145/3308558.3313710.

[10] M. Ferrari Dacrema, P. Cremonesi, D. Jannach. Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches. In *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys)*, 2019. DOI: 10.1145/3298689.3347058.

[11] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, M. Wang. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, trang 639–648, 2020. DOI: 10.1145/3397271.3401063.

[12] W. Krichene, S. Rendle. On Sampled Metrics for Item Recommendation. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, trang 1748–1757, 2020. DOI: 10.1145/3394486.3403226.

[13] Z. Sun, D. Yu, H. Fang, J. Yang, X. Qu, J. Zhang, C. Geng. Are We Evaluating Rigorously? Benchmarking Recommendation for Reproducible Evaluation and Fair Comparison. In *Fourteenth ACM Conference on Recommender Systems (RecSys)*, trang 23–32, 2020. DOI: 10.1145/3383313.3412489.

[14] Y. Shen, Y. Wu, Y. Zhang, C. Shan, J. Zhang, K. B. Letaief, D. Li. How Powerful is Graph Convolution for Recommendation? In *Proceedings of the 30th ACM International Conference on Information & Knowledge Management (CIKM)*, trang 1619–1629, 2021. DOI: 10.1145/3459637.3482264.

[15] C. Wang, Y. Yu, W. Ma, M. Zhang, C. Chen, Y. Liu, S. Ma. Towards Representation Alignment and Uniformity in Collaborative Filtering. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2022. DOI: 10.1145/3534678.3539253.

[16] Y. Ji, A. Sun, J. Zhang, C. Li. A Critical Study on Data Leakage in Recommender System Offline Evaluation. *ACM Transactions on Information Systems*, 41(3):75:1–75:27, 2023. DOI: 10.1145/3569930.

[17] J. Yu, X. Xia, T. Chen, L. Cui, N. Q. V. Hung, H. Yin. XSimGCL: Towards Extremely Simple Graph Contrastive Learning for Recommendation. *IEEE Transactions on Knowledge and Data Engineering*, 2023. DOI: 10.1109/TKDE.2023.3288135.