BỘ GIÁO DỤC VÀ ĐÀO TẠO

ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN

_____ o0o _____



BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN: HỌC MÁY NÂNG CAO 1-1-26(N01)

ĐỀ TÀI: HỆ THỐNG KHUYẾN NGHỊ SẢN PHẨM ĐIỆN TỬ BẰNG HỒI QUY LÂN CẬN VÀ KHUẾCH TÁN TRÊN ĐỒ THỊ

Đặng Anh Tuyền	**MSSV:** 23010912 **Lớp:** K17-KHMT(AI&KHDL)_1
Phạm Văn Sự	**MSSV:** 23010523 **Lớp:** K17-KHMT(AI&KHDL)_1
Nguyễn Chí Tài	**MSSV:** 23010548 **Lớp:** K17-KHMT(AI&KHDL)_1

GVHD: PGS.TS. Phạm Tiến Lâm

Hà Nội, Năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC PHENIKAA
TRƯỜNG CÔNG NGHỆ THÔNG TIN

_____ o0o _____

Đặng Anh Tuyền **MSSV:** 23010912
Lớp: K17-KHMT(AI&KHDL)_1

Phạm Văn Sự **MSSV:** 23010523
Lớp: K17-KHMT(AI&KHDL)_1

Nguyễn Chí Tài **MSSV:** 23010548
Lớp: K17-KHMT(AI&KHDL)_1

BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN: HỌC MÁY NÂNG CAO 1-1-26(N01)

HỆ THỐNG KHUYẾN NGHỊ SẢN PHẨM ĐIỆN TỬ BẰNG HỒI QUY LÂN CẬN VÀ KHUẾCH TÁN TRÊN ĐỒ THỊ

GVHD: PGS.TS. Phạm Tiến Lâm

Hà Nội, Năm 2026

BẢNG PHÂN CHIA CÔNG VIỆC

STT	Họ và tên	Vai trò	Nội dung công việc	Tỷ lệ
1	Đặng Anh Tuyền	**Trưởng nhóm**	• Điều phối nhóm • Tiền xử lý dữ liệu và chia tập theo thời gian • Tạo các mức giảm dữ liệu huấn luyện • Đề xuất và cài đặt GRNR • Cài đặt EASE và GF-CF • Tham gia xây dựng báo cáo và slide	**33%**
2	Phạm Văn Sự	Thành viên	• Đề xuất và cài đặt DFHF • Cài đặt LightGCN, XSimGCL và DirectAU • Huấn luyện các mô hình nhóm cần huấn luyện trên Kaggle • Tham gia xây dựng báo cáo và slide	**33%**
3	Nguyễn Chí Tài	Thành viên	• Xây dựng giao thức đánh giá • Cài đặt kiểm định bootstrap ghép cặp • Phân tích kết quả và vẽ biểu đồ • Xây dựng hệ thống demo • Tham gia xây dựng báo cáo và slide	**33%**

Repository dự án: github.com/tuyenda2011/GRNR-DFHF-RecSys

Mục lục

Danh mục từ viết tắt **7**

Danh mục ký hiệu **9**

1 Giới thiệu **10**
1.1 Bối cảnh và động cơ 10
1.2 Thách thức của bài toán 10
1.3 Hướng tiếp cận 11
1.4 Câu hỏi nghiên cứu và phạm vi 13

2 Cơ sở lý thuyết và nghiên cứu liên quan **15**
2.1 Phát biểu bài toán và ký hiệu 15
2.2 Nhóm giải trực tiếp 16
2.2.1 Lân cận sản phẩm và hồi quy thưa 16
2.2.2 Embarrassingly Shallow Autoencoder 16
2.2.3 Graph Filter based Collaborative Filtering 17
2.2.4 Tổng hợp và câu hỏi thiết kế 18
2.3 Nhóm cần huấn luyện 18
2.3.1 Phân rã ma trận và các hướng mở rộng 19
2.3.2 Light Graph Convolution Network 20
2.3.3 eXtremely Simple Graph Contrastive Learning 20
2.3.4 DirectAU 21
2.3.5 Tổng hợp và câu hỏi thiết kế 22

3 Phương pháp và thuật toán đề xuất **23**
3.1 Công cụ toán học 23
3.1.1 Hồi quy có trọng số và điều chuẩn 23
3.1.2 Đồng xuất hiện 23
3.1.3 Laplacian của đồ thị 24
3.1.4 Ma trận chuyển hai bước 24
3.1.5 Hàm mất mát softmax trên toàn danh mục 25
3.2 Graph-Regularized Neighborhood Regression 25
3.2.1 Lựa chọn láng giềng và đồ thị sản phẩm 25
3.2.2 Hàm mục tiêu và phương pháp giải 27
3.2.3 Thuật toán huấn luyện và suy luận 28
3.3 Diffusion-Filtered History Factorization 29

3.3.1 Biểu diễn lịch sử và bộ lọc khuếch tán 31
3.3.2 Hàm mục tiêu và phương pháp tối ưu 32
3.3.3 Thuật toán huấn luyện và suy luận 33
3.4 Phân tích tính chất và chi phí tính toán 34

4 Thiết lập thực nghiệm 37
4.1 Dữ liệu và tiền xử lý 37
4.2 Tiêu chí so sánh 39
4.2.1 Đơn vị đánh giá và thước đo xếp hạng 39
4.2.2 Đại lượng so sánh và kiểm định 41
4.3 Cấu hình thực nghiệm 42

5 Kết quả và thảo luận 45
5.1 Graph-Regularized Neighborhood Regression so với các mô hình giải trực tiếp 45
5.1.1 Chất lượng xếp hạng khi có đủ dữ liệu 45
5.1.2 Chất lượng theo thước đo và độ dài danh sách 46
5.1.3 Chất lượng khi dữ liệu thưa dần 49
5.1.4 Nguồn tín hiệu khi dữ liệu thưa 52
5.1.5 Chất lượng theo độ dài lịch sử người dùng 54
5.1.6 Chi phí tính toán 57
5.2 Diffusion-Filtered History Factorization so với các mô hình cần huấn luyện 58
5.2.1 Chất lượng xếp hạng khi có đủ dữ liệu 59
5.2.2 Chất lượng theo thước đo và độ dài danh sách 60
5.2.3 Chất lượng khi dữ liệu thưa dần 63
5.2.4 Nguồn tín hiệu khi dữ liệu thưa 66
5.2.5 Chất lượng theo độ dài lịch sử người dùng 67
5.2.6 Quá trình huấn luyện và chi phí tính toán 70
5.3 Hệ thống demo 73
5.3.1 Cài đặt môi trường và khởi động 73
5.3.2 Gợi ý cho người dùng có sẵn 73
5.3.3 Gợi ý từ lịch sử nhập mới 75
5.3.4 Tra cứu kết quả thực nghiệm 76
5.4 Thảo luận và hạn chế 78
5.4.1 Hai chế độ dữ liệu 78
5.4.2 Ý nghĩa đối với từng mô hình đề xuất 79

5.4.3 Các giải thích cạnh tranh 79
5.4.4 Đối chiếu với tài liệu 80
5.4.5 Hạn chế 80

6 Kết luận và hướng phát triển **82**
6.1 Kết luận 82
6.2 Hướng phát triển 83

TÀI LIỆU THAM KHẢO **85**

Danh sách hình ảnh

3.1 Sơ đồ hoạt động của GRNR 26
3.2 Sơ đồ hoạt động của DFHF 30
4.1 Quy trình tiền xử lý dữ liệu 37
5.1 NDCG@10 theo mức d, nhóm giải trực tiếp 47
5.2 NDCG@20 theo mức d, nhóm giải trực tiếp 47
5.3 Recall@10 theo mức d, nhóm giải trực tiếp 48
5.4 Recall@20 theo mức d, nhóm giải trực tiếp 49
5.5 NDCG@K, nhóm giải trực tiếp 49
5.6 NDCG@20 so với MostPop, nhóm giải trực tiếp 50
5.7 Tỉ lệ duy trì NDCG@10, nhóm giải trực tiếp 51
5.8 Tỉ lệ duy trì NDCG@20, nhóm giải trực tiếp 51
5.9 Tỉ lệ duy trì Recall@10, nhóm giải trực tiếp 52
5.10 Tỉ lệ duy trì Recall@20, nhóm giải trực tiếp 52
5.11 NDCG@20 theo độ dài lịch sử, nhóm giải trực tiếp 55
5.12 NDCG@10 theo độ dài lịch sử, nhóm giải trực tiếp 56
5.13 Recall@10 theo độ dài lịch sử, nhóm giải trực tiếp 56
5.14 Recall@20 theo độ dài lịch sử, nhóm giải trực tiếp 57
5.15 Dung lượng lưu trữ, nhóm giải trực tiếp 58
5.16 NDCG@10 theo mức d, nhóm cần huấn luyện 61
5.17 NDCG@20 theo mức d, nhóm cần huấn luyện 61
5.18 Recall@10 theo mức d, nhóm cần huấn luyện 62
5.19 Recall@20 theo mức d, nhóm cần huấn luyện 62
5.20 NDCG@K, nhóm cần huấn luyện 63
5.21 NDCG@20 so với MostPop, nhóm cần huấn luyện 63
5.22 Tỉ lệ duy trì NDCG@10, nhóm cần huấn luyện 64
5.23 Tỉ lệ duy trì NDCG@20, nhóm cần huấn luyện 65
5.24 Tỉ lệ duy trì Recall@10, nhóm cần huấn luyện 65
5.25 Tỉ lệ duy trì Recall@20, nhóm cần huấn luyện 66
5.26 NDCG@20 theo độ dài lịch sử, nhóm cần huấn luyện 68
5.27 NDCG@10 theo độ dài lịch sử, nhóm cần huấn luyện 69
5.28 Recall@10 theo độ dài lịch sử, nhóm cần huấn luyện 69
5.29 Recall@20 theo độ dài lịch sử, nhóm cần huấn luyện 70
5.30 Đường học NDCG@20, nhóm cần huấn luyện 71
5.31 Đường học NDCG@10, nhóm cần huấn luyện 71
5.32 Hàm mất mát huấn luyện, nhóm cần huấn luyện 72

5.33 Giao diện gợi ý cho người dùng có sẵn 74
5.34 Tìm sản phẩm và tạo lịch sử cho người dùng mới 75
5.35 Màn hình tổng quan của nhóm giải trực tiếp tại tỉ lệ dữ liệu 25% . . . 76
5.36 Biểu đồ chất lượng theo dữ liệu và theo dung lượng, nhóm giải trực tiếp 77
5.37 Màn hình kiểm định của nhóm cần huấn luyện tại tỉ lệ dữ liệu 100% . 77
5.38 Màn hình kiểm định của nhóm cần huấn luyện tại tỉ lệ dữ liệu 25% . . 77
5.39 Thư viện hình của nhóm cần huấn luyện trong ứng dụng 78

Danh sách bảng

2.1 Các baseline của nhóm giải trực tiếp 19
2.2 Các baseline của nhóm cần huấn luyện 22
3.1 Đặc điểm lý thuyết của GRNR và EASE 34
3.2 Đặc điểm lý thuyết của DFHF và LightGCN 35
4.1 Thống kê dữ liệu sau tiền xử lý 38
4.2 Kết quả chia tập theo thời gian 38
4.3 Tập huấn luyện ở các mức giảm tương tác 39
4.4 Cấu hình và môi trường chạy 43
4.5 Siêu tham số của GRNR 43
4.6 Siêu tham số của DFHF 44
5.1 Chất lượng xếp hạng, nhóm giải trực tiếp 45
5.2 Kiểm định NDCG@20, nhóm giải trực tiếp 46
5.3 Mức vượt MostPop, nhóm giải trực tiếp 50
5.4 Đồng xuất hiện còn lại trong tập huấn luyện 53
5.5 Độ phổ biến và độ phủ, nhóm giải trực tiếp 54
5.6 Chất lượng xếp hạng, nhóm cần huấn luyện 59
5.7 Kiểm định NDCG@20, nhóm cần huấn luyện 60
5.8 Mức vượt MostPop, nhóm cần huấn luyện 64
5.9 NDCG@20 theo số tương tác còn lại ($d = 0{,}25$) 66
5.10 Độ phổ biến và độ phủ, nhóm cần huấn luyện 67
5.11 Huấn luyện và chi phí ($d = 1$), nhóm cần huấn luyện 72

Danh mục từ viết tắt

Viết tắt	Tên đầy đủ hoặc ý nghĩa
BPR	Bayesian Personalized Ranking, hàm mất mát xếp hạng theo cặp
BSPM	Blurring-Sharpening Process Models, mô hình lọc đồ thị gần đây, không chạy trong thực nghiệm
CPU, GPU	Central Processing Unit (bộ xử lý trung tâm), Graphics Processing Unit (bộ xử lý đồ họa)
DCG	Discounted Cumulative Gain, tổng lợi ích chiết khấu theo vị trí
IDCG	Ideal Discounted Cumulative Gain, giá trị DCG của thứ tự lý tưởng
DFHF	Diffusion-Filtered History Factorization, mô hình đề xuất thuộc nhóm cần huấn luyện
DirectAU	Tên riêng, bài gốc không nêu dạng đầy đủ; hàm mục tiêu tối ưu trực tiếp tính căn chỉnh (alignment) và tính đồng đều (uniformity), baseline thuộc nhóm cần huấn luyện
EASE	Embarrassingly Shallow Autoencoder, baseline thuộc nhóm giải trực tiếp
FISM	Factored Item Similarity Models
GF-CF	Graph Filter based Collaborative Filtering, baseline thuộc nhóm giải trực tiếp
GRNR	Graph-Regularized Neighborhood Regression, mô hình đề xuất thuộc nhóm giải trực tiếp
KTC	Khoảng tin cậy
LightGCN	Light Graph Convolution Network, baseline thuộc nhóm cần huấn luyện
GiB	Gibibyte (2^{30} byte)
MiB	Mebibyte (2^{20} byte)
MostPop	Xếp hạng theo độ phổ biến, mốc tham chiếu không cá nhân hóa
Mult-VAE	Variational Autoencoder với phân phối đa thức

Viết tắt	Tên đầy đủ hoặc ý nghĩa
NDCG@K	Normalized Discounted Cumulative Gain at K
Recall@K	Recall at K, tỉ lệ sản phẩm mục tiêu nằm trong K vị trí đầu
SLIM	Sparse Linear Methods
XSimGCL	eXtremely Simple Graph Contrastive Learning, baseline thuộc nhóm cần huấn luyện

Danh mục ký hiệu

Bảng dưới liệt kê các ký hiệu dùng xuyên suốt báo cáo. Ký hiệu chỉ dùng trong một công thức được giải thích ngay tại chỗ.

Ký hiệu	Ý nghĩa	Định nghĩa
$\mathcal{U}, \mathcal{I}$	Tập người dùng, tập sản phẩm	Mục 2.1
X	Ma trận tương tác nhị phân, $X_{ui} = 1$ nếu đã quan sát được tương tác	Định nghĩa 2.1
x_u	Hàng u của X, tức lịch sử của người dùng u dưới dạng vector	Mục 2.1
H_u, n_u	Lịch sử của người dùng u và độ dài lịch sử	Mục 2.1
c_i	Số người dùng đã tương tác với sản phẩm i (độ phổ biến)	Mục 2.1
D_U, D_I	Ma trận bậc của người dùng và của sản phẩm	Mục 2.1
E, $\lvert E\rvert$	Tập tương tác và số tương tác	Mục 2.1
$s(u, i)$	Điểm mô hình gán cho cặp (u, i)	Định nghĩa 2.2
$\mathcal{C}_u$	Tập sản phẩm ứng viên hợp lệ của người dùng u	Định nghĩa 2.2
K	Số sản phẩm trong danh sách gợi ý	Định nghĩa 2.2
f	Số chiều embedding	Mục 2.3
λ	Hệ số phạt ridge của EASE	Mục 2.2.2
κ_{lift}	Hằng số làm trơn điểm dư đồng xuất hiện của GRNR	(3.9)
ω_+	Trọng số mẫu dương của GRNR	(3.12)
ρ_{pop}	Số mũ điều chỉnh độ phổ biến của GRNR	Mục 3.2.3
λ_{emb}	Hệ số phạt ridge cho embedding của DFHF	(3.23)
Ω, P	Ma trận trọng số mẫu, ma trận phạt trong hồi quy có trọng số	Định nghĩa 3.1
C, C°	Ma trận đồng xuất hiện và phiên bản có đường chéo bằng 0	Mục 2.1, Định nghĩa 3.2
A, D_A	Ma trận kề của một đồ thị và ma trận bậc của nó	Định nghĩa 3.3
$\tilde{A}$, L	Ma trận kề chuẩn hóa, Laplacian chuẩn hóa	Định nghĩa 3.3
T	Ma trận chuyển hai bước sản phẩm $\to$ người dùng $\to$ sản phẩm	(3.6)
$\mathcal{B}$, b	Ma trận hệ số sản phẩm–sản phẩm và vector chặn của GRNR	Mục 3.2.3
S, V, b	Hai bảng nguồn, đích và vector chặn của DFHF	Mục 3.3.1
F, π_i	Bộ lọc khuếch tán và xác suất sản phẩm i được lấy làm đích	Mục 3.3.1, 3.3.2
$\mathcal{Q}$	Lô, tập tương tác dùng trong một bước cập nhật	Mục 2.3
$\mathbb{E}$	Kỳ vọng	Mục 3.1.2
d	Tỉ lệ tương tác huấn luyện được giữ lại	Mục 4.1

1 Giới thiệu

1.1 Bối cảnh và động cơ

Một sàn thương mại điện tử có từ hàng chục nghìn đến hàng triệu sản phẩm, trong khi mỗi người dùng chỉ biết đến một phần rất nhỏ trong số đó. Hệ thống khuyến nghị thu hẹp khoảng cách này bằng một danh sách ngắn gồm những sản phẩm người dùng nhiều khả năng quan tâm. Báo cáo xét dạng phổ biến nhất của bài toán, gọi là *khuyến nghị top-K*: dựa vào lịch sử của một người dùng, mô hình xếp hạng các sản phẩm người đó chưa tương tác rồi chọn ra K sản phẩm đứng đầu.

Trong phần lớn hệ thống thực tế, ta không có điểm số của người dùng cho từng sản phẩm. Thứ hệ thống thường biết chỉ là người dùng đã mua, đã xem hay đã đánh giá tốt những sản phẩm nào. Dữ liệu kiểu này gọi là *phản hồi ngầm* [1], và nó mơ hồ ở một điểm cơ bản: một sản phẩm chưa được tương tác có thể là sản phẩm người dùng không thích, nhưng cũng có thể chỉ là sản phẩm họ chưa từng thấy. Phương pháp nào cũng phải xử lý sự mơ hồ này, hoặc bằng cách tin các ô có tương tác hơn các ô trống [1], hoặc bằng cách chỉ học thứ tự giữa sản phẩm đã và chưa tương tác [2].

Nhóm sử dụng danh mục Electronics trong bộ dữ liệu đánh giá sản phẩm Amazon của McAuley và cộng sự [6,7]. Bộ dữ liệu công khai, được dùng rộng rãi trong nghiên cứu, và có thời điểm của từng đánh giá nên chia được tập theo thứ tự thời gian. Dữ liệu ghi số sao từ 1 đến 5, nhưng nhóm chỉ giữ lại một thông tin: người dùng có đánh giá tốt sản phẩm hay không. Đánh giá từ 4 sao trở lên được coi là một tương tác, còn mức sao cụ thể bị bỏ. Bài toán top-K chỉ cần biết người dùng quan tâm đến sản phẩm nào, và cách làm này cho mọi mô hình cùng một dạng đầu vào; cái giá là những đánh giá thấp không được dùng đến. Vì thế, "tương tác" trong báo cáo là một đánh giá tích cực công khai, không phải một lượt mua. Sau tiền xử lý, dữ liệu còn 124.895 người dùng, 44.843 sản phẩm và khoảng 1,07 triệu tương tác.

1.2 Thách thức của bài toán

Dữ liệu này có ba đặc điểm chi phối cách xây dựng mô hình, và việc đánh giá mô hình trên nó cũng có những cạm bẫy riêng.

Trước hết, dữ liệu rất thưa. Chỉ khoảng 0,02% số ô của ma trận tương tác khác 0, và một nửa số người dùng có không quá 6 tương tác. Mỗi người dùng chỉ để lại vài manh mối về sở thích, nên một biểu diễn học riêng cho từng người rất dễ bị nhiễu chi phối. Trường hợp khó nhất là khi người dùng chỉ còn đúng một tương tác, và nhóm xem xét kỹ trường hợp này khi giảm dần dữ liệu huấn luyện.

Đặc điểm thứ hai là lịch sử của người dùng luôn thay đổi. Nhiều mô hình phổ

biến, như phân rã ma trận [29] hay các mô hình đồ thị kiểu Light Graph Convolution Network (LightGCN) [11], gán cho mỗi người dùng một vector riêng học trong lúc huấn luyện. Khi người dùng có thêm tương tác, hoặc khi có người dùng mới, vector đó không còn đúng nữa và chỉ cập nhật được bằng cách huấn luyện lại. Ngược lại, có những mô hình tính điểm của một sản phẩm trực tiếp từ các sản phẩm trong lịch sử, chẳng hạn các mô hình láng giềng sản phẩm [4, 9, 28] hay Factored Item Similarity Models (FISM) [5]. Những mô hình này chấm được một lịch sử mới ngay lập tức. Nhóm coi đây là một tính chất có lợi khi triển khai, có được nhờ thiết kế và được minh họa trong ứng dụng demo, nhưng không đo lợi ích của nó bằng số liệu. Điều được đánh giá là mặt trái của lựa chọn này: khi người dùng được biểu diễn hoàn toàn bằng lịch sử, chất lượng phụ thuộc vào việc lịch sử có đủ dài hay không, mà dữ liệu thưa thì không bảo đảm điều đó.

Đặc điểm thứ ba là độ phổ biến tự nó đã là một đối thủ mạnh. Trong thương mại điện tử, một số ít sản phẩm chiếm phần lớn tương tác: ở tập huấn luyện của dự án, 1% sản phẩm phổ biến nhất chiếm 19,2% số tương tác, còn 10% phổ biến nhất chiếm tới 51,8%. Chỉ cần gợi ý những sản phẩm phổ biến nhất (MostPop) cũng đã đạt một mức chất lượng đáng kể, và Dacrema cùng cộng sự cho thấy nhiều mô hình mạng nơ-ron đã công bố không vượt được các phương pháp đơn giản nếu những phương pháp này được thiết lập cẩn thận [10]. Trong các công trình nhóm đã đọc, mô hình mới thường chỉ được so với các mô hình khác; khoảng cách giữa mô hình và cách gợi ý theo độ phổ biến, cùng sự thay đổi của khoảng cách đó khi dữ liệu thưa dần, hiếm khi được báo cáo riêng. Đây là trục chính trong phần đánh giá độ thưa của báo cáo.

Bên cạnh ba đặc điểm trên, việc đánh giá có ba cạm bẫy đã được ghi nhận:

- thước đo tính trên một mẫu nhỏ sản phẩm âm có thể đảo thứ tự giữa các mô hình [12];
- cách chia dữ liệu và cách chọn siêu tham số có thể làm thay đổi kết luận [13];
- chia tập không theo thứ tự thời gian có thể làm lộ thông tin của tương lai [16].

Giao thức đánh giá của dự án được thiết kế để tránh hoặc giảm nhẹ từng cạm bẫy này.

1.3 Hướng tiếp cận

Theo cách học tham số, các mô hình khuyến nghị dựa trên phản hồi ngầm chia thành hai nhóm.

Nhóm giải trực tiếp tính tham số bằng một công thức đóng hoặc một phép lọc tuyến tính, không có vòng lặp huấn luyện, và mọi mô hình trong nhóm đều biểu diễn người dùng bằng lịch sử. Hai đại diện tiêu biểu là Embarrassingly Shallow Autoencoder

(EASE) [9] và Graph Filter based Collaborative Filtering (GF-CF) [14]. Hướng này vẫn đang phát triển: các công trình gần đây như Blurring-Sharpening Process Models (BSPM) [18] và Turbo-CF [19] tiếp tục khai thác đồ thị giữa các sản phẩm để giữ chất lượng với chi phí tính toán thấp hơn.

Nhóm cần huấn luyện học embedding, tức vector biểu diễn của sản phẩm và thường của cả người dùng, bằng tối ưu theo gradient qua nhiều epoch. LightGCN, eXtremely Simple Graph Contrastive Learning (XSimGCL) [17] và DirectAU [15] đều thuộc nhóm này; trong báo cáo, DirectAU được ghép với bộ mã hóa của LightGCN. Cả ba đều dùng vector riêng cho từng người dùng.

Nếu đem một mô hình giải trực tiếp so với một mô hình cần huấn luyện, rất khó biết chênh lệch đến từ đâu, vì hai bên khác nhau cả về chi phí, cách tinh chỉnh lẫn phần cứng phù hợp. Vì vậy nhóm đề xuất một mô hình cho mỗi nhóm và chỉ so mô hình đó với các baseline (mô hình đối chứng) cùng nhóm. Hai mô hình đề xuất được đánh giá độc lập, không so với nhau.

Graph-Regularized Neighborhood Regression (GRNR) thuộc nhóm giải trực tiếp và xuất phát từ một câu hỏi thực dụng. EASE thường là một baseline rất mạnh nhưng cần một ma trận trọng số đầy đủ, có kích thước bằng bình phương số sản phẩm. Liệu có thể thay ma trận đó bằng một số ít láng giềng được ước lượng cẩn thận mà không mất chất lượng? GRNR giải một bài toán hồi quy nhỏ cho mỗi sản phẩm, chỉ trên tối đa 128 sản phẩm láng giềng, với trọng số dành cho dữ liệu ngầm và điều chuẩn theo đồ thị giữa các láng giềng. Ở quy mô của dự án (44.843 sản phẩm), ma trận đầy đủ của EASE chiếm khoảng 7,5 GiB và vẫn chạy được, nên lợi ích về bộ nhớ của GRNR mới chỉ là dự phóng cho những danh mục lớn hơn. Điều kiểm chứng được trên dữ liệu này là chất lượng: GRNR có giữ được chất lượng của EASE đầy đủ khi chỉ dùng một phần nhỏ số hệ số hay không.

Diffusion-Filtered History Factorization (DFHF) thuộc nhóm cần huấn luyện. Khác với ba baseline cùng nhóm, DFHF không có vector người dùng: mỗi người dùng được mô tả bằng embedding của các sản phẩm trong lịch sử, theo hướng của FISM [5]. Hai bảng embedding sản phẩm được làm trơn bằng một bộ lọc khuếch tán trên đồ thị người dùng–sản phẩm, để một sản phẩm ít tương tác mượn được thông tin từ những sản phẩm mà cùng nhóm người dùng đã tương tác. Mô hình được huấn luyện bằng softmax trên toàn bộ danh mục, tức so sản phẩm đúng với mọi sản phẩm ứng viên cùng lúc [8]. Lựa chọn này lấy động cơ từ phân tích của Wu và cộng sự về softmax lấy mẫu: hàm mất mát này gắn với việc tối đa hóa thước đo xếp hạng, và phép lan truyền trên đồ thị bù được điểm yếu của nó trong việc điều chỉnh độ lớn của vector biểu diễn [20]. DFHF dùng softmax trên toàn danh mục thay vì lấy mẫu, nên phân tích này là cơ sở thiết kế chứ không phải một bảo đảm cho mô hình. Câu hỏi

với DFHF là một mô hình như vậy có cạnh tranh được với các mô hình đồ thị dùng vector người dùng hay không.

Dữ liệu gốc đã qua bộ lọc 5-core, tức chỉ giữ những người dùng và sản phẩm có ít nhất 5 đánh giá, nên dày hơn dữ liệu của một hệ thống thực tế. Để xét những mức thưa gần thực tế hơn, nhóm giảm tập huấn luyện xuống còn 75%, 50% và 25% số tương tác rồi đánh giá lại mọi mô hình. Ở mỗi mức, kết quả được đặt cạnh MostPop để xem mô hình còn hơn cách gợi ý theo độ phổ biến bao nhiêu khi dữ liệu thưa dần. Cách giảm ngẫu nhiên này chỉ mô phỏng độ thưa, không tái hiện đúng tình huống người dùng mới: mọi người dùng vẫn giữ ít nhất một tương tác, và người dùng nhiều tương tác mất nhiều dữ liệu hơn người dùng ít tương tác.

Dự án có ba đóng góp: hai mô hình biểu diễn người dùng bằng lịch sử, mỗi mô hình cho một nhóm phương pháp và đều chấm được lịch sử mới mà không cần huấn luyện lại; một đánh giá có kiểm soát trong từng nhóm, với cùng tập ứng viên, cùng người dùng, bốn mức thưa, kiểm định thống kê ghép cặp theo từng người dùng và đối chiếu có hệ thống với MostPop; và một kho dự án lưu mã nguồn, cấu hình và kết quả của các lần chạy, kèm một ứng dụng demo cho phép thử gợi ý với lịch sử tùy ý. Cả hai mô hình được ghép từ những thành phần đã biết. Trong các tài liệu nhóm đã đọc, chưa thấy công trình nào kết hợp đúng các thành phần này (Mục 2.2.4 và Mục 2.3.5), nhưng nhóm không cho rằng đây là những phương pháp hoàn toàn mới.

1.4 Câu hỏi nghiên cứu và phạm vi

Mục tiêu của đề tài là xây dựng hai mô hình khuyến nghị biểu diễn người dùng bằng lịch sử, mỗi mô hình cho một nhóm phương pháp, và đánh giá chúng một cách có kiểm soát, nhất là khi dữ liệu thưa dần. Thước đo chính là Normalized Discounted Cumulative Gain tại 20 vị trí đầu (NDCG@20), cho biết sản phẩm người dùng thực sự tương tác tiếp theo có nằm trong 20 gợi ý đầu hay không và nằm ở vị trí nào. Báo cáo trả lời bốn câu hỏi:

1. Trong nhóm của mình, mỗi mô hình đề xuất có NDCG@20 cao hơn các baseline cùng nhóm không, và chênh lệch có vượt khỏi biến động theo người dùng không?
2. Khi chỉ giữ lại 75%, 50% hoặc 25% tương tác huấn luyện, chất lượng của mỗi mô hình thay đổi thế nào so với các baseline cùng nhóm và so với MostPop?
3. Chi phí tính toán của mỗi mô hình, gồm thời gian huấn luyện, thời gian suy luận và dung lượng lưu trữ, so với nhóm của nó ra sao?
4. Hai mô hình phục vụ một lịch sử mới như thế nào khi triển khai, và điểm số của

GRNR có phân rã được thành lý do gợi ý hay không?

Phạm vi của báo cáo có những giới hạn rõ ràng:

- Mọi kết quả được đo trên tập xác thực của một bộ dữ liệu, với một seed (giá trị khởi tạo bộ sinh số ngẫu nhiên), và chỉ trên những người dùng có sản phẩm mục tiêu nằm trong tập ứng viên.
- Chất lượng được đo bằng thước đo xếp hạng ngoại tuyến; báo cáo không đánh giá doanh thu, mức hài lòng hay hành vi của người dùng thật.
- Câu hỏi thứ tư được trả lời bằng mô tả hệ thống và một ví dụ minh họa, không bằng phép đo định lượng.
- Các câu hỏi được chốt sau khi đã có kết quả thực nghiệm, và MostPop được bổ sung trong lúc phân tích. Vì vậy mọi phân tích, kể cả các so sánh với MostPop, đều mang tính khám phá chứ không phải kiểm định một giả thuyết đặt ra từ trước, và kết luận cần được xác nhận trên dữ liệu chưa dùng để chọn cấu hình.

2 Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Phát biểu bài toán và ký hiệu

Định nghĩa 2.1 (Dữ liệu phản hồi ngầm) Cho tập người dùng $\mathcal{U}$ và tập sản phẩm $\mathcal{I}$. Phản hồi ngầm được biểu diễn bằng ma trận nhị phân $X \in \{0,1\}^{|\mathcal{U}|\times|\mathcal{I}|}$, trong đó $X_{ui} = 1$ nếu dữ liệu ghi nhận một tương tác được xem là tích cực giữa người dùng u và sản phẩm i, và $X_{ui} = 0$ nếu chưa ghi nhận tương tác như vậy.

Các đại lượng sau được dùng trong toàn báo cáo:

- $x_u \in \{0,1\}^{|\mathcal{I}|}$ là hàng u của X, tức lịch sử của người dùng u dưới dạng vector;
- $H_u = \{i : X_{ui} = 1\}$ là lịch sử của người dùng u, và $n_u = |H_u|$ là độ dài lịch sử;
- $c_i = \sum_u X_{ui}$ là số người dùng đã tương tác với sản phẩm i, gọi là độ phổ biến của i;
- $C_{ji} = \sum_u X_{uj}X_{ui}$ là số người dùng chung của hai sản phẩm j và i;
- $D_U = \mathrm{diag}(n_u)$ và $D_I = \mathrm{diag}(c_i)$ là ma trận đường chéo chứa độ dài lịch sử và độ phổ biến;
- $E = \{(u,i) : X_{ui} = 1\}$ là tập tương tác, $|E|$ là số tương tác.

Các lũy thừa nghịch đảo của D_U và D_I chỉ xét trên những người dùng và sản phẩm có ít nhất một tương tác.

Định nghĩa 2.2 (Bài toán khuyến nghị top-K) Một mô hình khuyến nghị là một hàm điểm $s : \mathcal{U} \times \mathcal{I} \to \mathbb{R}$. Cho tập ứng viên $\mathcal{C}_u \subseteq \mathcal{I} \setminus H_u$ và số nguyên $1 \le K \le |\mathcal{C}_u|$, danh sách top-$K$ của người dùng u gồm K phần tử của $\mathcal{C}_u$ có điểm lớn nhất, xếp theo điểm giảm dần.

Bài toán có hai đặc điểm mà phương pháp nào cũng phải tính đến. Một ô $X_{ui} = 0$ chưa đủ để nói người dùng không thích sản phẩm, vì có thể họ chưa biết hoặc chưa có dịp tương tác với nó [1]. Còn danh sách top-K chỉ phụ thuộc vào thứ tự của điểm số, nên bên cạnh các mục tiêu khớp giá trị của từng ô, có những phương pháp học thẳng thứ tự giữa sản phẩm đã tương tác và sản phẩm chưa quan sát [2].

Theo cách học tham số, các baseline chia thành hai nhóm. Nhóm giải trực tiếp gồm EASE và GF-CF, có tham số xác định bằng nghiệm đóng hoặc phép lọc đồ thị, không tối ưu bằng gradient. Nhóm cần huấn luyện gồm LightGCN, XSimGCL và DirectAU, học tham số bằng gradient qua nhiều epoch.

2.2 Nhóm giải trực tiếp

EASE và GF-CF đều chấm điểm từ lịch sử thông qua một toán tử sản phẩm–sản phẩm. Vector điểm của người dùng u trên toàn bộ danh mục có dạng

$$s_u = x_u\, B, \tag{2.1}$$

trong đó $B \in \mathbb{R}^{|\mathcal{I}|\times|\mathcal{I}|}$ và B_{ji} là phần sản phẩm j trong lịch sử đóng góp vào điểm của sản phẩm i. Cột i chứa các hệ số dùng để dự đoán sản phẩm i, và những sản phẩm có hệ số khác 0 trong cột đó là láng giềng của i. Khi B đã cố định, một lịch sử mới được chấm điểm ngay bằng (2.1) mà không cần học thêm tham số nào cho người dùng [9, 14].

2.2.1 Lân cận sản phẩm và hồi quy thưa

Lọc cộng tác lân cận theo sản phẩm [28] lấy hệ số từ độ tương tự giữa hai sản phẩm, chẳng hạn cosin giữa hai cột của X, và chỉ giữ một số láng giềng giống nhất cho mỗi sản phẩm, nên B được lưu ở dạng thưa. Cách này có hai điểm yếu. Độ tương tự được tính cho từng cặp riêng lẻ, không xét đến việc các láng giềng cùng tham gia một dự đoán có thể mang thông tin trùng nhau [3]. Độ tương tự cũng kém tin cậy khi hai sản phẩm có ít người dùng chung: hai sản phẩm chỉ do đúng một người dùng tương tác đã có cosin bằng 1.

Để xử lý điểm yếu thứ hai, Koren nhân hệ số tương quan với $C_{ji}/(C_{ji} + \lambda_s)$, với $\lambda_s > 0$ điều khiển mức co, nên cặp càng ít người dùng chung càng bị kéo mạnh về 0 [3]. Ý tưởng ở đây là tách độ lớn của một quan hệ khỏi lượng dữ liệu đứng sau quan hệ đó.

Sparse Linear Methods (SLIM) [4] học hệ số bằng cách khớp $X \approx XB$, với phạt ℓ_1 để B thưa, phạt bình phương để giữ hệ số nhỏ, cùng hai ràng buộc $B \geq 0$ và $\mathrm{diag}(B) = 0$; ràng buộc sau ngăn một sản phẩm tự dự đoán chính nó. Bài toán tách được theo từng cột nhưng phải giải bằng tối ưu lặp, và biến thể fsSLIM chọn trước các láng giềng ứng viên theo độ tương tự để giảm chi phí [4]. SLIM ở đây là tiền đề của hồi quy sản phẩm–sản phẩm chứ không phải một baseline. Trong mục tiêu bình phương của SLIM, ô đã tương tác và ô chưa quan sát có cùng trọng số [4, 9].

2.2.2 Embarrassingly Shallow Autoencoder

Embarrassingly Shallow Autoencoder (EASE) [9] giữ bài toán hồi quy của SLIM nhưng bỏ phạt ℓ_1 và ràng buộc không âm, chỉ giữ phạt bình phương và ràng buộc

đường chéo. Bài toán trở thành một hồi quy ridge [21]:

$$\min_{B} \ \|X - XB\|_F^2 + \lambda \|B\|_F^2 \quad \text{với} \quad \operatorname{diag}(B) = 0, \tag{2.2}$$

trong đó $\|\cdot\|_F$ là chuẩn Frobenius, tức căn bậc hai của tổng bình phương các phần tử, và $\lambda > 0$ là hệ số điều chuẩn. Nhờ bỏ hai thành phần kia, bài toán có nghiệm đóng duy nhất: với $Q = (X^\top X + \lambda I)^{-1}$, ta có $B^\star_{jj} = 0$ và $B^\star_{ji} = -Q_{ji}/Q_{ii}$ khi $j \neq i$ [9]. Một phép nghịch đảo cho nghiệm của mọi cột cùng lúc, thay vì phải tối ưu lặp từng cột như SLIM.

Cái giá là phép nghịch đảo ma trận $|\mathcal{I}| \times |\mathcal{I}|$ tốn $O(|\mathcal{I}|^3)$ phép tính, còn $B^\star$ đầy đủ tốn $O(|\mathcal{I}|^2)$ bộ nhớ; với $|\mathcal{I}| \approx 45.000$, ma trận này ở dạng số thực 32 bit chiếm khoảng 7,5 GiB. Nghiệm của EASE thường không thưa dù X thưa: một cặp sản phẩm chưa có người dùng chung nào vẫn có thể nhận hệ số khác 0 qua các quan hệ gián tiếp trong ma trận nghịch đảo [9]. Biến thể EASE top-128 giữ 128 hệ số lớn nhất của mỗi cột sau khi giải. Phép cắt này giảm số hệ số phải lưu nhưng không ước lượng lại các hệ số còn lại, nên chúng không còn là nghiệm tối ưu cho tập láng giềng đã giữ.

Mục tiêu hồi quy của EASE còn hai đặc điểm đáng chú ý. Mọi ô của X có cùng trọng số trong (2.2), trong khi Hu và cộng sự cho rằng phản hồi đã quan sát đáng tin hơn ô chưa quan sát [1]. Phạt ridge thì dùng chung một mức phạt và kéo mọi hệ số về 0, không có thành phần nào phụ thuộc vào số người dùng chung của từng cặp hay vào độ chênh giữa hệ số của các láng giềng có liên quan với nhau; EASE cũng không có hệ số chặn riêng cho từng sản phẩm.

2.2.3 Graph Filter based Collaborative Filtering

Graph Filter based Collaborative Filtering (GF-CF) [14] xây toán tử sản phẩm–sản phẩm bằng lọc tín hiệu trên đồ thị. Lịch sử x_u được xem như một tín hiệu trên đồ thị sản phẩm; thành phần thay đổi chậm dọc theo các cạnh gọi là tần số thấp, và bộ lọc thông thấp giữ lại thành phần đó [22]. GF-CF dựa trên giả định rằng sở thích thay đổi trơn trên đồ thị sản phẩm.

Với ma trận chuẩn hóa $\tilde{R} = D_U^{-1/2} X D_I^{-1/2}$, phần tử

$$(\tilde{R}^\top \tilde{R})_{ji} = \frac{1}{\sqrt{c_j c_i}} \sum_u \frac{X_{uj} X_{ui}}{n_u}$$

là trọng số cạnh giữa hai sản phẩm: mỗi người dùng chung đóng góp nghịch đảo độ dài lịch sử của mình, và tổng được chuẩn hóa theo độ phổ biến của hai sản phẩm. GF-CF chấm điểm bằng

$$s_u = x_u \, \tilde{R}^\top \tilde{R} + \alpha_{\text{GF}} \, x_u \, D_I^{-1/2} V_r V_r^\top D_I^{1/2}, \tag{2.3}$$

trong đó V_r chứa r vector kỳ dị phải ứng với các giá trị kỳ dị lớn nhất của $\tilde{R}$, và $\alpha_{\text{GF}} \geq 0$ cân bằng hai số hạng. Đối với Laplacian $I - \tilde{R}^\top \tilde{R}$, các vector này ứng với những tần số thấp nhất. Số hạng đầu là một bộ lọc thông thấp tuyến tính, còn số hạng sau giữ lại không gian phổ hạng r sau một phép đổi tọa độ theo D_I, tức một bộ lọc thông thấp lý tưởng [14]. Như vậy GF-CF cũng có dạng (2.1), với B là ma trận của bộ lọc.

Đồ thị và V_r được tính từ dữ liệu, nhưng dạng đáp ứng của bộ lọc thì định sẵn và chỉ điều chỉnh qua hai siêu tham số chung r và α_{GF} [14]. GF-CF vì thế phụ thuộc vào dữ liệu nhưng không ước lượng một bộ hệ số riêng cho từng sản phẩm. Phần tuyến tính tính được bằng các phép nhân với ma trận thưa $\tilde{R}$, còn phần phổ cần tìm và lưu V_r, tốn $O(|\mathcal{I}|\, r)$ bộ nhớ. Công thức (2.3) cũng không gán trọng số cho từng ô như một mục tiêu hồi quy.

Hướng lọc đồ thị đã được mở rộng theo nhiều cách. Blurring-Sharpening Process Models (BSPM) [18] kết hợp một quá trình làm mờ với một quá trình làm sắc nét tín hiệu. Turbo-CF [19] dùng bộ lọc đa thức để khỏi phải phân rã ma trận. PolyCF [27] thì học các tham số của bộ lọc bằng tối ưu, nên dù dùng bộ lọc đồ thị, nó thuộc loại cần huấn luyện.

2.2.4 Tổng hợp và câu hỏi thiết kế

Bảng 2.1 cho thấy hai cách tiếp cận khác nhau: EASE hồi quy trên toàn danh mục, còn GF-CF lọc tín hiệu trên đồ thị mà không ước lượng hệ số riêng cho từng sản phẩm. Những gì cần để xây một hồi quy trên tập láng giềng nhỏ đều đã có riêng lẻ trong tài liệu: chọn láng giềng trước khi giải [4, 28], gán trọng số theo độ tin cậy [1], co quan hệ theo lượng dữ liệu đứng sau nó [3], phạt sự chênh lệch giữa các đỉnh liên kết chặt trên đồ thị [22], và giải bằng nghiệm đóng như EASE [9]. Trong các tài liệu nhóm đã đọc, chưa thấy phương pháp nào kết hợp tất cả những thành phần này trong một bài toán hồi quy nhỏ, giải chính xác cho từng sản phẩm.

Câu hỏi thiết kế vì thế là: một kết hợp như vậy có đạt chất lượng ngang EASE đầy đủ trong khi chỉ lưu một phần nhỏ số hệ số hay không. Graph-Regularized Neighborhood Regression (GRNR) được đề xuất cho câu hỏi này và được so với ba baseline: EASE đầy đủ là mốc của hồi quy toàn danh mục, EASE top-128 có cùng giới hạn 128 hệ số cho mỗi sản phẩm, còn GF-CF đại diện cho hướng lọc đồ thị.

2.3 Nhóm cần huấn luyện

Ba baseline của nhóm này học các vector biểu diễn trong $\mathbb{R}^f$, gọi là embedding, với f là số chiều, và cập nhật tham số bằng gradient qua nhiều epoch. Mỗi bước cập nhật dùng một lô $\mathcal{Q} \subseteq E$, tức một tập tương tác; $\mathcal{U}_\mathcal{Q}$ và $\mathcal{I}_\mathcal{Q}$ là tập người dùng và tập sản

Baseline	Cách xác định hệ số	Xử lý ô bằng 0	Điều chuẩn hoặc bộ lọc
EASE đầy đủ	Hồi quy trên mọi sản phẩm khác; có cả quan hệ gián tiếp	Cùng trọng số với ô có tương tác	Ridge, cùng mức phạt, kéo về 0
EASE top-128	128 hệ số lớn nhất, cắt sau khi giải, không ước lượng lại	Như EASE đầy đủ	Như EASE đầy đủ, áp dụng trước khi cắt
GF-CF	Toán tử tính từ dữ liệu, dạng đáp ứng định sẵn	Không có trọng số cho từng ô	Bộ lọc tuyến tính và bộ lọc lý tưởng; r, α_{GF} dùng chung

Bảng 2.1: Các baseline của nhóm giải trực tiếp

phẩm có mặt trong lô, mỗi phần tử tính một lần. Sản phẩm chưa tương tác được lấy ra để so với sản phẩm đã tương tác gọi là mẫu âm. Ba baseline là LightGCN, XSimGCL và DirectAU với bộ mã hóa LightGCN.

2.3.1 Phân rã ma trận và các hướng mở rộng

Trong phân rã ma trận, mỗi người dùng u và mỗi sản phẩm i có một vector nhân tố p_u, $q_i \in \mathbb{R}^f$, và thành phần tương tác của điểm là $s(u,i) = p_u^\top q_i$ [29]. Người dùng ít tương tác có ít bằng chứng để ước lượng p_u. Khi các vector đã cố định, người dùng có thêm tương tác thì điểm số cũng không tự thay đổi, còn người dùng mới thì chưa có vector nào trong bảng tham số; cả hai trường hợp đều cần một cơ chế cập nhật riêng.

Một hướng mở rộng là suy ra biểu diễn người dùng từ lịch sử. SVD++ của Koren cộng vào vector người dùng một tổng chuẩn hóa các vector của sản phẩm đã tương tác [3]. Factored Item Similarity Models (FISM) [5] đi xa hơn: không có vector người dùng, mà dùng hai bảng nhân tố sản phẩm cho hai vai trò, sản phẩm nguồn trong lịch sử và sản phẩm đích cần dự đoán. Điểm là tích vô hướng giữa tổng chuẩn hóa các vector nguồn với vector đích, nên khi lịch sử thay đổi, chỉ cần tính lại tổng đó với các bảng sản phẩm giữ nguyên. FISM học được quan hệ gián tiếp qua các nhân tố dùng chung, nhưng không có bước lan truyền tường minh trên đồ thị như LightGCN [5].

Một hướng khác thay đổi mục tiêu học. Variational Autoencoders for Collaborative Filtering [8] giới thiệu Mult-VAE, mô hình dùng bộ mã hóa để suy ra phân phối biến ẩn từ lịch sử và học bằng mục tiêu biến phân; tên gọi lấy từ hàm hợp lý đa thức (multinomial) của bộ giải mã. Bộ giải mã cho ra một phân phối đa thức trên toàn danh mục qua softmax, tức mọi sản phẩm cùng chia nhau một tổng xác suất bằng 1, khác hẳn cách so từng cặp của BPR. Wu và cộng sự nghiên cứu softmax lấy mẫu, trong đó

tập sản phẩm để so được lấy mẫu, và phân tích mối liên hệ của nó với thước đo xếp hạng cùng khả năng nhấn mạnh các mẫu âm khó [20].

2.3.2 Light Graph Convolution Network

Light Graph Convolution Network (LightGCN) [11] giữ cách biểu diễn của phân rã ma trận nhưng làm trơn các embedding trên đồ thị hai phía người dùng–sản phẩm trước khi chấm điểm. Mô hình học embedding ban đầu $e_u^{(0)}, e_i^{(0)}$ cho mọi người dùng và sản phẩm, rồi lan truyền chúng qua ν lớp bằng phép trung bình có chuẩn hóa; khác với mạng tích chập đồ thị thông thường, nó bỏ biến đổi phi tuyến và ma trận trọng số ở mỗi lớp. Với $t = 0, \ldots, \nu - 1$,

$$e_u^{(t+1)} = \sum_{i \in H_u} \frac{1}{\sqrt{n_u}\sqrt{c_i}}\, e_i^{(t)}, \qquad e_i^{(t+1)} = \sum_{u:\, i \in H_u} \frac{1}{\sqrt{c_i}\sqrt{n_u}}\, e_u^{(t)}. \tag{2.4}$$

Biểu diễn cuối là trung bình đều của mọi lớp, kể cả lớp ban đầu: $e_u = \frac{1}{\nu+1}\sum_{t=0}^{\nu} e_u^{(t)}$, tương tự cho e_i, và điểm là $s(u,i) = e_u^\top e_i$ [11]. Nhờ vậy embedding mang thông tin từ nhiều bước trên đồ thị, thay vì chỉ là các vector nhân tố trực tiếp như trong phân rã ma trận.

LightGCN được huấn luyện bằng Bayesian Personalized Ranking (BPR) [2], hàm mất mát giả định người dùng thích một sản phẩm đã tương tác i hơn một sản phẩm chưa tương tác j:

$$\mathcal{L}_{\text{BPR}} = -\sum_{(u,i,j)\in\mathcal{D}} \ln \sigma\big(s(u,i) - s(u,j)\big) + \lambda_\Theta \|\Theta\|^2, \tag{2.5}$$

trong đó $\mathcal{D}$ gồm các bộ ba với $(u,i) \in E$ và mẫu âm $j \notin H_u$ lấy ngẫu nhiên, $\sigma(z) = 1/(1+e^{-z})$ là hàm sigmoid, Θ là toàn bộ embedding ban đầu, và $\lambda_\Theta > 0$ là hệ số điều chuẩn. Mỗi lớp lan truyền tốn $O(|E|\, f)$, nên một lượt lan truyền tốn $O(\nu\,|E|\, f)$.

Mỗi người dùng trong LightGCN vẫn có một vector ban đầu riêng [11]. Khi đồ thị thay đổi, có thể lan truyền lại để biểu diễn thay đổi theo mà vẫn giữ nguyên tham số ban đầu, nhưng việc này khác với huấn luyện lại và không tạo được vector cho một người dùng chưa có trong bảng tham số. Về phía hàm mất mát, đạo hàm của số hạng $-\ln\sigma(\Delta)$ theo $\Delta = s(u,i) - s(u,j)$ là $-(1-\sigma(\Delta))$, gần bằng 0 khi mẫu âm đã dễ phân biệt; khi đó bộ ba gần như không đóng góp gì vào cập nhật, nên hiệu quả học phụ thuộc nhiều vào cách lấy mẫu âm [2, 20].

2.3.3 eXtremely Simple Graph Contrastive Learning

eXtremely Simple Graph Contrastive Learning (XSimGCL) [17] kết hợp lan truyền đồ thị, hàm BPR và học tương phản. Khi huấn luyện, sau mỗi lớp lan truyền, mô hình

cộng vào embedding một nhiễu có chuẩn ϵ, cùng dấu với embedding ở từng tọa độ. Biểu diễn dùng để chấm điểm là trung bình các lớp $1, \dots, \nu$, không tính lớp ban đầu: $\bar{e}'_v = \frac{1}{\nu}\sum_{t=1}^{\nu} e'^{(t)}_v$. Một lần lan truyền cho ra cả $\bar{e}'_v$ lẫn biểu diễn ở một lớp được chọn l^*; chuẩn hóa hai vector này về độ dài 1 được z'_v và z''_v, tạo thành một cặp dương của cùng nút v.

Hàm InfoNCE [23] so cặp dương với các nút cùng loại trong lô. Viết ở dạng trung bình như trong cài đặt của tác giả,

$$\ell(\mathcal{S}) = -\frac{1}{|\mathcal{S}|}\sum_{v\in\mathcal{S}} \log \frac{\exp\left(z'^{\top}_v z''_v/\tau\right)}{\sum_{w\in\mathcal{S}} \exp\left(z'^{\top}_v z''_w/\tau\right)}, \qquad \ell_{\text{NCE}} = \ell(\mathcal{U}_{\mathcal{Q}}) + \ell(\mathcal{I}_{\mathcal{Q}}), \tag{2.6}$$

trong đó $\mathcal{S}$ lần lượt là tập người dùng và tập sản phẩm của lô, $\tau > 0$ là tham số nhiệt độ, và mẫu số tính cả cặp dương $w = v$. Mục tiêu học là BPR có điều chuẩn cộng thêm $\lambda_{\text{cl}}\ell_{\text{NCE}}$ [17].

XSimGCL dùng chung một lần lan truyền cho cả xếp hạng lẫn tương phản, và nhiễu chỉ có khi huấn luyện. Riêng phần tương phản tốn thêm $O((|\mathcal{U}_{\mathcal{Q}}|^2 + |\mathcal{I}_{\mathcal{Q}}|^2)f)$ cho mỗi lô [17], đổi lại có thêm bốn lựa chọn phải chỉnh: độ lớn nhiễu ϵ, nhiệt độ τ, trọng số λ_{cl} và lớp l^*. InfoNCE ở đây so các nút cùng loại với nhau; việc xếp hạng sản phẩm cho người dùng vẫn do BPR đảm nhận, và mỗi người dùng vẫn có vector riêng như trong LightGCN.

2.3.4 DirectAU

DirectAU [15] là một mục tiêu học tối ưu trực tiếp hai tính chất của biểu diễn: tính căn chỉnh (alignment), kéo người dùng và sản phẩm có tương tác lại gần nhau, và tính đồng đều (uniformity), giữ cho các biểu diễn trải rộng trên mặt cầu đơn vị. Với embedding khác 0 được chuẩn hóa thành $\tilde{e}_v = e_v/\|e_v\|$, hai đại lượng có dạng

$$\ell_{\text{align}} = \mathbb{E}_{(u,i)\in E}\left\|\tilde{e}_u - \tilde{e}_i\right\|^2, \qquad \ell_{\text{uniform}} = \log \mathbb{E}_{v,v'}\, e^{-2\|\tilde{e}_v - \tilde{e}_{v'}\|^2}, \tag{2.7}$$

trong đó $\mathbb{E}$ là kỳ vọng, ước lượng trên lô tương tác. Tính căn chỉnh lấy trên các cặp người dùng–sản phẩm có tương tác, còn tính đồng đều lấy riêng trên các cặp người dùng và các cặp sản phẩm theo tần suất xuất hiện trong dữ liệu [15]. Mục tiêu là $\ell_{\text{align}} + \frac{\gamma_{\text{AU}}}{2}\left(\ell^{\mathcal{U}}_{\text{uniform}} + \ell^{\mathcal{I}}_{\text{uniform}}\right)$, với $\gamma_{\text{AU}} > 0$ cân bằng hai thành phần.

DirectAU chỉ dùng các cặp dương trong lô, không cần lấy thêm mẫu âm, vì tính đồng đều tự đẩy các biểu diễn ra xa nhau; thành phần này tốn $O(|\mathcal{Q}|^2 f)$ cho mỗi lô. Bài gốc dùng bảng embedding theo mã người dùng và mã sản phẩm làm bộ mã hóa mặc định, và có khảo sát thêm bộ mã hóa đồ thị [15]. Baseline DirectAU trong báo

cáo dùng bộ mã hóa LightGCN, nên giữ nguyên cách lan truyền và vector người dùng của LightGCN, chỉ thay BPR bằng căn chỉnh và đồng đều.

2.3.5 Tổng hợp và câu hỏi thiết kế

Bảng 2.2 cho thấy cả ba baseline đều học một vector ban đầu riêng cho mỗi người dùng và đều khai thác đồ thị; chúng chỉ khác nhau ở cách tổng hợp các lớp, ở nhiễu và ở mục tiêu học. Không baseline nào so sản phẩm đúng với toàn bộ danh mục. Những hướng đi khác nằm rải rác trong tài liệu: FISM biểu diễn người dùng bằng lịch sử nhưng không lan truyền trên đồ thị [5], Mult-VAE dùng softmax trên toàn danh mục nhưng không dùng đồ thị [8], còn Wu và cộng sự ghép softmax lấy mẫu với mô hình đồ thị nhưng các mô hình đó vẫn có vector người dùng [20]. Trong các tài liệu nhóm đã đọc, chưa thấy mô hình nào đồng thời biểu diễn người dùng bằng lịch sử, làm trơn embedding sản phẩm trên đồ thị và huấn luyện bằng softmax trên toàn danh mục.

Baseline	Tham số người dùng	Lan truyền và tổng hợp	Hàm mất mát
LightGCN	Vector ban đầu riêng	Trung bình các lớp $0, \ldots, \nu$	BPR có điều chuẩn
XSimGCL	Vector ban đầu riêng	Trung bình các lớp $1, \ldots, \nu$; thêm nhiễu khi học	BPR có điều chuẩn, cộng InfoNCE theo từng loại nút
DirectAU	Vector ban đầu riêng	Bộ mã hóa LightGCN	Căn chỉnh và đồng đều, không lấy mẫu âm

Bảng 2.2: Các baseline của nhóm cần huấn luyện

Câu hỏi thiết kế là một mô hình như vậy có cạnh tranh được với LightGCN, XSimGCL và DirectAU hay không. Diffusion-Filtered History Factorization (DFHF) được đề xuất cho câu hỏi này và chỉ được so với ba baseline trên. Vì ba baseline dùng ba mục tiêu học khác nhau trên cùng một cách biểu diễn, nếu DFHF có ưu thế thì ưu thế đó không gắn với một mục tiêu học cụ thể của đối thủ.

3 Phương pháp và thuật toán đề xuất

Graph-Regularized Neighborhood Regression (GRNR) và Diffusion-Filtered History Factorization (DFHF) đều tính điểm từ lịch sử thay vì học một vector tham số riêng cho từng người dùng. Khi hệ số hồi quy hoặc các bảng embedding sản phẩm đã cố định, nhóm có thể chấm một lịch sử mới mà không phải học thêm tham số người dùng. Các ký hiệu chung tuân theo Mục 2.1.

3.1 Công cụ toán học

3.1.1 Hồi quy có trọng số và điều chuẩn

Định nghĩa 3.1 (Hồi quy có trọng số và có điều chuẩn) Cho ma trận đặc trưng $\Phi \in \mathbb{R}^{N\times m}$ gồm N mẫu và m đặc trưng, vector mục tiêu $y \in \mathbb{R}^N$, ma trận trọng số mẫu $\Omega = \operatorname{diag}(w_1, \ldots, w_N)$ với $w_n \geq 0$, ma trận phạt đối xứng nửa xác định dương $P \in \mathbb{R}^{m\times m}$ và điểm neo $\theta^0 \in \mathbb{R}^m$. Bài toán hồi quy có trọng số và có điều chuẩn là

$$\min_{\theta\in\mathbb{R}^m} \; J(\theta) = \frac{1}{2}(y - \Phi\theta)^\top \Omega(y - \Phi\theta) + \frac{1}{2}(\theta - \theta^0)^\top P(\theta - \theta^0). \tag{3.1}$$

Trọng số Ω phân biệt mức tin cậy của các quan sát, theo hướng xử lý phản hồi ngầm của Hu, Koren và Volinsky [1]. Ma trận P điều khiển mức phạt theo hướng tham số, còn θ^0 là điểm neo [24, Mục 6.3].

Đặt $G = \Phi^\top\Omega\Phi + P$. Khi G xác định dương, chẳng hạn khi P xác định dương, bài toán (3.1) có nghiệm duy nhất, là nghiệm của phương trình chuẩn [24, Mục 4.4]

$$G\theta^\star = \Phi^\top\Omega y + P\theta^0. \tag{3.2}$$

Hệ được giải qua Cholesky $G = RR^\top$, với R tam giác dưới, rồi hai lần thế tam giác. Phân rã tốn khoảng $m^3/3$ phép tính, nên giới hạn số đặc trưng trực tiếp giảm chi phí giải [24, Phụ lục C.2–C.3].

3.1.2 Đồng xuất hiện

Định nghĩa 3.2 (Đồng xuất hiện ngoài đường chéo) Với ma trận đồng xuất hiện C ở Mục 2.1, nhóm ký hiệu C° là ma trận nhận được khi đặt đường chéo của C bằng 0. Các phần tử ngoài đường chéo vẫn giữ số người dùng chung của từng cặp sản phẩm.

Với $c_i, c_j > 0$, tỷ số lift so đồng xuất hiện với mức kỳ vọng dưới giả định độc lập:

$$\operatorname{lift}(i, j) = \frac{C_{ij}}{c_i c_j/|\mathcal{U}|}, \tag{3.3}$$

nên $\operatorname{lift}(i, j) > 1$ biểu thị đồng xuất hiện vượt kỳ vọng. Đây là chỉ số mô tả, không phải kiểm định thống kê; GRNR dùng một điểm dư khác ở Mục 3.2.1.

3.1.3 Laplacian của đồ thị

Định nghĩa 3.3 (Laplacian chuẩn hóa) Cho đồ thị vô hướng với tập đỉnh $\mathcal{V}$, ma trận kề đối xứng không âm A và bậc $\delta_v = \sum_w A_{vw}$. Gọi $D_A = \mathrm{diag}(\delta_v)$. Khi mọi đỉnh có bậc dương, ma trận kề chuẩn hóa và Laplacian chuẩn hóa là

$$\tilde{A} = D_A^{-1/2} A D_A^{-1/2}, \qquad L = I - \tilde{A}. \tag{3.4}$$

Khi có đỉnh cô lập, quy ước $(D_A^{-1/2})_{vv} = 0$ và thay I bằng ma trận đường chéo có giá trị 1 ở các đỉnh có bậc dương. Một tín hiệu trên đồ thị là một vector $\mathbf{g} \in \mathbb{R}^{|\mathcal{V}|}$.

Đặt $z_v = g_v/\sqrt{\delta_v}$ khi $\delta_v > 0$ và $z_v = 0$ ở đỉnh cô lập. Khi đó,

$$\mathbf{g}^\top L\, \mathbf{g} = \frac{1}{2} \sum_{v,w} A_{vw}(z_v - z_w)^2, \tag{3.5}$$

và mọi giá trị riêng của L thuộc $[0, 2]$ [25, Mục 1.2–1.4]. Năng lượng nhỏ khi các giá trị đã chia căn bậc gần nhau trên cạnh có trọng số lớn. Phạt ridge xác định dương là điều kiện đủ cho nghiệm duy nhất; điều kiện quyết định vẫn là $\Phi^\top \Omega \Phi + P \succ 0$.

3.1.4 Ma trận chuyển hai bước

Đặt $\mathcal{U}_+ = \{u : n_u > 0\}$ và $\mathcal{I}_+ = \{i : c_i > 0\}$ là tập người dùng và sản phẩm có tương tác. Trên đồ thị này, một bước chuyển sản phẩm $\to$ người dùng $\to$ sản phẩm, với mỗi chặng chọn đều một láng giềng, có ma trận chuyển

$$T = D_I^{-1} X^\top D_U^{-1} X, \tag{3.6}$$

với T_{ij} là xác suất đi từ sản phẩm i tới sản phẩm j. Nhân T với một tín hiệu trên sản phẩm là lấy trung bình tín hiệu trên các sản phẩm mà cùng nhóm người dùng đã tương tác.

Nhận xét 3.1 Mỗi hàng của T không âm và có tổng bằng 1, vì $\sum_j T_{ij} = \frac{1}{c_i} \sum_u X_{ui} \frac{1}{n_u} \sum_j X_{uj} = 1$. Ngoài ra $D_I^{1/2} T D_I^{-1/2} = \tilde{R}^\top \tilde{R}$ với $\tilde{R}$ như ở Mục 2.2.3, nên T đồng dạng với một ma trận đối xứng nửa xác định dương; kết hợp với tính ngẫu nhiên theo hàng, mọi giá trị riêng của T là số thực thuộc $[0, 1]$ [25, Mục 1.5]. Hệ quả là một đa thức $F = \sum_t a_t T^t$ với $a_t \geq 0$ và $\sum_t a_t = 1$ cũng có các hàng không âm, tổng bằng 1, tức là một phép lấy trung bình có trọng số, và có giá trị riêng thuộc $[a_0, 1]$.

T đồng dạng với toán tử Gram chuẩn hóa của Graph Filter based Collaborative Filtering (GF-CF) (Mục 2.2.3), nhưng biểu diễn phép chuyển ngẫu nhiên. Nhóm tính bộ lọc đa thức bằng nhân ma trận để tránh phân rã phổ, theo nguyên tắc của Turbo-CF [19]. Với sản phẩm cô lập, DFHF mở rộng T bằng phép đồng nhất để giữ nguyên vector của sản phẩm đó.

3.1.5 Hàm mất mát softmax trên toàn danh mục

Hàm mất mát softmax so sản phẩm dương với một tập $\mathcal{A}_{ui}$ chứa i. Với truy vấn (u, i), đặt $p^{\text{sm}}_{ui'} = \exp s(u, i') \big/ \sum_{i'' \in \mathcal{A}_{ui}} \exp s(u, i'')$ cho $i' \in \mathcal{A}_{ui}$. Khi đó,

$$\ell(u, i) = -\log p^{\text{sm}}_{ui}, \qquad \frac{\partial \ell(u, i)}{\partial s(u, i')} = p^{\text{sm}}_{ui'} - \mathbb{1}[i' = i], \tag{3.7}$$

với $i' \in \mathcal{A}_{ui}$ và $\mathbb{1}[\cdot]$ là hàm chỉ báo. Công thức theo đạo hàm log-sum-exp [24, Mục 3.1.5]; các sản phẩm khác đích có xác suất lớn nhận đạo hàm lớn hơn.

3.2 Graph-Regularized Neighborhood Regression

Để xử lý câu hỏi thiết kế ở Mục 2.2.4, nhóm chọn một tập láng giềng nhỏ cho mỗi sản phẩm rồi ước lượng đồng thời các hệ số bằng hồi quy có trọng số. GRNR kế thừa hồi quy sản phẩm–sản phẩm từ Sparse Linear Methods (SLIM) [4] và Embarrassingly Shallow Autoencoder (EASE) [9], cùng cách phân biệt độ tin cậy của phản hồi ngầm từ Hu và cộng sự [1]. Nhóm kết hợp phạt theo lượng dữ liệu của nguồn, phạt đồ thị có điều chỉnh biên và điểm neo cho hệ số chặn để điều chuẩn từng bài toán hồi quy.

Giới hạn $k = 128$ nguồn khống chế kích thước hệ và số hệ số cần lưu, nhưng loại các nguồn ngoài tập đã chọn khỏi hồi quy. Khác với hồi quy toàn danh mục của EASE [9], các hệ số còn lại được ước lượng trực tiếp trên tập nguồn này. Hai giai đoạn khớp mô hình và chấm điểm được thể hiện ở hình 3.1: hàng trên chạy một lần khi khớp mô hình, còn hàng dưới chạy cho mỗi người dùng, kể cả người dùng có lịch sử mới.

Nhóm dựng đồ thị trên toàn bộ sản phẩm, rồi lấy khối tương ứng với tập nguồn cho từng hồi quy. Sau khi giải, hệ số và hệ số chặn được giữ cố định; lịch sử mới được dùng để tính điểm trước khi điều chỉnh theo độ phổ biến và chọn top-K.

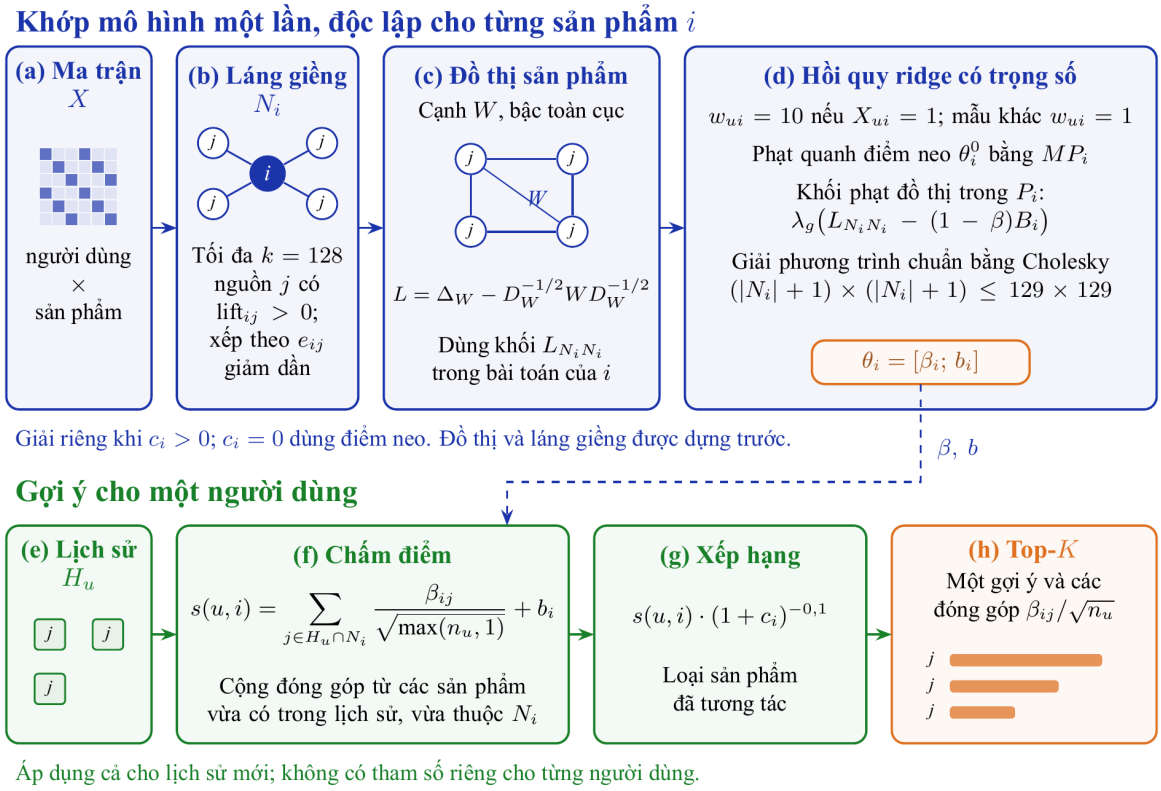
3.2.1 Lựa chọn láng giềng và đồ thị sản phẩm

Dùng ma trận đồng xuất hiện đã xóa đường chéo C° theo Định nghĩa 3.2. Với sản phẩm đích i, đặt xác suất nền đã làm trơn

$$p_i = \frac{c_i + 1}{|\mathcal{U}| + 2}. \tag{3.8}$$

Với mỗi sản phẩm nguồn $j \neq i$, mức đồng xuất hiện vượt kỳ vọng và điểm dư đã làm trơn được tính bởi

$$e_{ij} = C^{\circ}_{ji} - c_j\, p_i, \qquad \text{lift}_{ij} = \frac{e_{ij}}{c_j + \kappa_{\text{lift}}}, \quad \kappa_{\text{lift}} = 10. \tag{3.9}$$



Hình 3.1: Sơ đồ hoạt động của GRNR

lift_{ij} là điểm dư có làm trơn, khác với tỉ số lift ở Mục 3.1.2. Nhóm chọn tối đa $k = 128$ nguồn có điểm dương, xếp theo e_{ij} giảm dần và theo chỉ số sản phẩm nếu bằng điểm. Trừ $c_j p_i$ loại mức đồng xuất hiện kỳ vọng từ nền phổ biến, còn xếp theo e_{ij} ưu tiên lượng vượt kỳ vọng tuyệt đối. Cosin và tỉ số lift chuẩn hóa đồng xuất hiện theo cách khác nên có thể chọn các nguồn khác. Vì $c_j + \kappa_{\text{lift}} > 0$, tham số κ_{lift} chỉ điều chỉnh trọng số đồ thị, không đổi dấu hay thứ tự chọn theo e_{ij}.

Từ các trọng số lift dương, xây dựng đồ thị sản phẩm có hướng $W_{ij}^{\text{dir}} = \text{lift}_{ij}$ với $j \in N_i$, đối xứng hóa bằng $W = \max(W^{\text{dir}}, W^{\text{dir}\top})$ và lấy Laplacian chuẩn hóa

$$L = \Delta_W - D_W^{-1/2} W D_W^{-1/2}, \tag{3.10}$$

trong đó W là trường hợp cụ thể của ma trận kề A ở Định nghĩa 3.3, D_W là ma trận bậc, Δ_W có đường chéo bằng 1 ở đỉnh có bậc dương và bằng 0 ở đỉnh cô lập. Quy ước nghịch đảo căn bậc tại đỉnh cô lập bằng 0. Phép lấy max giữ cạnh nếu ít nhất một hướng đã chọn, với trọng số lớn hơn của hai hướng; lấy trung bình là một lựa chọn khác và cho mức phạt khác.

Với Laplacian chuẩn hóa, nhóm phạt chênh lệch giữa các hệ số đã chia căn bậc trên những cạnh mạnh. Đại lượng này khác với hệ số thô trong Laplacian không chuẩn

hóa và với phạt ridge vốn co từng hệ số về điểm neo [25, Mục 1.2, 1.4]; lựa chọn chuẩn hóa xác định đại lượng được làm trơn.

3.2.2 Hàm mục tiêu và phương pháp giải

Với sản phẩm i, mỗi người dùng u được mô tả bởi vector đặc trưng gồm các láng giềng có trong lịch sử, chuẩn hóa theo độ dài lịch sử, và một hệ số chặn:

$$\phi_u^{(i)} = \left[\frac{X_{u,N_i}}{\sqrt{\max(n_u - X_{ui},\, 1)}} \;;\; 1 \right] \in \mathbb{R}^{|N_i|+1}. \tag{3.11}$$

Mẫu số dùng $n_u - X_{ui}$ để loại đích khỏi độ dài lịch sử khi tạo mẫu dương, phù hợp với dự đoán sản phẩm chưa thấy. Chuẩn hóa căn bậc làm giảm đóng góp của lịch sử dài so với tổng thô, nhưng giữ mức lớn hơn phép lấy trung bình (Mục 3.3.1). Với $c_i > 0$, nhóm ước lượng tham số $\theta_i = [\beta_i; b_i]$ bằng bình phương tối thiểu có trọng số:

$$\min_{\theta_i} \; \frac{1}{2} \sum_{u \in \mathcal{U}} w_{ui} \big(X_{ui} - \phi_u^{(i)\top} \theta_i \big)^2 \; + \; \frac{1}{2} (\theta_i - \theta_i^0)^\top M P_i \, (\theta_i - \theta_i^0), \tag{3.12}$$

với $w_{ui} = \omega_+ = 10$ nếu $X_{ui} = 1$, còn lại $w_{ui} = 1$, và $M = |\mathcal{U}|$. Nhóm gán trọng số 10 cho mẫu dương để tăng độ tin cậy so với ô chưa quan sát, theo hướng của Hu và cộng sự [1]. Nhân phạt với M tương đương chia phần sai số dữ liệu cho số người dùng rồi giữ ma trận phạt P_i.

Với láng giềng cố định, sai số bình phương và phạt bậc hai cho Hessian không phụ thuộc θ_i, nên có thể giải một hệ tuyến tính. Hồi quy logistic phù hợp với nhãn nhị phân nhưng thường cần tối ưu lặp; thêm phạt L_1 có thể tạo thưa trong tập nguồn song không còn dạng giải một hệ Cholesky [24, Mục 6.1, 6.3]. Nhóm chọn cấu trúc bậc hai để giải trực tiếp; điểm dự đoán là điểm xếp hạng, không bị ràng buộc trong $[0, 1]$. Ma trận phạt là

$$P_i = \begin{bmatrix} \eta \, \mathrm{diag}(s_j)_{j \in N_i} + \lambda_g \big(L_{N_i N_i} - (1 - \beta) B_i \big) & 0 \\ 0 & \eta_b \end{bmatrix}, \tag{3.13}$$

trong đó $\eta = 10^{-5}$, $\eta_b = 10^{-3}$, $\lambda_g = 10^{-3}$ và $\beta = 0{,}5$. Ở khối phạt, β là hệ số biên vô hướng, khác vector hồi quy β_i. Đặt $s_j = \min\big((c_j/(c_j + \alpha_s))^{-2}, s_{\max} \big)$ với $\alpha_s = 2$, $s_{\max} = 10$. Khi c_j tăng, mức phạt giảm về 1, thể hiện lựa chọn co mạnh hơn các nguồn ít dữ liệu; số mũ 2 quy định tốc độ giảm. Với số đếm $c_j \geq 1$, $s_j \leq 9$, nên ngưỡng 10 không tác động trong cấu hình này.

$L_{N_i N_i}$ là khối con của Laplacian toàn cục; $B_i \in \mathbb{R}^{|N_i| \times |N_i|}$ là ma trận đường chéo chứa năng lượng biên do liên kết ra ngoài N_i, với mọi phần tử ngoài đường chéo bằng

0. Hệ số β nội suy giữa bỏ phần biên ($\beta = 0$) và giữ đủ ($\beta = 1$); $\beta = 0{,}5$ giữ một nửa, chưa được chứng minh là lựa chọn tối ưu. Điểm neo θ_i^0 có hệ số láng giềng bằng 0 và chặn theo xác suất nền đã làm trơn:

$$b_i^0 = \frac{\omega_+ \, p_i}{1 + (\omega_+ - 1)\, p_i}, \quad \omega_+ = 10. \tag{3.14}$$

Khi chỉ khớp một hằng số với dữ liệu gốc và trọng số ω_+, nghiệm của phần sai số dữ liệu là $\omega_+ c_i/(M + (\omega_+ - 1)c_i)$. Nhóm thay c_i/M bằng p_i đã làm trơn để tạo điểm neo; với $0 < p_i < 1$, điểm này thỏa $b_i^0/(1 - b_i^0) = \omega_+ p_i/(1 - p_i)$. Hệ số chặn vì thế được neo theo xác suất nền đã điều chỉnh trọng số, thay vì neo về 0.

Tính xác định dương của P_i cần được kiểm tra để áp dụng kết quả về nghiệm duy nhất ở Mục 3.1.1. Gọi $\delta_j = \sum_k W_{jk}$ là bậc toàn cục. Với $j \in N_i$, phần tử đường chéo của B_i là $\sum_{k \notin N_i} W_{jk}/\delta_j$ nếu $\delta_j > 0$, và bằng 0 nếu $\delta_j = 0$. Với vector hệ số z trên N_i, đặt $a_j = z_j/\sqrt{\delta_j}$ khi bậc dương, bằng 0 trong trường hợp còn lại. Từ công thức năng lượng (3.5),

$$\begin{aligned} z^\top \big(L_{N_i N_i} - (1-\beta) B_i\big) z = \frac{1}{2} \sum_{j,k \in N_i} W_{jk} (a_j - a_k)^2 \\ + \beta \sum_{j \in N_i} (B_i)_{jj} z_j^2 \geq 0. \end{aligned} \tag{3.15}$$

Bất đẳng thức đúng với $\beta \in [0, 1]$. Vì $\eta > 0$, $s_j > 0$, $\eta_b > 0$ và $\lambda_g \geq 0$, hai khối của P_i đều xác định dương; nếu không có láng giềng, chỉ còn khối chặn η_b. Như vậy $P_i \succ 0$. Áp dụng kết quả ở Mục 3.1.1 với ma trận phạt MP_i và điểm neo θ_i^0, bài toán có nghiệm duy nhất thỏa

$$\left(\Phi_i^\top \Omega_i \Phi_i + MP_i\right) \theta_i = \Phi_i^\top \Omega_i \, x_i + MP_i \, \theta_i^0, \tag{3.16}$$

với Φ_i là ma trận xếp các hàng $\phi_u^{(i)}$, $\Omega_i = \mathrm{diag}(w_{ui})$ và x_i là cột i của X. Hệ (3.16) có kích thước tối đa 129×129 và được giải bằng Cholesky ở độ chính xác số thực 64 bit. Cài đặt kiểm tra sai số dư tương đối $\|G_i\theta_i - r_i\| / \max(\|r_i\|, 10^{-15}) < 10^{-8}$ cho từng sản phẩm có tương tác, với G_i, r_i là ma trận và vế phải của hệ.

Với $c_i = 0$, GRNR dùng quy tắc dự phòng $\theta_i \leftarrow \theta_i^0$. Đây là ngoại lệ ngoài bước tối ưu hồi quy ở trên; các sản phẩm này không thuộc tập ứng viên $\mathcal{I}_+$.

3.2.3 Thuật toán huấn luyện và suy luận

Nhóm tính ma trận Gram $\Phi_i^\top \Omega_i \Phi_i$ từ một ma trận dùng chung rồi hiệu chỉnh các mẫu dương. Phần lớn người dùng có $X_{ui} = 0$ và trọng số 1, nên dùng được Gram toàn cục $G = \tilde{X}^\top \tilde{X}$ của lịch sử chuẩn hóa $\tilde{X}_{uj} = X_{uj}/\sqrt{\max(n_u, 1)}$. Với người dùng có

$X_{ui} = 1$, nhóm thay đúng hàng đặc trưng đã loại i khỏi mẫu số và gán trọng số 10, như trong Thuật toán 1.

Thuật toán 1: Huấn luyện và chấm điểm GRNR

Đầu vào: Ma trận tương tác giữ lại X; siêu tham số ở bảng 4.5
Đầu ra: Ma trận hệ số thưa $\mathcal{B} \in \mathbb{R}^{|\mathcal{I}|\times|\mathcal{I}|}$, vector chặn b

Tính c, p, n; kiểm tra cận $H = \sum_u n_u^2 \le 5 \cdot 10^7$;
Tính đồng xuất hiện $C = X^\top X$ và xóa đường chéo;
với mỗi *sản phẩm* i **thực hiện**
    Chọn N_i theo (3.9); ghi trọng số vào W^{dir};
kết thúc
Đối xứng hóa $W = \max(W^{\text{dir}}, W^{\text{dir}\top})$; tính Laplacian L;
Tính lịch sử chuẩn hóa $\tilde{X}$ và Gram toàn cục $G = \tilde{X}^\top \tilde{X}$;
với mỗi *sản phẩm* i **thực hiện**
    nếu $c_i = 0$ **thì**
        $\theta_i \leftarrow \theta_i^0$;
    ngược lại
        Lấy khối Gram của N_i từ G, thay chính xác các hàng của người dùng có $X_{ui} = 1$;
        Lập P_i theo (3.13); giải (3.16) bằng Cholesky; kiểm tra sai số dư;
    kết thúc
    Ghi β_i vào cột i của $\mathcal{B}$ và b_i vào b;
kết thúc
Chấm điểm: $s(u,i) = \tilde{X}_{u,:}\,\mathcal{B}_{:,i} + b_i$; khi xếp hạng dùng $s(u,i) \cdot (1+c_i)^{-0{,}1}$;

Quy ước $\mathcal{B}_{ji} = \beta_{ij}$ với $j \in N_i$, bằng 0 ngoài tập nguồn. Khi suy luận, điểm của người dùng u cho sản phẩm i là

$$s(u,i) = \sum_{j \in H_u \cap N_i} \beta_{ij} / \sqrt{\max(n_u, 1)} + b_i. \tag{3.17}$$

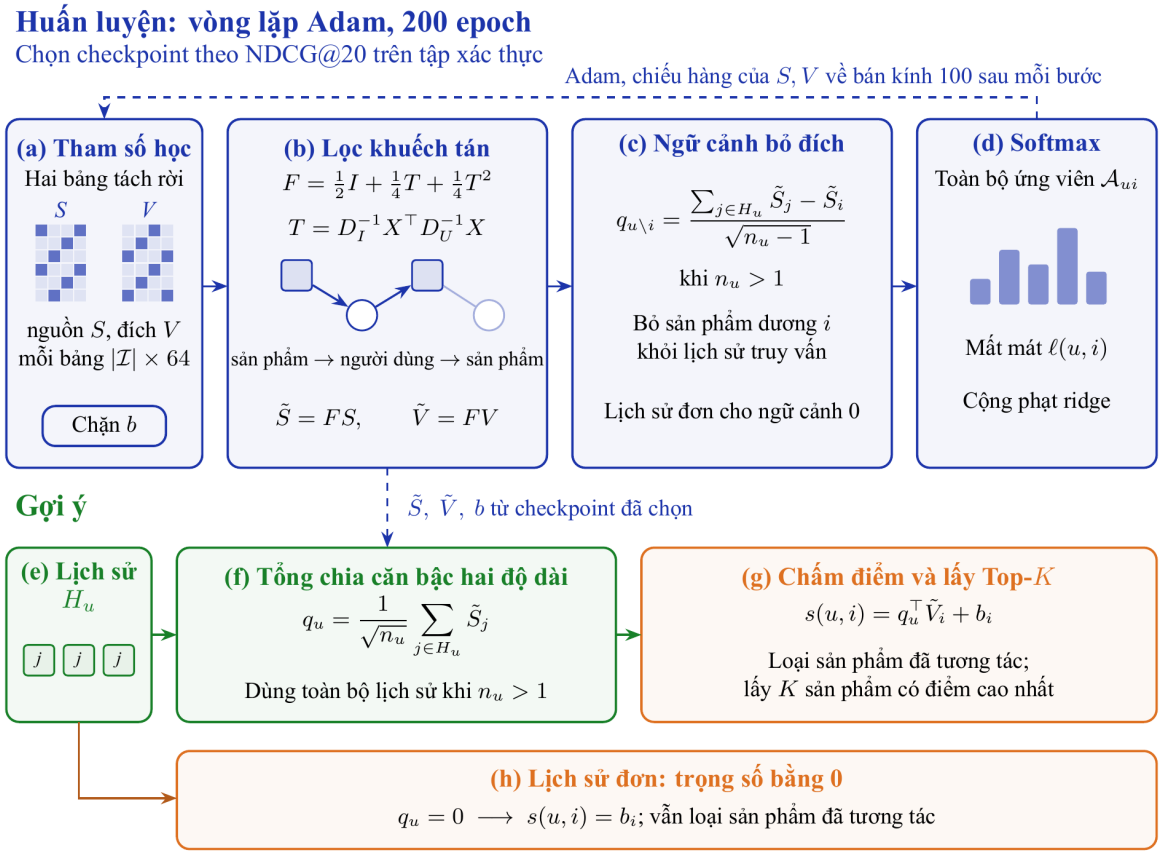
Ở bước xếp hạng, nhóm nhân điểm với $(1+c_i)^{\rho_{\text{pop}}}$, $\rho_{\text{pop}} = -0{,}1$. Hàm lũy thừa điều chỉnh liên tục theo số đếm, còn cộng 1 giữ biểu thức xác định tại $c_i = 0$. Với điểm dương, phép nhân giảm điểm của sản phẩm phổ biến mạnh hơn; với điểm âm, chiều tác động có thể ngược lại. Phép điều chỉnh diễn ra sau hồi quy nên không tham gia (3.12). Khi lịch sử rỗng, mô hình dùng hệ số chặn trước phép điều chỉnh.

Vì điểm là tổng tuyến tính, nhóm có thể tách đóng góp $\beta_{ij}/\sqrt{n_u}$ của từng sản phẩm j trong lịch sử. Phân rã này giải thích điểm số bằng các thành phần đại số, không xác định nguyên nhân khiến người dùng thích sản phẩm.

3.3 Diffusion-Filtered History Factorization

Để xây dựng biểu diễn từ lịch sử theo câu hỏi ở Mục 2.3.5, nhóm kết hợp hai bảng embedding nguồn–đích với bộ lọc khuếch tán và hàm mất mát softmax. DFHF kế

thừa cách tổng hợp lịch sử của Factored Item Similarity Models (FISM) [5] và biểu diễn bất đối xứng của Koren [3]; bộ lọc đa thức theo nguyên tắc tránh phân rã phổ của Turbo-CF [19], còn cạnh tranh xác suất trên danh mục có tiền lệ ở Multinomial Variational Autoencoder (Mult-VAE) [8]. Nhóm lọc cả hai bảng sản phẩm, học từ ngữ cảnh đã bỏ sản phẩm đích và đặt quy tắc riêng cho lịch sử đơn, như trong hình 3.2. Hàng trên của sơ đồ là vòng huấn luyện, hàng dưới là bước gợi ý từ lịch sử; vì lịch sử đơn có trọng số bằng 0, người dùng chỉ có một tương tác được chấm điểm bằng chặn b.



Hình 3.2: Sơ đồ hoạt động của DFHF

Trong vòng học, mỗi lô tính lại hai bảng đã lọc rồi cập nhật tham số từ ngữ cảnh bỏ đích. Khi gợi ý, các bảng từ checkpoint (bản lưu tham số mô hình tại một epoch) được giữ cố định để tổng hợp lịch sử theo (3.19); lịch sử đơn theo quy tắc riêng.

Các bảng sản phẩm đã cố định cho phép tính lại biểu diễn khi lịch sử thay đổi mà không cần vector tham số riêng cho người dùng. Cấu hình cụ thể được ghi ở bảng 4.6.

3.3.1 Biểu diễn lịch sử và bộ lọc khuếch tán

DFHF có hai bảng sản phẩm, mỗi bảng $f = 64$ chiều: nguồn $S \in \mathbb{R}^{|\mathcal{I}|\times f}$ mô tả lịch sử và đích $V \in \mathbb{R}^{|\mathcal{I}|\times f}$ mô tả sản phẩm được chấm điểm, cùng chặn $b \in \mathbb{R}^{|\mathcal{I}|}$. Hai bảng tự do cho phép $\tilde{S}_j^\top \tilde{V}_i$ khác $\tilde{S}_i^\top \tilde{V}_j$; buộc $S = V$ tạo thành phần sản phẩm–sản phẩm dạng Gram đối xứng. Sự linh hoạt về vai trò nguồn–đích đổi lại thêm một bảng tham số, theo hướng nhân tố hóa của FISM [5].

Toán tử T ở (3.6) lấy trung bình theo hai bước sản phẩm–người dùng–sản phẩm. Các phép chia bậc giữ mỗi hàng có tổng 1, khác đồng xuất hiện thô vốn còn mang quy mô số đếm. Bộ lọc là

$$F = \tfrac{1}{2}I + \tfrac{1}{4}T + \tfrac{1}{4}T^2 \tag{3.18}$$

và được áp dụng cho cả hai bảng: $\tilde{S} = FS$, $\tilde{V} = FV$. Thành phần I giữ một phần vector gốc, T và T^2 bổ sung hai mức lan truyền sản phẩm–sản phẩm; bậc hai giới hạn chi phí ở hai lần áp T trên mỗi bảng. Các hệ số không âm, tổng 1 giữ tính lấy trung bình và không tăng chuẩn cực đại theo từng chiều, theo Nhận xét 3.1. Sản phẩm cô lập giữ nguyên vector gốc. So với $F = I$, bộ lọc đưa đồng tương tác vào tham số hóa; so với $\frac{1}{2}I + \frac{1}{2}T$, nó thêm một mức lan truyền và một lần áp T. Các tính chất này giải thích hành vi và chi phí, chưa xác nhận bộ hệ số $(1/2, 1/4, 1/4)$ tốt hơn những lựa chọn khác.

Gọi $\zeta_{\text{hist}} = 0{,}5$ là số mũ chuẩn hóa và $\omega_1 = 0$ là trọng số lịch sử đơn. Tổng thô ứng với số mũ 0, trung bình ứng với số mũ 1; căn độ dài nằm giữa hai cách về hệ số nhân lịch sử. FISM khảo sát số mũ trong $[0, 1]$ và báo cáo mức tốt khoảng $0{,}4$–$0{,}5$ trong thực nghiệm của bài [5, Mục 4, 7.2], cung cấp tiền lệ để cân nhắc $0{,}5$, không xác nhận tối ưu cho DFHF. Cách chia căn chỉ ổn định phương sai theo độ dài dưới những giả thiết thích hợp về tương quan; các vector đã học không mặc nhiên thỏa giả thiết đó. Với các giá trị đang dùng,

$$q_u = \begin{cases} \dfrac{1}{n_u^{\zeta_{\text{hist}}}} \displaystyle\sum_{j \in H_u} \tilde{S}_j, & n_u \geq 2, \\ 0, & n_u \leq 1, \end{cases} \qquad s(u,i) = q_u^\top \tilde{V}_i + b_i. \tag{3.19}$$

Khi $n_u \leq 1$, điểm bằng b_i; danh sách cuối vẫn có thể khác do lịch sử bị loại. Với $n_u = 0$, không có vector lịch sử để tổng hợp. Với $n_u = 1$, đặt $\omega_1 = 0$ chủ động bỏ thông tin của sản phẩm duy nhất; giữ trọng số khác 0 là một phương án khác. Bỏ lịch sử đơn là một lựa chọn thiết kế, không phải hệ quả bắt buộc của việc không dùng vector người dùng.

Với giá trị riêng $\lambda_T \in [0, 1]$ của T, đáp ứng $h(\lambda_T) = \frac{1}{2} + \frac{1}{4}\lambda_T + \frac{1}{4}\lambda_T^2$ thuộc $[1/2, 1]$, nên F khả nghịch. Nếu chưa xét phạt và giới hạn chuẩn, hai bảng tự do S, V vẫn

biểu diễn được mọi cặp bảng $\tilde{S}, \tilde{V}$ qua phép đổi biến này. Bộ lọc vì thế tác động qua tham số hóa, điều chuẩn và quá trình tối ưu, không đặt một ràng buộc cứng buộc mọi nghiệm phải trơn.

3.3.2 Hàm mục tiêu và phương pháp tối ưu

Mỗi truy vấn huấn luyện (u, i) được lấy bằng hai bước: chọn đều $u \in \mathcal{U}_+$, rồi chọn đều $i \in H_u$. Xác suất lấy một truy vấn cụ thể là $1/(|\mathcal{U}_+|n_u)$; các cạnh không có xác suất bằng nhau khi độ dài lịch sử khác nhau. Với $n_u > 1$, ngữ cảnh bỏ chính sản phẩm dương (bỏ một phần tử khỏi lịch sử):

$$q_{u\setminus i} = \frac{1}{(n_u - 1)^{\zeta_{\text{hist}}}} \Big(\sum_{j \in H_u} \tilde{S}_j - \tilde{S}_i \Big). \tag{3.20}$$

Với $n_u = 1$, ngữ cảnh bằng 0, vì loại sản phẩm dương làm lịch sử rỗng. Khi $n_u = 2$, ngữ cảnh huấn luyện vẫn tổng hợp sản phẩm còn lại theo công thức trên: quy tắc lịch sử đơn căn cứ vào bậc giữ lại n_u, không phải độ dài sau loại đích. Tập so sánh khi học là $\mathcal{A}_{ui} = (\mathcal{I}_+ \setminus H_u) \cup \{i\}$. Nó giữ lại đích dương, loại các tương tác giữ lại khác và các sản phẩm cô lập. Hàm mất mát entropy chéo là

$$\ell(u, i) = -\log \frac{\exp\big((q_{u\setminus i}^\top \tilde{V}_i + b_i)/\tau_{\text{sm}}\big)}{\sum_{i' \in \mathcal{A}_{ui}} \exp\big((q_{u\setminus i}^\top \tilde{V}_{i'} + b_{i'})/\tau_{\text{sm}}\big)}, \tag{3.21}$$

với nhiệt độ $\tau_{\text{sm}} = 1$. Softmax làm các ứng viên cạnh tranh trong cùng mẫu số: tăng điểm một sản phẩm khác đích làm giảm xác suất đích. Entropy chéo nhị phân gán hàm mất mát riêng cho từng nhãn, còn Bayesian Personalized Ranking (BPR) so từng cặp dương–âm. Tính đủ mẫu số tránh lấy mẫu một tập âm nhỏ như softmax lấy mẫu, đổi lại phải tính điểm số chưa chuẩn hóa trên toàn danh mục. Mult-VAE cung cấp tiền lệ về cạnh tranh xác suất đa thức [8]; DFHF dùng ngữ cảnh xác định và tập đã loại lịch sử, nên không chuyển kết quả bài đó thành bảo đảm cho hàm mất mát này.

Tập $\mathcal{A}_{ui}$ được xác định từ lịch sử dùng để học, còn tập ứng viên đánh giá tuân theo Mục 4.2.1.

Gọi π_i là xác suất sản phẩm i được chọn làm đích dưới quy tắc lấy mẫu trên. Khi đó,

$$\pi_i = \frac{1}{|\mathcal{U}_+|} \sum_{u \in \mathcal{U}_+} \frac{X_{ui}}{n_u}, \qquad \sum_{i \in \mathcal{I}} \pi_i = 1. \tag{3.22}$$

Mục tiêu kỳ vọng theo phân phối truy vấn, cộng phạt trên hai bảng tham số gốc và

vector chặn, là

$$\mathcal{L} = \frac{1}{|\mathcal{U}_+|} \sum_{u \in \mathcal{U}_+} \frac{1}{n_u} \sum_{i \in H_u} \ell(u, i) + \frac{\lambda_{\text{emb}}}{2} \sum_i \pi_i \frac{\|V_i\|^2 + \|S_i\|^2}{2} + \frac{\lambda_b}{2} \|b\|^2, \tag{3.23}$$

với $\lambda_{\text{emb}} = 0{,}1$ và $\lambda_b = 10^{-4}$. Trung bình hàm mất mát trên lô ước lượng thành phần xếp hạng. Trọng số π_i khiến phạt bằng kỳ vọng mức phạt hàng tại sản phẩm được lấy làm đích, thay vì phạt đều mọi hàng. Nhóm dùng cùng xác suất đích cho cả S và V, dù tần suất xuất hiện ở lịch sử nguồn có thể khác π_i; hai số hạng phạt đều được tính trên toàn bộ bảng ở mỗi bước.

Nhóm dùng thuật toán Adaptive Moment Estimation (Adam) để điều chỉnh cập nhật theo mômen của gradient [30]. Sau bước Adam, gọi $z \in \mathbb{R}^f$ là một hàng vừa cập nhật của S hoặc V, $\hat{v}_{t,i}$ là vector mômen bậc hai đã hiệu chỉnh sai lệch của hàng đó tại bước t. Với $\epsilon = 10^{-8}$, ma trận xác định khoảng cách đường chéo là $D_{t,i}^{\text{Adam}} = \text{diag}(\sqrt{\hat{v}_{t,i}} + \epsilon)$, trong đó căn và phép cộng tính theo từng tọa độ. Phép chiếu được định nghĩa bởi

$$\Pi_R^D(z) = \arg\min_{\|x\|_2 \le R} \frac{1}{2}(x - z)^\top D(x - z), \qquad R = R_{\text{emb}} = 100. \tag{3.24}$$

Nếu z nằm trong cầu thì giữ nguyên; nếu ở ngoài, nghiệm có tọa độ $x_k = D_{kk} z_k / (D_{kk} + \mu)$, với $\mu > 0$ được tìm bằng chia đôi để $\|x\|_2 = R$. Vì D thường không tỉ lệ với I, phép này khác co hướng tâm Euclid. Giới hạn chuẩn khống chế độ lớn hàng tham số; phạt ridge vẫn tham gia mục tiêu bên trong miền đó. Vector chặn chỉ chịu phạt λ_b, không chịu phép chiếu này. Bán kính 100 là giá trị sử dụng, chưa được xác nhận tối ưu bằng phân tích độ nhạy.

3.3.3 Thuật toán huấn luyện và suy luận

DFHF được huấn luyện bằng Adam với tốc độ học $\text{lr} = 0{,}0003$, hai hệ số mômen $\beta_{1,\text{Adam}} = 0{,}9$, $\beta_{2,\text{Adam}} = 0{,}999$, lô tối đa $Q_{\text{batch}} = 2048$ truy vấn và $N_{\text{ep}} = 200$ epoch. Mỗi epoch lấy độc lập $|E|$ truy vấn theo quy tắc chọn người dùng rồi chọn sản phẩm; một cạnh có thể lặp hoặc không được chọn.

Thuật toán 2: Huấn luyện DFHF

Đầu vào: Tập cạnh giữ lại E; siêu tham số ở bảng 4.6
Đầu ra: Checkpoint (S, V, b) có NDCG@20 tập xác thực cao nhất

Khởi tạo $V \sim \mathcal{N}(0, 1/f)$, $S \leftarrow V$ (sau đó cập nhật độc lập), $b \leftarrow 0$;
với *epoch* $= 1, \ldots, N_{\text{ep}}$ **thực hiện**
  Lấy một dãy $|E|$ truy vấn độc lập: $u \sim \text{Unif}(\mathcal{U}_+)$, rồi $i \sim \text{Unif}(H_u)$;
  Chia dãy thành các lô tối đa Q_{batch} truy vấn, cho phép truy vấn lặp;
  với mỗi *lô truy vấn trong dãy* **thực hiện**
    Tính $\tilde{S} = FS$, $\tilde{V} = FV$ theo (3.18);
    Tính ngữ cảnh $q_{u\setminus i}$ và hàm mất mát (3.21) cộng phạt;
    Cập nhật Adam với lr; chiếu hàng của S, V về bán kính R_{emb} theo khoảng cách của Adam;
  kết thúc
  Đánh giá NDCG@20 trên tập xác thực; lưu checkpoint nếu tốt hơn;
kết thúc

Khi suy luận, nhóm giữ cố định các bảng sản phẩm từ checkpoint và tổng hợp lịch sử theo (3.19), với quy tắc riêng cho lịch sử rỗng và lịch sử đơn. Cách lựa chọn checkpoint và các siêu tham số được xác định ở Mục 4.3.

3.4 Phân tích tính chất và chi phí tính toán

Theo bảng 3.1, GRNR lưu tối đa $(k+1)|\mathcal{I}|$ hệ số và hệ số chặn, còn EASE đầy đủ có $|\mathcal{I}|(|\mathcal{I}|-1)$ hệ số ngoài đường chéo. Bảng 3.2 cho thấy DFHF chỉ lưu bảng sản phẩm, trong khi Light Graph Convolution Network (LightGCN) còn có bảng người dùng. Với $k = 128$, số hệ số của GRNR kể cả chặn không vượt $129|\mathcal{I}|$; với $f = 64$, DFHF học $129|\mathcal{I}|$ tham số.

	GRNR	EASE đầy đủ
Vector tham số người dùng	Không	Không
Số hệ số và chặn	$\leq (k+1)\|\mathcal{I}\|$	$\|\mathcal{I}\|(\|\mathcal{I}\|-1)$ hệ số ngoài đường chéo
Cách xác định hệ số	Các hệ tuyến tính kích thước tối đa $(k+1)\times(k+1)$	Một phép nghịch đảo cỡ $\|\mathcal{I}\| \times \|\mathcal{I}\|$
Khi lịch sử thay đổi	Tính lại điểm với hệ số cố định	Tính lại điểm với hệ số cố định

Bảng 3.1: Đặc điểm lý thuyết của GRNR và EASE

Với GRNR, phần giải các hệ có chi phí $O(|\mathcal{I}|(k+1)^3)$. Ngoài ra còn có dựng đồng xuất hiện C, Gram G, chọn láng giềng và hiệu chỉnh các mẫu dương. Đặt $H = \sum_u n_u^2$; phép tạo C và G có khối lượng đóng góp theo các cặp sản phẩm trong từng lịch sử, ở mức $O(H)$. Nếu hàng i của C° có t_i phần tử khác 0, việc xếp nguồn để chọn láng

giềng tốn tối đa $O(\sum_i t_i \log \max(t_i, 1))$. Hiệu chỉnh Gram theo các mẫu dương có cận $O(|E|(k+1)^2)$. Vì vậy chi phí giải hệ chỉ là một phần của toàn bộ giai đoạn khớp mô hình.

Cài đặt kiểm tra trước cận $H \leq 5 \cdot 10^7$; nếu vượt cận thì dừng trước khi tạo ma trận đồng xuất hiện. Đây là giới hạn cho phép thực hiện phép tính, không phải cắt ma trận xuống một số phần tử cố định. Bộ nhớ tạm khi tạo C hoặc G có thể vượt phần hệ số cuối. Phần hệ số và chặn được lưu thưa ở mức $O(k|\mathcal{I}|)$, ngoài dữ liệu lịch sử và đồ thị cần giữ lại.

EASE [9] tốn $O(|\mathcal{I}|^3)$ cho nghịch đảo và $O(|\mathcal{I}|^2)$ cho ma trận đầy đủ, dù đường chéo của nghiệm bằng 0. Khi suy luận, cả hai phương pháp nhân lịch sử với hệ số đã lưu; GRNR còn cộng chặn và điều chỉnh theo độ phổ biến. Với GRNR, chi phí tích thưa phụ thuộc số hệ số trên các hàng sản phẩm thực sự được truy cập trong lịch sử.

	DFHF	LightGCN
Vector tham số người dùng	Không	Có
Số tham số được học	$(2f+1)\|\mathcal{I}\|$	$f(\|\mathcal{U}\| + \|\mathcal{I}\|)$
Mục tiêu học	Softmax trên ứng viên hợp lệ, cộng phạt	BPR có điều chuẩn
Khi lịch sử thay đổi	Tổng hợp lại lịch sử với bảng sản phẩm cố định, theo quy tắc lịch sử đơn	Phân biệt tính lại lan truyền khi đổi đồ thị với cập nhật các vector tham số

Bảng 3.2: Đặc điểm lý thuyết của DFHF và LightGCN

DFHF có số tham số học không phụ thuộc số người dùng, còn LightGCN [11] có một vector tham số riêng cho mỗi người dùng. Tuy nhiên, DFHF vẫn lưu lịch sử và các cấu trúc thưa, nên tổng bộ nhớ của cài đặt còn phụ thuộc $|E|$, $|\mathcal{U}|$ và $|\mathcal{I}|$.

Gọi $Q_{\text{batch}} = 2048$ là số truy vấn tối đa trong lô và $B_{\text{ep}} = \lceil |E|/Q_{\text{batch}} \rceil$ là số lô mỗi epoch. Mỗi lô tính lại hai bảng đã lọc; mỗi bảng dùng hai lần áp T, tức tổng cộng bốn lần áp toán tử. Một lần áp T qua hai phép nhân thưa có chi phí $O(|E|f)$, cộng chuẩn hóa và xử lý các hàng ở mức $O((|\mathcal{U}| + |\mathcal{I}|)f)$. Tính điểm số chưa chuẩn hóa cho mọi sản phẩm rồi loại các phần tử ngoài $\mathcal{A}_{ui}$ có chi phí $O(Q_{\text{batch}}|\mathcal{I}|f)$ mỗi lô. Với các hạng chính này, chi phí một epoch huấn luyện là

$$O\big(|E|\,|\mathcal{I}|\,f + B_{\text{ep}}(|E| + |\mathcal{U}| + |\mathcal{I}|)f\big)\,, \tag{3.25}$$

Phép tính này được lặp ở từng lô, thay vì chỉ lọc một lần ở đầu epoch. Khi tham số cố định, các bảng được lọc và lịch sử được tổng hợp một lần trước khi chấm điểm. Nếu

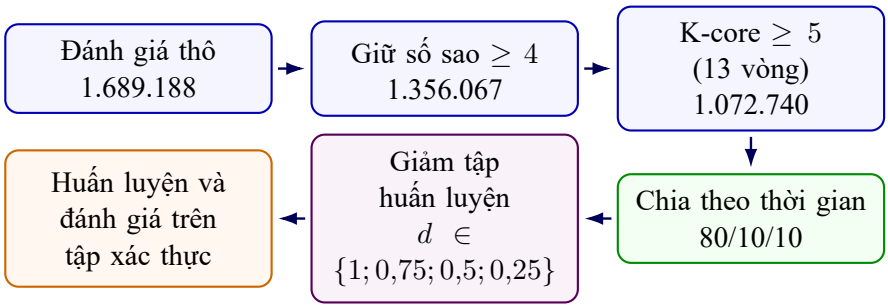
có N_{val} người dùng cần chấm điểm, phần tính điểm đầy đủ tốn $O(N_{\text{val}}|\mathcal{I}|f)$, ngoài chi phí tạo các bảng và biểu diễn. Khi phục vụ lịch sử mới, các bảng đã lọc có thể được giữ cố định để tính tổng lịch sử và điểm ứng viên.

4 Thiết lập thực nghiệm

4.1 Dữ liệu và tiền xử lý

Nhóm sử dụng danh mục Electronics của bộ Amazon product data do McAuley và cộng sự công bố [6, 7], gồm các đánh giá thuộc bản 5-core và thông tin mô tả sản phẩm (metadata). Bản 5-core yêu cầu mỗi người dùng và sản phẩm có ít nhất 5 đánh giá. Nhóm lấy mã người dùng, mã sản phẩm, số sao và thời điểm từ từng đánh giá, rồi quy ước đánh giá từ 4 sao trở lên là một phản hồi tích cực, tức $X_{ui} = 1$ theo Định nghĩa 2.1. Tương tác ở đây là tín hiệu sở thích suy ra từ đánh giá công khai, không phải lượt mua. Thông tin mô tả chỉ cung cấp tên, thương hiệu và danh mục cho demo, không tham gia xếp hạng.

Nhóm khử các đánh giá tích cực trùng cặp người dùng–sản phẩm bằng cách giữ đánh giá mới nhất, ưu tiên số sao cao hơn nếu cùng thời điểm; dữ liệu này không có cặp trùng. Sau khi bỏ đánh giá thấp, một số người dùng và sản phẩm không còn đủ 5 tương tác, nên nhóm áp lại K-core hai phía với ngưỡng 5: loại các nút dưới ngưỡng, tính lại bậc và lặp đến khi hội tụ sau 13 vòng. Các mã còn lại được ánh xạ sang chỉ số liên tục theo thứ tự mã gốc. Hình 4.1 ghi số tương tác qua từng bước: lọc số sao loại 333.121 đánh giá, khử trùng không loại đánh giá nào và K-core loại thêm 283.327 tương tác.



Hình 4.1: Quy trình tiền xử lý dữ liệu

Bảng 4.1 thống kê dữ liệu trước khi chia tập. Mật độ tương tác bằng 0,0192%, và một nửa người dùng có không quá 6 tương tác. Nhóm tạo thêm các mức độ thưa bằng cách giảm số tương tác huấn luyện.

Dữ liệu sau tiền xử lý được chia theo thời gian. Lịch sử của mỗi người dùng được sắp theo thời điểm đánh giá; các tương tác cùng thời điểm được sắp theo một hàm băm có seed của cặp người dùng–sản phẩm, rồi theo mã sản phẩm. Từ những người dùng có ít nhất 3 tương tác, chọn ngẫu nhiên 107.274 người dùng với seed 42; sau K-core, mọi người dùng đều thỏa điều kiện này. Số người dùng được chọn bằng 10% tổng số

Thống kê	Giá trị
Số người dùng	124.895
Số sản phẩm	44.843
Số tương tác	1.072.740
Mật độ	0,0192%
Số tương tác mỗi người dùng: trung bình / trung vị / lớn nhất	8,59 / 6 / 354
Số tương tác trung bình mỗi sản phẩm	23,9

Bảng 4.1: Thống kê dữ liệu sau tiền xử lý

tương tác, để tập xác thực và tập kiểm tra mỗi tập chiếm đúng 10% dữ liệu. Với mỗi người dùng được chọn, tương tác cuối cùng được đưa vào tập kiểm tra, tương tác áp cuối vào tập xác thực, và các tương tác trước đó vào tập huấn luyện. 17.621 người dùng còn lại chỉ có mặt trong tập huấn luyện. Tỉ lệ 80/10/10 ở bảng 4.2 vì vậy được tính trên tổng số tương tác, không áp dụng riêng cho từng người dùng. Cách chia này cho mỗi người dùng được chọn đúng một mục tiêu, nhờ đó chất lượng được đo và so sánh ghép cặp theo từng người dùng; một mốc thời gian chung sẽ để lại nhiều người dùng không có mục tiêu nào. Trong bảng 4.2, sản phẩm mới là sản phẩm không có trong tập huấn luyện.

	Huấn luyện	Xác thực	Kiểm tra
Số tương tác	858.192	107.274	107.274
Tỉ lệ	80%	10%	10%
Mục tiêu thuộc sản phẩm mới	—	59	187

Bảng 4.2: Kết quả chia tập theo thời gian

Sau khi chia, không có cặp người dùng–sản phẩm nào xuất hiện ở hai tập, và thứ tự thời gian trong từng lịch sử là không giảm. Có 40 sản phẩm không xuất hiện trong tập huấn luyện; tương tác của chúng được giữ nguyên ở tập đã chia để không phá thứ tự thời gian. Cách xử lý 59 mục tiêu xác thực thuộc các sản phẩm này được nêu ở Mục 4.2.1. Tập xác thực vừa dùng để chọn cấu hình và checkpoint, vừa dùng để báo cáo mọi kết quả. Tập kiểm tra không được dùng; kiểm kê các tệp kết quả không tìm thấy điểm nào trên tập kiểm tra đã được lưu, nhưng điều đó chưa đủ để khẳng định tập kiểm tra chưa từng được xem.

Để khảo sát ảnh hưởng của độ thưa, tập huấn luyện được giữ lại ở các tỉ lệ $d \in \{1; 0{,}75; 0{,}5; 0{,}25\}$, còn tập xác thực và tập kiểm tra giữ nguyên. d là tỉ lệ số tương tác huấn luyện còn lại so với tập huấn luyện đầy đủ; vì số người dùng và sản phẩm được giữ cố định, mật độ của ma trận tương tác giảm theo d. Bốn mức cách đều nhau 25%

đi từ tập huấn luyện đầy đủ đến mức mà phần lớn người dùng chỉ còn một tương tác, như bảng 4.3 cho thấy.

Thuật toán giảm dùng seed 42, gán một số ngẫu nhiên cho mỗi tương tác rồi tạo một *lõi phủ*: trước hết giữ tương tác đầu tiên theo thứ tự ngẫu nhiên của mỗi sản phẩm, sau đó giữ tương tác đầu tiên của mỗi người dùng chưa được phủ. Các tương tác còn lại được thêm theo cùng thứ tự cho đến khi đủ round$(d \cdot |E|)$ tương tác, với E là tập tương tác huấn luyện đầy đủ. Cách tạo này bảo đảm mỗi người dùng và mỗi sản phẩm có mặt trong tập huấn luyện ban đầu vẫn còn ít nhất một tương tác. Mỗi mức d được tạo một lần và dùng chung cho mọi mô hình.

d	1	0,75	0,5	0,25
Số tương tác	858.192	643.644	429.096	214.548
Số tương tác trung bình mỗi người dùng	6,87	5,15	3,44	1,72
Người dùng warm bậc 1	0	6.657	28.555	72.944
Tỉ lệ người dùng warm bậc 1	0%	6,2%	26,6%	68,0%

Bảng 4.3: Tập huấn luyện ở các mức giảm tương tác

Lõi phủ bảo toàn ít nhất một tương tác cho các nút ít dữ liệu, nên cách giảm này khác với lấy mẫu tương tác ngẫu nhiên đều. Bảng 4.3 gọi người dùng warm (Mục 4.2.1) chỉ còn đúng một tương tác huấn luyện là người dùng bậc 1. Ở $d = 0{,}25$, 68,0% người dùng warm thuộc nhóm này. Nhóm xác định các nhóm người dùng theo độ dài lịch sử ở tập huấn luyện gốc ($d = 1$) và giữ cách phân nhóm đó tại mọi mức d.

4.2 Tiêu chí so sánh

4.2.1 Đơn vị đánh giá và thước đo xếp hạng

Nhóm đánh giá trên tập $\mathcal{U}_w$ gồm các người dùng *warm*, tức vừa có lịch sử huấn luyện vừa có sản phẩm mục tiêu xác thực đã xuất hiện trong tập huấn luyện. Theo quy tắc này, 59 mục tiêu thuộc sản phẩm chưa có trong tập huấn luyện bị loại, còn 107.215 người dùng. Tập $\mathcal{U}_w$ được giữ cố định cho mọi mô hình và mọi d, mỗi người dùng có đúng một sản phẩm mục tiêu.

Với từng người dùng, nhóm chấm điểm toàn bộ sản phẩm có trong tập huấn luyện (44.803 sản phẩm ở $d = 1$), loại lịch sử huấn luyện gốc, kể cả các tương tác bị bỏ khi giảm dữ liệu, rồi chọn K sản phẩm có điểm cao nhất theo Định nghĩa 2.2. Gọi r_u là hạng của sản phẩm mục tiêu trong danh sách, bắt đầu từ 1. Phép đánh giá dùng toàn bộ tập ứng viên vì lấy mẫu sản phẩm âm có thể làm đổi thứ tự mô hình [12]; quy

tắc này không thay đổi cách lấy mẫu âm khi huấn luyện bằng Bayesian Personalized Ranking (BPR).

Nhóm đo chất lượng bằng Recall at K (Recall@K) và Normalized Discounted Cumulative Gain at K (NDCG@K), với $K \in \{10, 20\}$, lấy NDCG@20 làm thước đo chính. Ngưỡng 20 cũng được các bài gốc của Light Graph Convolution Network (LightGCN) và eXtremely Simple Graph Contrastive Learning (XSimGCL) sử dụng [11, 17]. Mỗi thước đo được tính riêng cho từng người dùng rồi lấy trung bình với trọng số bằng nhau.

Gọi $\mathcal{R}_u \neq \varnothing$ là tập sản phẩm liên quan dùng để đánh giá người dùng u, $\mathcal{L}_u^K$ là tập K gợi ý đầu. Khi đó [31]:

$$\text{Recall}_u@K = \frac{|\mathcal{R}_u \cap \mathcal{L}_u^K|}{|\mathcal{R}_u|}, \qquad \text{Recall@}K = \frac{1}{|\mathcal{U}_w|} \sum_{u \in \mathcal{U}_w} \text{Recall}_u@K. \tag{4.1}$$

Tử số đếm sản phẩm liên quan tìm thấy trong top-K, còn mẫu số đếm toàn bộ sản phẩm liên quan dùng để đánh giá. Ở đây mỗi người dùng có một mục tiêu xác thực, nên tìm trúng được điểm 1, bỏ sót được điểm 0. Trung bình là tỉ lệ người dùng được gợi ý trúng (Hit Rate); vị trí bên trong top-K không ảnh hưởng đến điểm.

NDCG@K tính thêm vị trí của mục tiêu. Discounted Cumulative Gain (DCG) và dạng chuẩn hóa của nó do Järvelin và Kekäläinen đề xuất [32]: mỗi sản phẩm phù hợp đóng góp trọng số $1/\log_2(j+1)$ tại hạng j. Mẫu số chuẩn hóa là Ideal Discounted Cumulative Gain at K (IDCG@K), tức DCG của thứ tự lý tưởng. Gọi $\text{rel}_{u,j}$ bằng 1 khi sản phẩm tại hạng j là mục tiêu của người dùng u và bằng 0 nếu ngược lại; khi đó

$$\text{DCG}_u@K = \sum_{j=1}^{K} \frac{\text{rel}_{u,j}}{\log_2(j+1)}, \qquad \text{NDCG}_u@K = \frac{\text{DCG}_u@K}{\text{IDCG}_u@K}. \tag{4.2}$$

Với một mục tiêu, thứ tự lý tưởng đặt mục tiêu ở hạng 1, nên $\text{IDCG}_u@K = 1/\log_2 2 = 1$. Gọi $\mathbf{1}[\cdot]$ là hàm chỉ báo, bằng 1 khi điều kiện đúng và 0 khi sai; khi đó

$$\text{NDCG@}K = \frac{1}{|\mathcal{U}_w|} \sum_{u \in \mathcal{U}_w} \frac{\mathbf{1}[r_u \leq K]}{\log_2(r_u + 1)}. \tag{4.3}$$

Cả hai thước đo đều thuộc $[0, 1]$, giá trị càng cao càng tốt. Với NDCG, mục tiêu ở hạng 1 đóng góp 1, ở hạng 3 đóng góp 0,5, ở hạng 20 đóng góp khoảng 0,228, và ngoài top-K đóng góp 0. Vì có trọng số theo vị trí, NDCG trung bình không biểu thị tỉ lệ người dùng có mục tiêu trong danh sách.

Ví dụ giả định, ba người dùng có mục tiêu ở các hạng 1, 5 và 15. Với $K = 10$, Recall@10 bằng $2/3 \approx 0{,}6667$, còn NDCG@10 bằng $(1 + 1/\log_2 6)/3 \approx 0{,}4623$. Nếu

mục tiêu ở hạng 5 được đưa lên hạng 2, Recall@10 giữ nguyên nhưng NDCG@10 tăng lên khoảng $0{,}5436$. Cả hai chỉ đo trên mục tiêu quan sát được, không bao quát những sở thích chưa được ghi nhận của người dùng.

4.2.2 Đại lượng so sánh và kiểm định

Nhóm dùng MostPop làm mốc chung cho hai nhóm mô hình. Ở mỗi d, MostPop gán điểm $s(u, i) = c_i$, với c_i là số tương tác của sản phẩm i trong tập huấn luyện giữ lại, rồi loại lịch sử theo cùng quy tắc với các mô hình khác. Thứ tự trước khi loại lịch sử là chung cho mọi người dùng. Mốc không cá nhân hóa này cho phép đối chiếu với cách chỉ gợi ý sản phẩm phổ biến; Dacrema và cộng sự cũng nhấn mạnh vai trò của các phương pháp đơn giản được thiết lập cẩn thận [10].

Gọi $M_m(d)$ là giá trị một thước đo của mô hình m tại mức d. So với mô hình b, chênh lệch tuyệt đối là $\Delta M = M_m(d) - M_b(d)$, còn mức thay đổi tương đối là $100\,\Delta M / M_b(d)$ % khi $M_b(d) > 0$; giá trị âm nghĩa là m thấp hơn b. Mức vượt MostPop dùng b là MostPop và M là NDCG@20. Nhóm đối chiếu từng mô hình với mốc này trong phạm vi nhóm của nó.

Nhóm theo dõi chất lượng ở từng d bằng giá trị tuyệt đối và tỉ lệ duy trì $M_m(d)/M_m(1)$ khi $M_m(1) > 0$. Tỉ lệ này cho biết phần chất lượng còn lại so với chính mô hình trên tập huấn luyện đầy đủ và luôn đi cùng giá trị tuyệt đối.

Ngoài các ngưỡng chính 10 và 20, nhóm tính NDCG@K với $K = 1, \ldots, 20$ từ cùng danh sách dự đoán đã lưu để mô tả ảnh hưởng của độ dài danh sách; không chọn lại checkpoint hay kiểm định riêng tại từng K. Hai đại lượng mô tả bổ sung là độ phổ biến của sản phẩm được gợi ý và độ phủ danh mục. Gọi $\mathcal{I}_0$ là tập 44.803 sản phẩm xuất hiện trong tập huấn luyện gốc, $c_i^{(0)}$ là số tương tác của sản phẩm i trong tập này và $L_{u,m}^{20}(d)$ là danh sách 20 gợi ý của mô hình m cho người dùng u ở mức d. Khi đó

$$\mathrm{Pop}_{20}(m, d) = \frac{1}{20|\mathcal{U}_w|} \sum_{u \in \mathcal{U}_w} \sum_{i \in L_{u,m}^{20}(d)} \ln(1 + c_i^{(0)}), \tag{4.4}$$

$$\mathrm{Cov}_{20}(m, d) = 100\, \frac{\left|\bigcup_{u \in \mathcal{U}_w} L_{u,m}^{20}(d)\right|}{|\mathcal{I}_0|}\ \%. \tag{4.5}$$

Đại lượng thứ nhất lấy trung bình sau biến đổi log để giảm ảnh hưởng của sản phẩm có rất nhiều tương tác; giá trị cao hơn nghĩa là các gợi ý nghiêng về sản phẩm phổ biến hơn theo mốc huấn luyện gốc. Đại lượng thứ hai đếm phần danh mục được gợi ý ít nhất một lần cho toàn bộ tập người dùng. Mốc độ phổ biến và mẫu số danh mục giữ cố định ở mọi d, còn tập ứng viên vẫn tuân theo giao thức ở trên. Hai đại lượng chỉ mô tả các danh sách đã lưu, không đo trực tiếp sự hài lòng hay độ đa dạng trong từng danh sách và không dùng để chọn mô hình.

Với mỗi cặp mô hình đề xuất và baseline cùng nhóm, nhóm tính hiệu NDCG@20 của từng người dùng rồi bootstrap ghép cặp theo người dùng 10.000 lần. Khoảng tin cậy 95% được lấy từ các phân vị bootstrap. Giá trị p một phía cho giả thuyết mô hình đề xuất tốt hơn được tính từ phân phối bootstrap đã dịch tâm về chênh lệch trung bình bằng 0, rồi hiệu chỉnh Holm trong 3 so sánh của mỗi nhóm tại từng d. Với 10.000 lần lặp, giá trị p chưa hiệu chỉnh có sàn $(0+1)/(10^4+1) \approx 10^{-4}$, nên sau hiệu chỉnh Holm, kết quả chạm sàn được ghi là $p_{\text{Holm}} \leq 3 \cdot 10^{-4}$. Mỗi mức d được xem là một họ giả thuyết riêng, và việc hiệu chỉnh không gộp qua bốn mức. Khoảng tin cậy được báo cáo riêng cho từng so sánh, không hiệu chỉnh đồng thời.

Phép bootstrap giữ cố định mô hình và checkpoint đã chọn, lấy người dùng làm đơn vị tái lấy mẫu. Khi khoảng tin cậy chứa 0, nhóm kết luận chưa phát hiện được khác biệt, không kết luận hai mô hình tương đương.

Chi phí được đo bằng thời gian xây dựng mô hình, thời gian suy luận và dung lượng lưu trữ. Với nhóm giải trực tiếp, thời gian là thời gian khớp mô hình ghi lại trong lần chạy; với nhóm cần huấn luyện, đó là tổng thời gian 200 epoch và thời gian trung bình mỗi epoch. Thời gian suy luận là thời gian trung bình cho mỗi người dùng khi chấm điểm theo lô; nhóm cần huấn luyện được đo trên GPU, còn số đo riêng của GRNR được ghi trên CPU. Không có số đo suy luận cùng điều kiện cho các baseline giải trực tiếp. Dung lượng của các mô hình giải trực tiếp là kích thước tệp checkpoint, tính theo mebibyte (MiB; $1\,\text{MiB} = 2^{20}$ byte). Riêng EASE đầy đủ dùng kích thước lý thuyết của ma trận hệ số ở dạng số thực 32 bit, $4|\mathcal{I}|^2/2^{20}$ MiB, vì ma trận này không được lưu thành checkpoint. Bộ nhớ cực đại khi khớp mô hình hoặc khi suy luận chưa được đo. Thời gian chạy phụ thuộc vào môi trường nêu ở Mục 4.3.

4.3 Cấu hình thực nghiệm

Nhóm so Graph-Regularized Neighborhood Regression (GRNR) với Embarrassingly Shallow Autoencoder (EASE) đầy đủ, EASE top-128 và Graph Filter based Collaborative Filtering (GF-CF) trong nhóm giải trực tiếp; Diffusion-Filtered History Factorization (DFHF) được so với LightGCN, XSimGCL và DirectAU trong nhóm cần huấn luyện. Hai mô hình đề xuất không được so trực tiếp với nhau. Cấu hình và phần cứng được ghi ở bảng 4.4. EASE top-128 giữ 128 hệ số lớn nhất mỗi cột của nghiệm EASE đầy đủ, còn GRNR giải từng hệ bằng Cholesky. EASE dùng $\lambda = 300$, giá trị giữa của lưới 100, 300, 1000 trong mã nguồn tham chiếu; nhóm không chọn lại λ trên tập xác thực của dự án. GF-CF dùng cấu hình mặc định và các baseline cần huấn luyện dùng cấu hình tham chiếu của tác giả. Mã gốc của GF-CF tính các vector kỳ dị bằng thư viện sparsesvd; thư viện này không cài được với NumPy 2, nên nhóm thay

bằng phép lặp không gian con theo khối, dừng khi phần dư đạt ngưỡng hội tụ, để lấy $r = 256$ vector kỳ dị đầu. Nhóm chưa đối chiếu nghiệm của hai cách tính.

Nhóm	Mô hình	Cấu hình chính	Phần cứng
Giải trực tiếp	GRNR	Bảng 4.5	CPU
	EASE đầy đủ [9]	$\lambda = 300$	CPU
	EASE top-128	EASE đầy đủ, giữ 128 hệ số mỗi cột	CPU
	GF-CF [14]	$r = 256$, $\alpha_{\text{GF}} = 0{,}3$	CPU
Cần huấn luyện	DFHF	Bảng 4.6	GPU
	LightGCN [11]	$f = 64$, $\nu = 3$, BPR	GPU
	XSimGCL [17]	$\lambda_{\text{cl}} = 0{,}1$; $\tau = 0{,}2$; $\epsilon = 0{,}1$	GPU
	DirectAU [15]	Bộ mã hóa LightGCN; $\gamma_{\text{AU}} = 1$	GPU
Mốc chung	MostPop	Độ phổ biến trong tập huấn luyện	CPU

Bảng 4.4: Cấu hình và môi trường chạy

LightGCN, XSimGCL và DirectAU dùng embedding 64 chiều, 3 lớp lan truyền, thuật toán tối ưu Adaptive Moment Estimation (Adam) với tốc độ học $0{,}0003$, kích thước lô 2.048 và 200 epoch. LightGCN và XSimGCL dùng hệ số phạt ℓ_2 bằng 10^{-4} trong hàm mất mát và không thêm suy giảm trọng số ở Adam. DirectAU dùng hệ số 2 trong số hạng đồng đều, đúng như công thức (2.7), suy giảm trọng số của Adam bằng 10^{-6} và không thêm phạt ℓ_2 riêng trong hàm mất mát, theo cấu hình tham chiếu của tác giả.

Với GRNR, nhóm giới hạn mỗi hồi quy ở 128 láng giềng, dùng các hệ số điều chuẩn trong bảng 4.5 khi giải hệ và nhân điểm với hệ số độ phổ biến có số mũ $\rho_{\text{pop}} = -0{,}1$. Các bước tính tuân theo Mục 3.2.

Ký hiệu	Ý nghĩa	Giá trị
k	Số láng giềng tối đa	128
κ_{lift}	Làm trơn mẫu số của lift	10
ω_+	Trọng số mẫu dương	10
η	Phạt ridge cho hệ số láng giềng	10^{-5}
α_s	Làm trơn mức hỗ trợ trong s_j	2
$s_{\max}$	Giới hạn trên của s_j	10
λ_g	Trọng số điều chuẩn đồ thị	10^{-3}
β	Phần năng lượng biên được giữ	0,5
η_b	Phạt cho hệ số chặn	10^{-3}
ρ_{pop}	Số mũ của hệ số độ phổ biến khi xếp hạng	$-0{,}1$

Bảng 4.5: Siêu tham số của GRNR

Với DFHF, nhóm dùng cấu hình ở bảng 4.6 cho mô hình trong Mục 3.3. Tham số $\omega_1 = 0$ làm lịch sử đơn không đóng góp vào vector người dùng, nên điểm của người

dùng chỉ còn một tương tác được xác định bằng hệ số chặn.

Ký hiệu	Ý nghĩa	Giá trị
f	Số chiều embedding	64
lr	Tốc độ học	$0{,}0003$
$\lvert\mathcal{Q}\rvert$	Kích thước lô tối đa	2.048
λ_{emb}	Phạt ridge cho embedding	0,1
λ_b	Phạt cho vector chặn	10^{-4}
R_{emb}	Bán kính chiếu embedding	100
ζ_{hist}	Số mũ chuẩn hóa lịch sử	0,5
ω_1	Trọng số lịch sử đơn	0
τ_{sm}	Nhiệt độ softmax	1
N_{ep}	Số epoch	200

Bảng 4.6: Siêu tham số của DFHF

Nhóm chạy mọi mô hình trên Kaggle, dùng CPU cho nhóm giải trực tiếp và GPU cho nhóm cần huấn luyện. Tính cả bốn mức d, thời gian xây dựng các mô hình giải trực tiếp là khoảng 2,5 giờ (GRNR 7 phút, EASE 45 phút, GF-CF 95 phút), còn thời gian huấn luyện là khoảng 13,1 giờ (DFHF 5,2 giờ, DirectAU 3,5 giờ, XSimGCL 2,6 giờ, LightGCN 1,8 giờ). Môi trường phần mềm gồm Python 3.13, PyTorch 2.11, NumPy 2.1 và SciPy 1.16.

Nhóm huấn luyện các mô hình đủ 200 epoch và chọn checkpoint có NDCG@20 trên tập xác thực cao nhất. Kết quả được tính từ checkpoint đã chọn, còn chi phí huấn luyện tính trên toàn bộ 200 epoch.

5 Kết quả và thảo luận

Mọi kết quả trong chương được đo trên tập xác thực, với một seed (42), theo các tiêu chí ở Mục 4.2. Để câu văn dễ theo dõi, bốn mức giữ lại dữ liệu huấn luyện $d = 1$, $0{,}75$, $0{,}5$ và $0{,}25$ (Mục 4.1) được gọi lần lượt là toàn bộ dữ liệu, ba phần tư, một nửa và một phần tư dữ liệu; mức một phần tư cũng được gọi là mức thưa nhất.

5.1 Graph-Regularized Neighborhood Regression so với các mô hình giải trực tiếp

GRNR được thiết kế để trả lời một câu hỏi thực dụng: có cần đến ma trận trọng số đầy đủ của EASE không, hay chỉ cần một số ít láng giềng được ước lượng cẩn thận là đủ? Vì vậy, đối chứng quan trọng nhất của GRNR không chỉ là EASE đầy đủ mà còn là EASE top-128. Hai mô hình này có cùng ngân sách lưu trữ, khoảng 128 hệ số cho mỗi sản phẩm. Điểm khác nhau là EASE top-128 giải bài toán đầy đủ rồi mới cắt bớt, còn GRNR giới hạn láng giềng ngay trong bài toán. GF-CF đại diện cho hướng lọc tín hiệu trên toàn đồ thị.

5.1.1 Chất lượng xếp hạng khi có đủ dữ liệu

d	Mô hình	NDCG@10	NDCG@20	Recall@10	Recall@20
1	GRNR	**0,03292**	**0,03829**	**0,05629**	**0,07757**
	EASE đầy đủ	0,03287	0,03796	0,05607	0,07629
	EASE top-128	0,03206	0,03679	0,05413	0,07290
	GF-CF	0,01573	0,01886	0,02788	0,04035
0,75	GRNR	**0,02545**	0,02928	**0,04319**	0,05836
	EASE đầy đủ	**0,02545**	**0,02939**	0,04303	**0,05867**
	EASE top-128	0,02448	0,02772	0,04068	0,05345
	GF-CF	0,00668	0,00839	0,01237	0,01916
0,5	GRNR	0,01465	0,01715	0,02417	0,03410
	EASE đầy đủ	**0,01658**	**0,01917**	**0,02710**	**0,03736**
	EASE top-128	0,01564	0,01766	0,02496	0,03294
	GF-CF	0,00268	0,00384	0,00547	0,01009
0,25	GRNR	**0,00573**	**0,00798**	**0,01113**	**0,02017**
	EASE đầy đủ	0,00534	0,00674	0,00956	0,01513
	EASE top-128	0,00438	0,00497	0,00703	0,00936
	GF-CF	0,00205	0,00385	0,00511	0,01235

Bảng 5.1: Chất lượng xếp hạng, nhóm giải trực tiếp

Bảng 5.1 cho thấy khi dùng toàn bộ dữ liệu, ba mô hình hồi quy giữa các sản phẩm gần như không tách được nhau, và thứ tự của chúng giữ nguyên ở cả bốn thước đo. GRNR đứng đầu với NDCG@20 bằng 0,03829, nhưng chỉ hơn EASE đầy đủ 0,9%; theo bảng 5.2, khoảng tin cậy của chênh lệch này vẫn chứa 0, nên chưa thể nói GRNR tốt hơn. Phép so sánh đáng chú ý hơn là với EASE top-128, mô hình dùng đúng ngân sách hệ số như GRNR. Ở đây GRNR hơn 4,1%, và khoảng tin cậy nằm hẳn trên 0.

Nói cách khác, với toàn bộ dữ liệu, nếu đằng nào cũng phải giới hạn số hệ số thì giải ngay bài toán đã giới hạn tốt hơn là giải bài toán đầy đủ rồi cắt bớt. Lý do có thể nằm ở cách EASE ước lượng hệ số: mỗi hệ số được tính khi có mặt mọi sản phẩm khác, nên khi phần lớn sản phẩm bị bỏ đi, những hệ số còn lại không còn là nghiệm tốt nhất cho tập láng giềng mới. GRNR thì ước lượng hệ số ngay trên tập láng giềng mà nó sẽ dùng. Báo cáo chưa tách riêng được yếu tố này khỏi những khác biệt khác của GRNR, như trọng số mẫu và điều chuẩn đồ thị.

d	So sánh	Δ NDCG@20	KTC 95%	p_{Holm} (một phía)
1	GRNR − EASE đầy đủ	+0,00033	[−0,00007; +0,00073]	0,051
	GRNR − EASE top-128	+0,00150	[+0,00111; +0,00189]	$\leq 3 \cdot 10^{-4}$
	GRNR − GF-CF	+0,01943	[+0,01874; +0,02010]	$\leq 3 \cdot 10^{-4}$
0,75	GRNR − EASE đầy đủ	−0,00011	[−0,00049; +0,00028]	0,721
	GRNR − EASE top-128	+0,00157	[+0,00121; +0,00193]	$\leq 3 \cdot 10^{-4}$
	GRNR − GF-CF	+0,02089	[+0,02023; +0,02159]	$\leq 3 \cdot 10^{-4}$
0,5	GRNR − EASE đầy đủ	−0,00202	[−0,00237; −0,00167]	1,000
	GRNR − EASE top-128	−0,00051	[−0,00082; −0,00021]	1,000
	GRNR − GF-CF	+0,01331	[+0,01276; +0,01386]	$\leq 3 \cdot 10^{-4}$
0,25	GRNR − EASE đầy đủ	+0,00124	[+0,00095; +0,00154]	$\leq 3 \cdot 10^{-4}$
	GRNR − EASE top-128	+0,00301	[+0,00274; +0,00330]	$\leq 3 \cdot 10^{-4}$
	GRNR − GF-CF	+0,00413	[+0,00383; +0,00444]	$\leq 3 \cdot 10^{-4}$

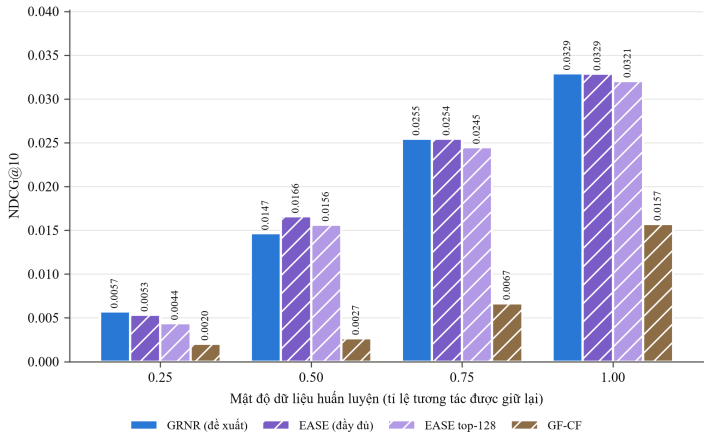
Bảng 5.2: Kiểm định NDCG@20, nhóm giải trực tiếp

GF-CF thì ở hẳn một mức khác, với NDCG@20 chỉ hơn mốc MostPop 4%. Kết quả này trái với báo cáo của Shen và cộng sự, nơi GF-CF cạnh tranh được với các mô hình đồ thị cần huấn luyện [14], nên nhiều khả năng cấu hình hoặc cài đặt GF-CF trong dự án chưa hợp với bộ dữ liệu này. Khoảng cách rất lớn giữa GRNR và GF-CF vì thế phản ánh một baseline yếu nhiều hơn là sức mạnh của GRNR.

5.1.2 Chất lượng theo thước đo và độ dài danh sách

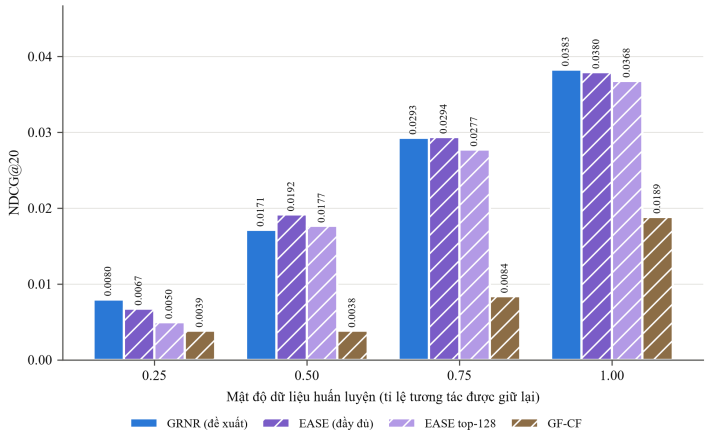
Khi bớt dần dữ liệu, thứ tự ấy không còn giữ nguyên. Ở NDCG@10, hình 5.1 cho thấy GRNR và EASE đầy đủ vẫn đi sát nhau khi còn ba phần tư dữ liệu, thậm chí bằng

nhau đến chữ số thứ năm, còn EASE top-128 luôn thấp hơn chừng 3%. Bức tranh chỉ đổi ở nửa sau của dải dữ liệu. Khi còn một nửa, GRNR tụt xuống dưới cả hai biến thể EASE, kém EASE đầy đủ 11,6%; nhưng khi chỉ còn một phần tư, GRNR lại vươn lên dẫn đầu, hơn EASE đầy đủ 7,3%. GF-CF thấp nhất ở mọi mức, và ngay cả với toàn bộ dữ liệu cũng chỉ đạt khoảng một nửa GRNR.



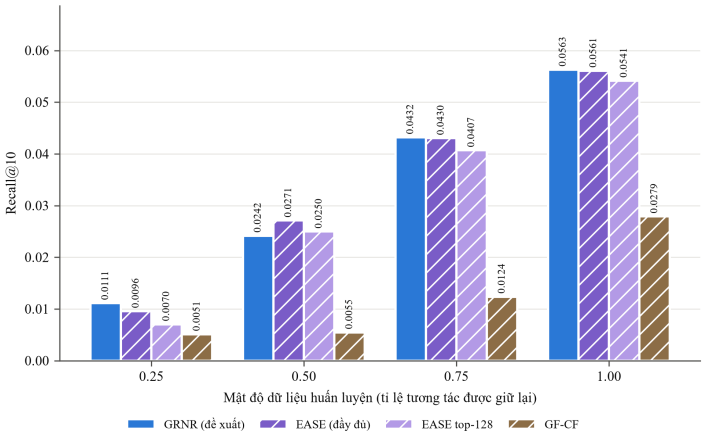
Hình 5.1: NDCG@10 theo mức d, nhóm giải trực tiếp

Hình 5.2 mở rộng danh sách lên 20 vị trí. Thứ tự giữ nguyên ở ba mức đầu, nhưng khoảng cách ở mức thưa nhất giãn ra hẳn: khi chỉ còn một phần tư dữ liệu, GRNR hơn EASE đầy đủ 18,4%, gấp hơn hai lần mức chênh ở NDCG@10. Vì hai thước đo chỉ khác nhau ở mười vị trí cuối, phần lớn ưu thế ấy phải nằm ở các vị trí 11–20, chứ không ở mười gợi ý đầu. Khoảng cách bất lợi khi còn một nửa dữ liệu thì hầu như không đổi, GRNR vẫn kém EASE đầy đủ 10,5%. Riêng GF-CF gần như đứng yên từ mức một nửa xuống mức một phần tư; đó không phải dấu hiệu bền vững, mà vì mô hình đã chạm mức rất thấp từ trước.



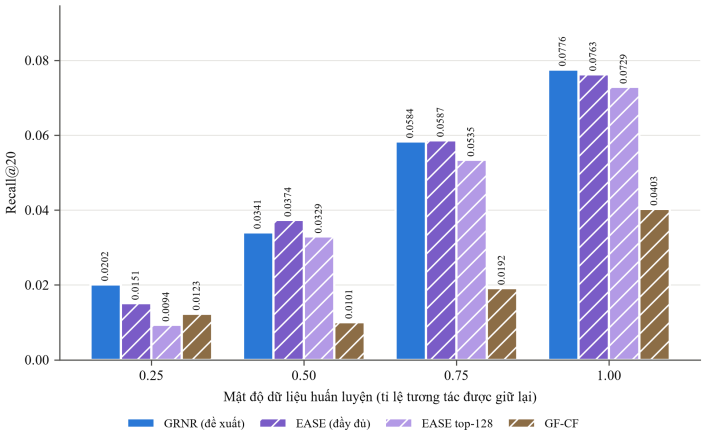
Hình 5.2: NDCG@20 theo mức d, nhóm giải trực tiếp

Recall bỏ qua vị trí và chỉ hỏi sản phẩm mục tiêu có lọt vào danh sách hay không, nhờ đó tách được hai câu hỏi "có tìm thấy không" và "có xếp đúng chỗ không". Ở Recall@10, hình 5.3 cho thấy GRNR nhỉnh hơn EASE đầy đủ khi còn ba phần tư dữ liệu, dù kém một chút theo NDCG@20; hai thước đo như vậy không phải lúc nào cũng cùng chiều khi các mô hình đứng sát nhau. Khi còn một nửa, GRNR xếp cuối trong ba mô hình hồi quy; khi chỉ còn một phần tư, nó hơn EASE đầy đủ 16,4%, gấp đôi mức chênh theo NDCG@10.



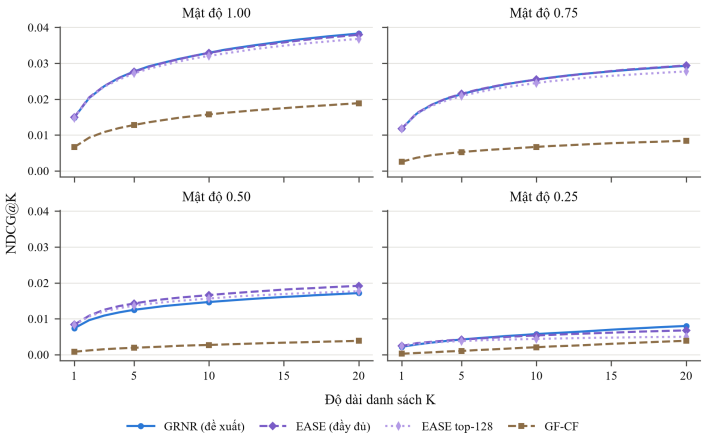
Hình 5.3: Recall@10 theo mức d, nhóm giải trực tiếp

Hình 5.4 cho thấy Recall@20 khuếch đại cùng xu hướng. Ở mức thưa nhất, GRNR hơn EASE đầy đủ tới 33,3%; khi còn một nửa dữ liệu, GRNR vượt được EASE top-128 dù thua ở Recall@10. Cả hai quan sát cùng chỉ về một hướng: danh sách càng dài, GRNR càng tìm thêm được mục tiêu ở các hạng sau, điều chưa đồng nghĩa với việc đưa mục tiêu lên đầu danh sách tốt hơn. GF-CF lại một lần nữa hành xử bất thường: Recall@20 của nó tăng khi bớt dữ liệu từ một nửa xuống một phần tư, đến mức vượt cả EASE top-128, thêm một dấu hiệu cho thấy cấu hình của baseline này cần được kiểm tra lại.



Hình 5.4: Recall@20 theo mức d, nhóm giải trực tiếp

Đường NDCG@K ở hình 5.5 trả lời thẳng câu hỏi khoảng cách giữa các mô hình nằm ở đầu hay cuối danh sách. Khi còn từ ba phần tư dữ liệu trở lên, đường của GRNR và EASE đầy đủ chồng lên nhau ngay từ gợi ý đầu tiên, còn EASE top-128 chỉ tách xuống ở các vị trí sau. Khi còn một nửa, EASE đầy đủ dẫn ngay từ gợi ý đầu tiên và giữ khoảng cách đó đến cuối. Khi chỉ còn một phần tư, GRNR thậm chí kém EASE đầy đủ ở ba vị trí đầu, ngang bằng ở vị trí thứ năm rồi mới vượt lên, đúng như khác biệt giữa NDCG@10 và NDCG@20 đã gợi ý. Các đường được tính từ cùng danh sách dự đoán, không chọn lại mô hình cho từng K, nên chỉ mang tính mô tả; kiểm định chính vẫn dành cho NDCG@20.



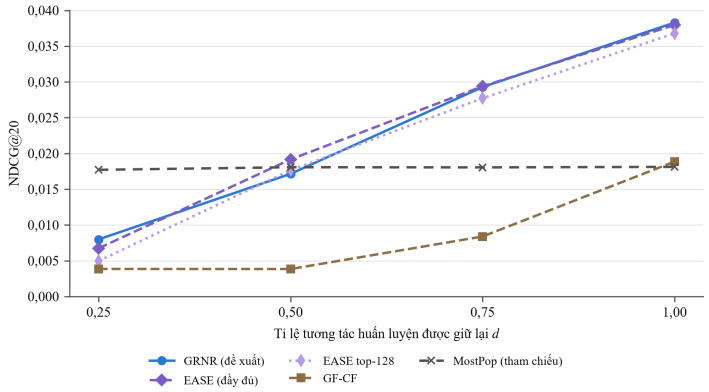
Hình 5.5: NDCG@K, nhóm giải trực tiếp

5.1.3 Chất lượng khi dữ liệu thưa dần

Nếu chỉ so các mô hình với nhau, diễn biến theo mức thưa khá rõi: GRNR hơn EASE đầy đủ ở mức một phần tư, chưa phân định được ở mức ba phần tư, nhưng thua rõ khi

còn một nửa dữ liệu, với khoảng tin cậy nằm hẳn dưới 0 theo bảng 5.2, và ở mức này còn kém cả EASE top-128. Đây là kết quả bất lợi cho GRNR. Vì kiểm định một phía chỉ được thiết kế để phát hiện GRNR tốt hơn, nó không báo được chiều ngược này; phải đọc khoảng tin cậy mới thấy.

Khi đặt thêm mốc MostPop vào như ở hình 5.6 thì một xu hướng lớn hơn nhiều hiện ra: cả nhóm cùng rơi xuống dưới mức xếp hạng theo độ phổ biến.



Hình 5.6: NDCG@20 so với MostPop, nhóm giải trực tiếp

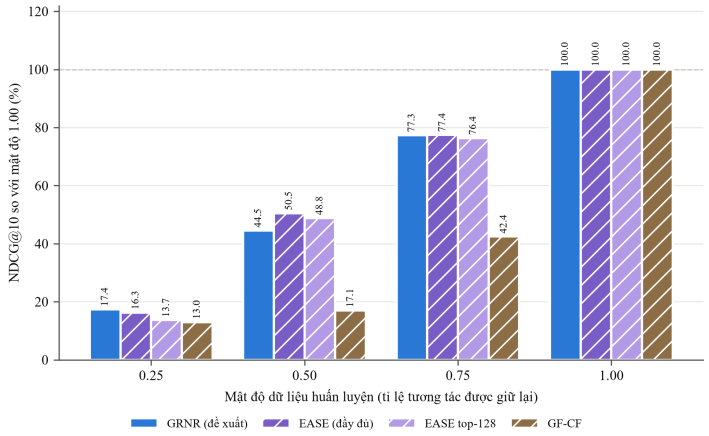
Bảng 5.3 đo điều này bằng mức vượt MostPop, tức chênh lệch tương đối so với cách xếp hạng không cá nhân hóa. Với toàn bộ dữ liệu, ba mô hình hồi quy đều đạt khoảng gấp đôi MostPop. Chỉ bớt một phần tư dữ liệu, mức vượt đã giảm còn 54–63%; còn một nửa thì cả ba chỉ quanh quẩn mốc MostPop; và còn một phần tư thì cả nhóm kém MostPop từ 55% đến 78%. So với khoảng cách vài phần trăm giữa các mô hình, mức sụt này lớn hơn cả một bậc.

	$d = 1$	$d = 0{,}75$	$d = 0{,}5$	$d = 0{,}25$
MostPop (NDCG@20)	0,01812	0,01805	0,01807	0,01771
GRNR	+111,3%	+62,2%	−5,1%	−54,9%
EASE đầy đủ	+109,5%	+62,8%	+6,1%	−61,9%
EASE top-128	+103,0%	+53,6%	−2,3%	−71,9%
GF-CF	+4,1%	−53,5%	−78,8%	−78,3%

Bảng 5.3: Mức vượt MostPop, nhóm giải trực tiếp

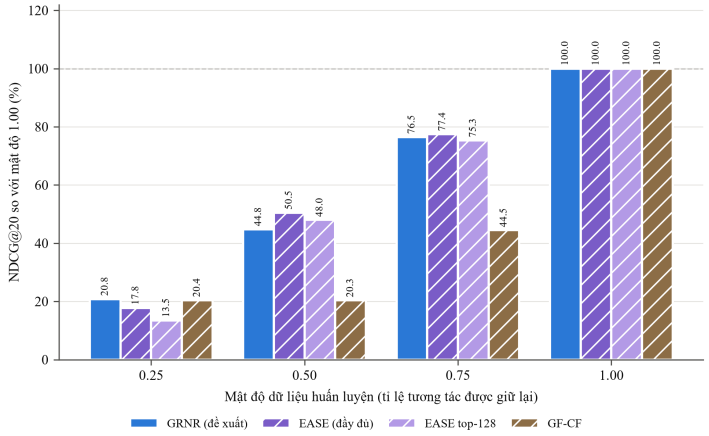
Tỉ lệ duy trì nhìn cùng dữ liệu từ một góc khác: chất lượng ở mỗi mức được tính thành phần trăm của chính mô hình đó khi dùng toàn bộ dữ liệu, nên cho biết mô hình suy giảm nhanh hay chậm, bất kể xuất phát cao hay thấp. Theo NDCG@10 ở hình 5.7, ba mô hình hồi quy cùng giữ khoảng 77% khi bớt một phần tư dữ liệu và chỉ tách ra ở nửa sau. Khi còn một nửa, GRNR giảm nhanh hơn, chỉ giữ 44,5% so với khoảng

một nửa ở hai biến thể EASE; khi còn một phần tư, thứ tự đảo lại và GRNR giữ nhiều nhất. GF-CF suy giảm nhanh nhất ngay từ bước đầu, mất hơn một nửa chất lượng khi mới bớt một phần tư dữ liệu.



Hình 5.7: Tỉ lệ duy trì NDCG@10, nhóm giải trực tiếp

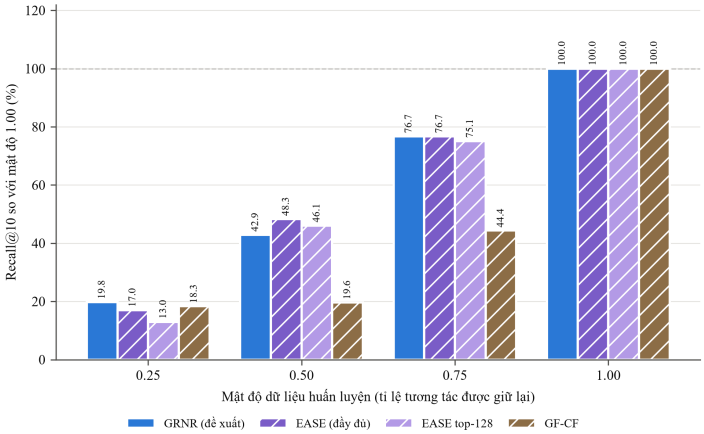
NDCG@20 ở hình 5.8 cho cùng diễn biến: ở mức thưa nhất, cả nhóm giữ được từ 13,5% đến 20,8% chất lượng ban đầu, và GRNR vẫn giữ nhiều nhất. Tỉ lệ 20,4% của GF-CF trông gần bằng GRNR, nhưng con số này dễ gây hiểu lầm, vì nó đến từ việc mô hình đã chạm đáy từ mức một nửa chứ không phải từ sức bền. Hiện tượng này, cùng việc thời gian chạy của GF-CF không tăng đều theo lượng dữ liệu, chưa được giải thích.



Hình 5.8: Tỉ lệ duy trì NDCG@20, nhóm giải trực tiếp

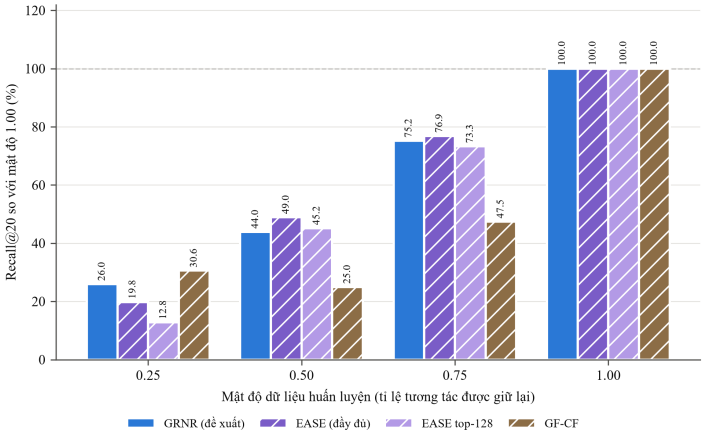
Ở Recall@10, hình 5.9 cho thấy bức tranh vẫn vậy: GRNR suy giảm nhanh hơn hai biến thể EASE khi còn một nửa dữ liệu, chỉ giữ 42,9% so với 46–48%, nhưng giữ nhiều nhất khi còn một phần tư. Khoảng cách đáng chú ý nhất ở mức thưa nhất lại là

giữa GRNR và EASE top-128, gần 7 điểm phần trăm. Bản EASE bị cắt vì thế là mô hình chịu thiệt nhiều nhất khi dữ liệu cạn.



Hình 5.9: Tỉ lệ duy trì Recall@10, nhóm giải trực tiếp

Theo hình 5.10, Recall@20 là thước đo duy nhất mà GRNR giữ được hơn một phần tư giá trị ban đầu ở mức thưa nhất, 26,0% so với 20,8% theo NDCG@20: mô hình vẫn đưa được một phần mục tiêu vào 20 vị trí đầu, nhưng phần chất lượng phụ thuộc vào vị trí suy giảm mạnh hơn. EASE top-128 giữ ít nhất. GF-CF có tỉ lệ cao nhất nhóm, 30,6%, nhưng đó là hệ quả của việc Recall@20 của nó tăng lên khi bớt dữ liệu, không phải dấu hiệu bền vững. Vì mỗi mô hình có một mẫu số riêng, các tỉ lệ này luôn cần được đọc cùng giá trị tuyệt đối ở bảng 5.1.



Hình 5.10: Tỉ lệ duy trì Recall@20, nhóm giải trực tiếp

5.1.4 Nguồn tín hiệu khi dữ liệu thưa

Mức sụt so với MostPop có một nguyên nhân cơ học. Mọi mô hình trong nhóm đều học từ đồng xuất hiện, tức hai sản phẩm cùng nằm trong lịch sử của một người dùng,

và một cặp chỉ còn khi cả hai tương tác cùng được giữ lại. Số cặp vì thế giảm nhanh hơn nhiều so với số tương tác. Bảng 5.4 xác nhận điều đó: khi chỉ còn một phần tư số tương tác, tập huấn luyện chỉ còn 4,2% số cặp đồng xuất hiện. Trong bảng, số cặp theo người dùng là $\sum_u n_u(n_u-1)/2$, số cặp sản phẩm là số cặp sản phẩm khác nhau có $C_{ij} > 0$, còn hai hàng cuối đếm hệ số láng giềng khác 0 trong checkpoint GRNR. Có thể đối chiếu với một mốc lý thuyết đơn giản: nếu mỗi tương tác được giữ độc lập với xác suất d, một cặp chỉ còn với xác suất d^2. Ở hai mức ba phần tư và một nửa, số đo (56,3% và 24,2%) gần sát mốc này (56,25% và 25%); chỉ ở mức một phần tư, số đo thấp hơn rõ (4,2% so với 6,25%). Một cách giải thích là cách giảm dữ liệu giữ ít nhất một tương tác cho mỗi người dùng (Mục 4.1): khi dữ liệu còn rất ít, một phần đáng kể số tương tác được giữ lại dồn vào những người dùng chỉ còn một tương tác, vốn không tạo ra cặp nào. Ảnh hưởng lên GRNR thấy rõ qua số láng giềng: mỗi sản phẩm trung bình có 89,8 láng giềng khi dùng toàn bộ dữ liệu nhưng chỉ còn 11,1 ở mức thưa nhất, và 12,7% sản phẩm không còn láng giềng nào. Với những sản phẩm này, điểm của GRNR chỉ còn hệ số chặn b_i, tức một dạng độ phổ biến.

	$d = 1$	$d = 0{,}75$	$d = 0{,}5$	$d = 0{,}25$
Số tương tác	100,0%	75,0%	50,0%	25,0%
Số cặp đồng xuất hiện theo người dùng	100,0%	56,3%	24,2%	4,2%
Số cặp sản phẩm có đồng xuất hiện	100,0%	58,5%	26,1%	4,7%
Số láng giềng trung bình của GRNR	89,8	68,9	42,5	11,1
Sản phẩm không có láng giềng	0,1%	0,1%	0,8%	12,7%

Bảng 5.4: Đồng xuất hiện còn lại trong tập huấn luyện

NDCG@20 của GRNR giảm cùng chiều với số cặp đồng xuất hiện nhưng chậm hơn nhiều: còn 76,5%, 44,8% và 20,8% ở ba mức thưa, trong khi số cặp chỉ còn 56,3%, 24,2% và 4,2%. Phần chênh này một phần đến từ hệ số chặn, vốn không cần đồng xuất hiện. GRNR cũng là mô hình "ít tệ nhất" trong nhóm ở mức thưa nhất, kém MostPop 55% so với 62% của EASE đầy đủ. Vì bài toán của GRNR neo hệ số chặn vào xác suất nền của sản phẩm và phạt nặng các láng giềng ít dữ liệu, một cách giải thích là khi thiếu đồng xuất hiện, mô hình dựa nhiều hơn vào hệ số chặn thay vì vào các hệ số nhiễu. Đây mới là giả thuyết, và phân tích độ phổ biến dưới đây không ủng hộ nó.

Nếu GRNR thật sự xếp hạng gần theo độ phổ biến khi dữ liệu thưa, các sản phẩm được gợi ý phải phổ biến hơn và tập trung vào ít sản phẩm hơn. Bảng 5.5, tính theo Mục 4.2.2, cho thấy điều ngược lại. Độ phổ biến trung bình sau biến đổi log của GRNR giảm từ 5,60 với toàn bộ dữ liệu xuống 4,18 khi còn một nửa, rồi chỉ nhích

lên 4,50 ở mức thưa nhất, vẫn thấp hơn ban đầu; hai biến thể EASE thì giảm đều. Khi đồng xuất hiện cạn, cả nhóm như vậy gợi ý những sản phẩm ít phổ biến hơn chứ không lùi về sản phẩm phổ biến. Một cách giải thích khác cũng phù hợp với số liệu: hệ số láng giềng của các sản phẩm ít tương tác trở nên nhiễu và đẩy chính các sản phẩm này lên danh sách.

Độ phủ danh mục trong top-20, tính trên 44.803 sản phẩm của tập huấn luyện gốc, cùng chiều với nhận xét này: GRNR gợi ý ít nhất một lần khoảng 85% danh mục ở cả mức đầy đủ lẫn mức thưa nhất, tức danh sách không co lại về một nhóm nhỏ sản phẩm. GF-CF có độ phủ trên 93% ở mọi mức dù xếp hạng kém, cho thấy độ phủ cao chỉ nói rằng nhiều sản phẩm xuất hiện trong danh sách, chưa nói gì về việc chúng có hợp với người nhận hay không.

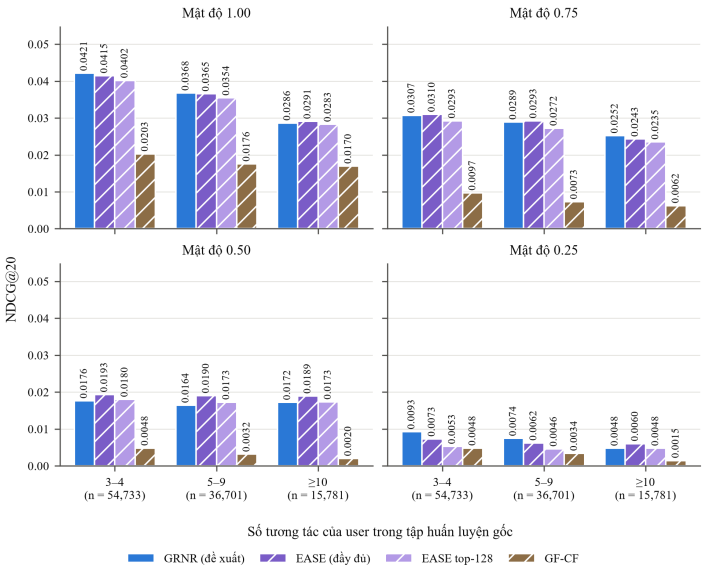
	$d = 1$	$d = 0{,}75$	$d = 0{,}5$	$d = 0{,}25$
Độ phổ biến trung bình (log)				
GRNR	5,60	5,02	4,18	4,50
EASE đầy đủ	5,64	5,39	4,86	4,25
EASE top-128	5,12	4,89	4,42	3,38
GF-CF	2,68	2,39	2,58	3,68
Độ phủ danh mục trong top-20 (%)				
GRNR	85,3	94,9	97,6	84,7
EASE đầy đủ	72,2	92,8	96,3	83,7
EASE top-128	87,0	95,9	97,0	84,2
GF-CF	98,6	99,4	99,9	93,9

Bảng 5.5: Độ phổ biến và độ phủ, nhóm giải trực tiếp

5.1.5 Chất lượng theo độ dài lịch sử người dùng

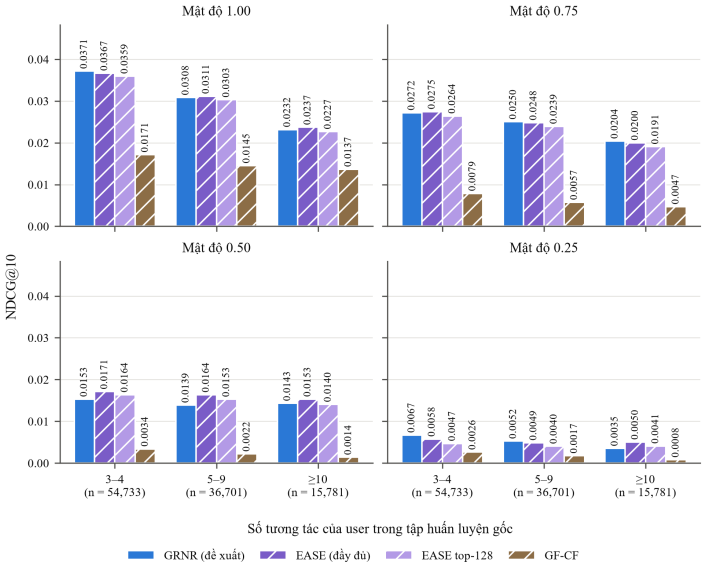
Một cách khác để đọc kết quả là chia người dùng theo số tương tác trong tập huấn luyện gốc thành ba nhóm: 3–4, 5–9 và từ 10 tương tác trở lên, lần lượt có 54.733, 36.701 và 15.781 người dùng. Hình 5.11 cho một kết quả ngược trực giác: người dùng có nhiều tương tác hơn lại được gợi ý kém hơn. Ở mọi mô hình và mọi mức dữ liệu, NDCG@20 của nhóm lịch sử dài nhất đều thấp hơn nhóm ngắn nhất; với GRNR trên toàn bộ dữ liệu, ba nhóm đạt lần lượt 0,0421, 0,0368 và 0,0286. Có hai cách giải thích cạnh tranh mà báo cáo chưa kiểm tra: người dùng nhiều tương tác có thể có sở thích trải rộng hơn, khiến lịch sử ít định hướng cho lần mua tiếp theo; hoặc sản phẩm mục tiêu của họ ít phổ biến hơn, nên khó đoán với mọi mô hình. Vì hiện tượng này lặp lại ở nhóm cần huấn luyện (Mục 5.2), nhiều khả năng đây là tính chất của dữ liệu hơn là của riêng một mô hình.

Cách chia này cũng cho biết ưu thế của GRNR ở mức thưa nhất đến từ đâu. GRNR hơn EASE đầy đủ ở hai nhóm lịch sử ngắn (0,0093 so với 0,0073 và 0,0074 so với 0,0062) nhưng kém ở nhóm dài nhất (0,0048 so với 0,0060). Ưu thế trung bình vì thế đến từ những người dùng ít tương tác, cũng là nhóm đông nhất, dù phân tích chưa cho biết cơ chế đằng sau. Các nhóm được giữ cố định theo lịch sử gốc nên không đổi khi bớt dữ liệu, và các giá trị theo nhóm chỉ mang tính mô tả.



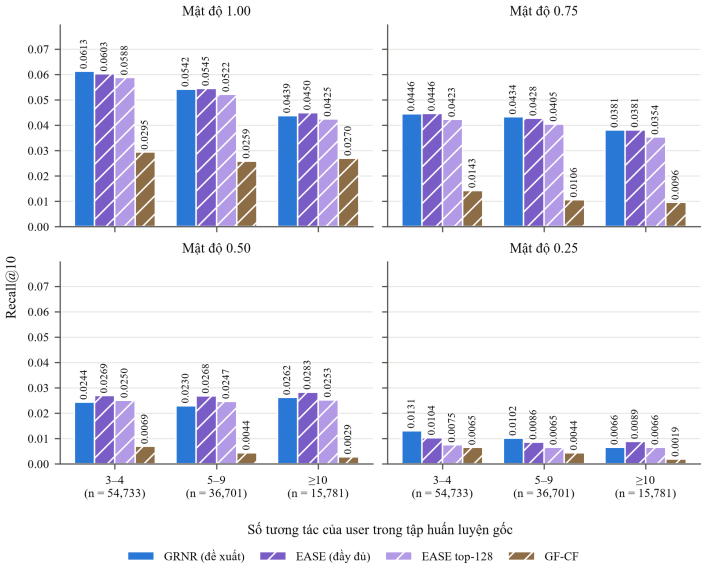
Hình 5.11: NDCG@20 theo độ dài lịch sử, nhóm giải trực tiếp

Khi thu hẹp về mười vị trí đầu ở hình 5.12, xu hướng giảm theo độ dài lịch sử vẫn còn, nhưng GRNR không còn dẫn ở mọi nhóm. Ngay với toàn bộ dữ liệu, GRNR chỉ cao nhất ở nhóm lịch sử ngắn nhất, còn ở hai nhóm kia EASE đầy đủ nhỉnh hơn một chút. Sự phân hóa rõ nhất ở mức thưa nhất: GRNR hơn EASE đầy đủ 16% ở nhóm 3–4 nhưng kém 31% ở nhóm dài nhất. Mức chênh trung bình giữa hai mô hình vì vậy che đi hai chiều ngược nhau giữa các nhóm người dùng.



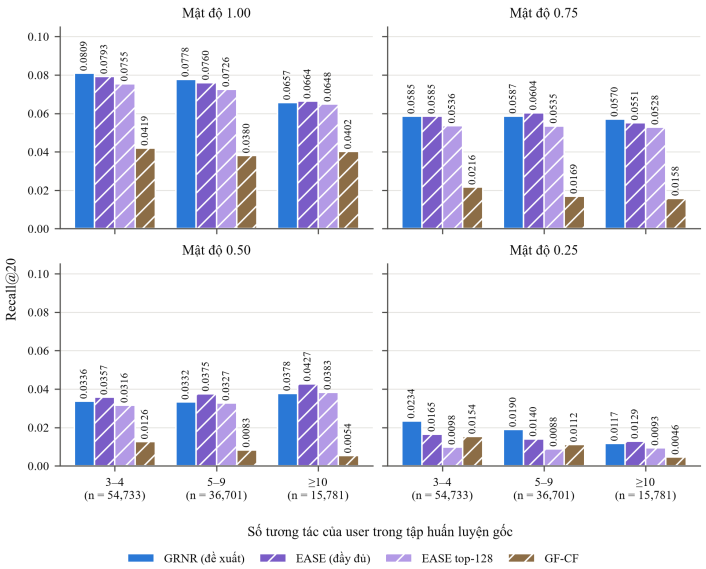
Hình 5.12: NDCG@10 theo độ dài lịch sử, nhóm giải trực tiếp

Recall@10 ở hình 5.13 cho thấy chính nhận xét "lịch sử dài thì khó gợi ý hơn" cũng không đúng ở mọi mức dữ liệu. Với toàn bộ dữ liệu, Recall@10 của GRNR giảm đều theo độ dài lịch sử, từ 0,061 xuống 0,044. Nhưng khi còn một nửa, nhóm lịch sử dài nhất lại có Recall@10 cao nhất, và EASE đầy đủ cũng đảo chiều như vậy. Có thể là sau khi bớt dữ liệu, người dùng lịch sử dài vẫn còn vài tương tác để tạo đồng xuất hiện, trong khi nhiều người dùng lịch sử ngắn chỉ còn một; báo cáo chưa kiểm tra giải thích này. Đến mức thưa nhất, mẫu hình của NDCG@10 quay lại: GRNR dẫn ở hai nhóm ngắn nhưng thua EASE đầy đủ ở nhóm dài nhất.



Hình 5.13: Recall@10 theo độ dài lịch sử, nhóm giải trực tiếp

Ở Recall@20, hình 5.14 cho thấy sự đảo chiều khi còn một nửa dữ liệu còn rõ hơn. Recall@20 của EASE đầy đủ tăng dần theo độ dài lịch sử, từ 0,036 lên 0,043, ngược hẳn với khi dùng toàn bộ dữ liệu, và GRNR cũng cao hơn ở nhóm dài nhất so với nhóm ngắn nhất. Ở mức ba phần tư, Recall@20 của GRNR gần như bằng nhau giữa ba nhóm. Nhận xét "người dùng nhiều tương tác khó được gợi ý hơn" vì thế chỉ đúng khi gắn với một thước đo và một mức dữ liệu cụ thể.



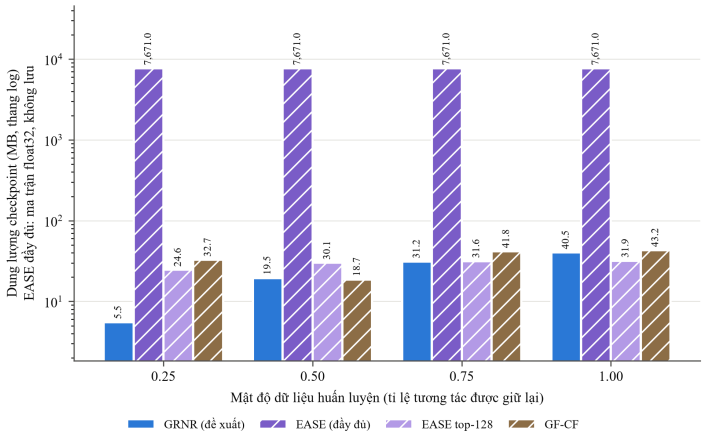
Hình 5.14: Recall@20 theo độ dài lịch sử, nhóm giải trực tiếp

5.1.6 Chi phí tính toán

Về thời gian, với toàn bộ dữ liệu GRNR mất 2,5 phút để khớp mô hình, EASE 11,2 phút và GF-CF 45,2 phút. Các con số này lẫn với khác biệt phần cứng, vì GRNR được giải trên CPU một luồng của máy có GPU còn EASE và GF-CF chạy trên máy chỉ có CPU; chúng mô tả chi phí trong môi trường của dự án, không phải tốc độ của bản thân thuật toán.

Dung lượng lưu trữ thì không phụ thuộc máy chạy, và hình 5.15 cho thấy khoảng cách ở đây lên tới hai bậc. Ma trận đầy đủ của EASE ở dạng float32 chiếm khoảng 7.671 MiB, theo ước tính vì ma trận này không được lưu, gấp khoảng 190 lần checkpoint 40,5 MiB của GRNR. Khoảng cách này còn lớn dần theo quy mô danh mục: bộ nhớ của EASE tăng theo bình phương số sản phẩm, còn của GRNR tăng tuyến tính vì mỗi sản phẩm giữ tối đa 128 hệ số (Mục 3.4). Ngoại suy cho một danh mục lớn gấp 10 lần, EASE đầy đủ sẽ cần khoảng 750 GiB, trong khi GRNR chỉ cần khoảng 0,4 GiB. Cắt EASE xuống top-128 đưa dung lượng về cùng cỡ với GRNR, nhưng như đã thấy, bản cắt kém GRNR ở ba trong bốn mức dữ liệu và kém EASE đầy đủ ở cả

bốn mức. GF-CF vừa chậm nhất vừa yếu nhất nhóm, nên trong thiết lập này không có đánh đổi nào có lợi cho nó.



Hình 5.15: Dung lượng lưu trữ, nhóm giải trực tiếp

Thời gian suy luận đã ghi lại của GRNR trên CPU là khoảng 0,38 ms mỗi người dùng với toàn bộ dữ liệu và 0,88–0,90 ms ở ba mức còn lại, tức không giảm theo lượng dữ liệu. Đây là trung bình khi chấm điểm theo lô, chịu ảnh hưởng của cách thực thi và môi trường chạy; vì không có số đo cùng điều kiện cho EASE và GF-CF, báo cáo không kết luận về thứ tự tốc độ suy luận trong nhóm.

Tóm lại, khi dữ liệu còn đủ dày, từ ba phần tư trở lên, GRNR cho chất lượng chưa phân biệt được với EASE đầy đủ với dung lượng nhỏ hơn hai bậc, và tốt hơn cách cắt EASE với cùng ngân sách. Khi dữ liệu thưa, ưu điểm này mất ý nghĩa, vì cả nhóm cùng cạn tín hiệu đồng xuất hiện và rơi xuống dưới mốc độ phổ biến; kết quả bất lợi khi còn một nửa dữ liệu cũng cho thấy GRNR không phải lúc nào cũng thắng EASE đầy đủ.

5.2 Diffusion-Filtered History Factorization so với các mô hình cần huấn luyện

Ba baseline của nhóm này cùng dùng bộ mã hóa LightGCN, tức cùng một kiến trúc lan truyền trên đồ thị với vector riêng cho mỗi người dùng. Chúng chỉ khác nhau ở hàm mục tiêu: BPR (LightGCN), BPR cộng học tương phản (XSimGCL), và căn chỉnh–đồng đều (DirectAU). DFHF khác cả ba ở hai điểm cơ bản: không có vector người dùng, và huấn luyện bằng softmax trên toàn danh mục. Câu hỏi của mục này là các khác biệt đó đem lại gì, và mất gì.

5.2.1 Chất lượng xếp hạng khi có đủ dữ liệu

d	Mô hình	NDCG@10	NDCG@20	Recall@10	Recall@20
1	DFHF	**0,02946**	**0,03519**	**0,05217**	**0,07500**
	LightGCN	0,02173	0,02655	0,03998	0,05912
	XSimGCL	0,02721	0,03292	0,04905	0,07173
	DirectAU	0,02666	0,03205	0,04781	0,06925
0,75	DFHF	**0,02400**	**0,02901**	**0,04269**	**0,06261**
	LightGCN	0,01814	0,02261	0,03346	0,05122
	XSimGCL	0,02288	0,02759	0,04077	0,05948
	DirectAU	0,02238	0,02698	0,03960	0,05789
0,5	DFHF	**0,01824**	**0,02266**	**0,03377**	**0,05133**
	LightGCN	0,01455	0,01839	0,02764	0,04298
	XSimGCL	0,01596	0,01933	0,02881	0,04223
	DirectAU	0,01700	0,02050	0,03022	0,04418
0,25	DFHF	**0,01359**	**0,01766**	**0,02608**	**0,04220**
	LightGCN	0,00676	0,00842	0,01199	0,01857
	XSimGCL	0,00913	0,01117	0,01725	0,02535
	DirectAU	0,00849	0,01029	0,01517	0,02235

Bảng 5.6: Chất lượng xếp hạng, nhóm cần huấn luyện

Theo bảng 5.6, với toàn bộ dữ liệu, DFHF dẫn đầu nhóm với NDCG@20 bằng 0,03519, hơn XSimGCL 6,9%, DirectAU 9,8% và LightGCN 32,5%, và theo bảng 5.7, cả ba chênh lệch đều có khoảng tin cậy nằm hẳn trên 0.

Thứ tự giữa các baseline cũng đáng chú ý. LightGCN, chỉ dùng BPR, là mô hình yếu nhất; chỉ cần thay hàm mục tiêu và giữ nguyên bộ mã hóa, XSimGCL và DirectAU đã cao hơn nó 24% và 21%. Trong nhóm này, hàm mục tiêu vì vậy có vẻ quan trọng hơn kiến trúc lan truyền. DFHF đi tiếp theo cùng hướng: softmax trên toàn danh mục so sánh sản phẩm dương với mọi sản phẩm cùng lúc, thay vì với một mẫu âm ngẫu nhiên như BPR, nên gần với thước đo xếp hạng hơn [8]. Đây là một cách giải thích phù hợp với dữ liệu nhưng chưa được kiểm chứng, vì báo cáo chưa có thí nghiệm tách đóng góp của hàm mất mát, bộ lọc khuếch tán và cách biểu diễn bằng lịch sử.

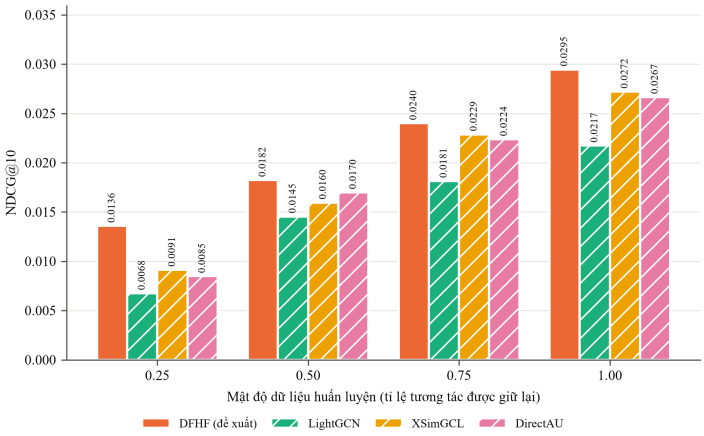
d	So sánh	Δ NDCG@20	KTC 95%	p_{Holm} (một phía)
1	DFHF − LightGCN	+0,00864	[+0,00802; +0,00928]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00228	[+0,00172; +0,00284]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00314	[+0,00251; +0,00378]	$\leq 3 \cdot 10^{-4}$
0,75	DFHF − LightGCN	+0,00640	[+0,00582; +0,00699]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00142	[+0,00086; +0,00201]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00203	[+0,00142; +0,00266]	$\leq 3 \cdot 10^{-4}$
0,5	DFHF − LightGCN	+0,00427	[+0,00376; +0,00479]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00333	[+0,00273; +0,00392]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00216	[+0,00152; +0,00281]	$\leq 3 \cdot 10^{-4}$
0,25	DFHF − LightGCN	+0,00924	[+0,00867; +0,00982]	$\leq 3 \cdot 10^{-4}$
	DFHF − XSimGCL	+0,00649	[+0,00596; +0,00706]	$\leq 3 \cdot 10^{-4}$
	DFHF − DirectAU	+0,00737	[+0,00674; +0,00802]	$\leq 3 \cdot 10^{-4}$

Bảng 5.7: Kiểm định NDCG@20, nhóm cần huấn luyện

Hai giới hạn của giao thức có thể khiến các chênh lệch này lớn hơn thực tế. Thứ nhất, checkpoint của mọi mô hình được chọn trên chính tập xác thực dùng để báo cáo. Thứ hai, DirectAU đạt điểm cao nhất ở epoch cuối cùng khi dùng toàn bộ dữ liệu, ở epoch 113 khi còn ba phần tư, và ở epoch 195 và 181 khi còn một nửa và một phần tư. Ở ba trong bốn mức, đỉnh nằm sát cuối quá trình huấn luyện, nên nhiều khả năng mô hình này chưa hội tụ trong 200 epoch và chênh lệch giữa DFHF với nó có thể bị phóng đại. Kiểm định của nhóm này cũng được thực hiện sau khi đã xem điểm trung bình, nên mang tính khám phá.

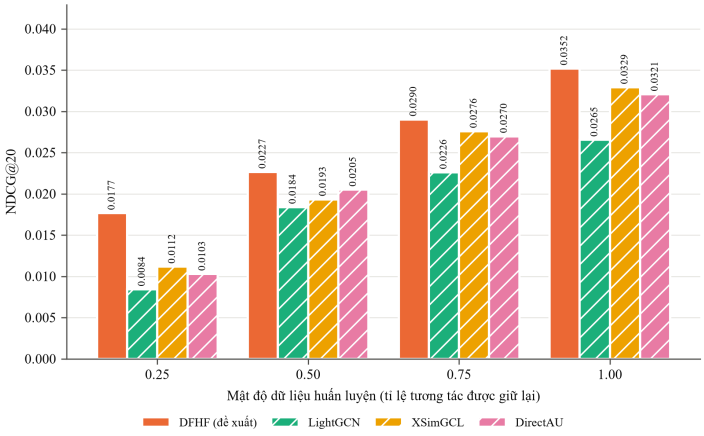
5.2.2 Chất lượng theo thước đo và độ dài danh sách

Hình 5.16 cho thấy khi bớt dần dữ liệu, DFHF vẫn giữ vị trí đầu, nhưng khoảng cách với baseline mạnh nhất co giãn theo lượng dữ liệu. Ở NDCG@10, DFHF hơn XSimGCL 8,3% với toàn bộ dữ liệu, rồi khoảng cách thu hẹp còn 4,9% khi còn ba phần tư. Khi còn một nửa, đối thủ gần nhất đổi thành DirectAU và DFHF hơn nó 7,3%. Đến mức một phần tư, khoảng cách bỗng giãn ra tới 48,8%. Một bước nhảy đột ngột như vậy là dấu hiệu cần được giải thích, chứ chưa phải bằng chứng rằng DFHF học tốt hơn hẳn. LightGCN thấp nhất ở mọi mức.



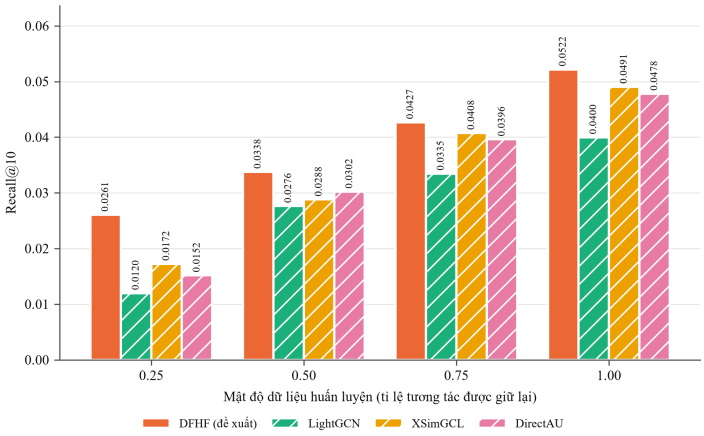
Hình 5.16: NDCG@10 theo mức d, nhóm cần huấn luyện

NDCG@20 ở hình 5.17 giữ nguyên thứ tự đó: DFHF hơn baseline mạnh nhất từ 5% đến 11% ở ba mức đầu và tới 58% ở mức thưa nhất. Điều thay đổi theo lượng dữ liệu là thứ tự giữa các baseline. XSimGCL đứng thứ hai khi dữ liệu còn dày, nhường chỗ cho DirectAU khi còn một nửa, rồi lấy lại vị trí đó ở mức một phần tư; so sánh trên tập đầy đủ vì vậy chưa nói hết hành vi của các mô hình khi dữ liệu thưa.



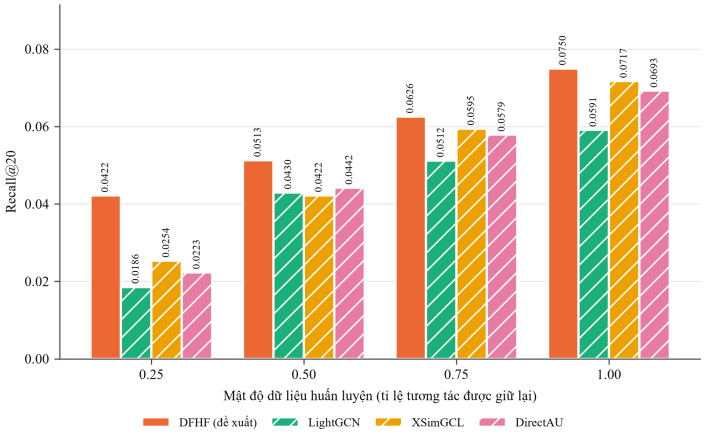
Hình 5.17: NDCG@20 theo mức d, nhóm cần huấn luyện

Recall@10 ở hình 5.18 kể cùng câu chuyện: DFHF hơn XSimGCL 6,4% với toàn bộ dữ liệu, hơn DirectAU 11,7% khi còn một nửa, và hơn XSimGCL 51% khi còn một phần tư. Ở mức thưa nhất, khoảng cách này gần bằng khoảng cách theo NDCG@10, tức ưu thế của DFHF không dồn về phần cuối của mười vị trí đầu.



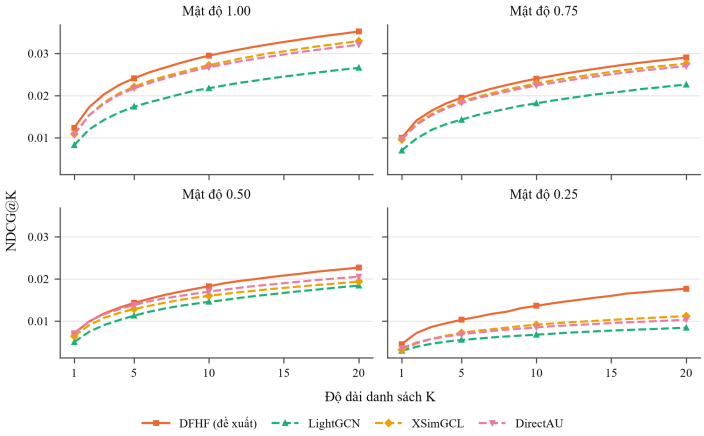
Hình 5.18: Recall@10 theo mức d, nhóm cần huấn luyện

Ở Recall@20, hình 5.19 cho thấy khoảng cách với toàn bộ dữ liệu nhỏ nhất trong bốn thước đo, chỉ 4,6%, còn ở mức thưa nhất lại lớn nhất, tới 66%. Đây cũng là thước đo duy nhất mà LightGCN vượt được XSimGCL, khi còn một nửa dữ liệu, dù LightGCN thấp nhất theo NDCG ở cùng mức. Thứ tự giữa các baseline vì thế phụ thuộc vào cả thước đo lẫn lượng dữ liệu.



Hình 5.19: Recall@20 theo mức d, nhóm cần huấn luyện

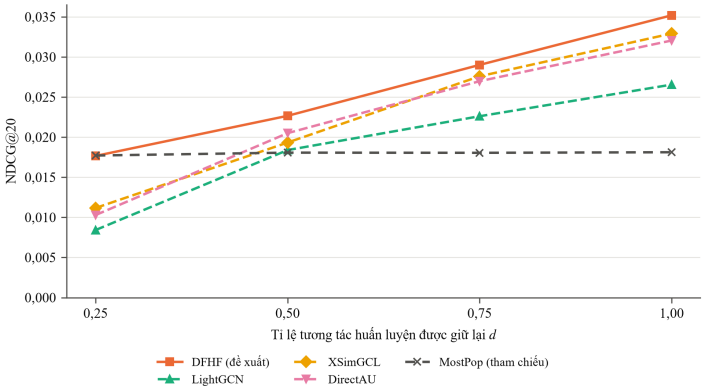
Đường NDCG@K ở hình 5.20 cho biết ưu thế của DFHF nằm ở đâu trong danh sách. Với toàn bộ dữ liệu, khoảng cách tương đối giữa DFHF và XSimGCL lớn nhất ngay ở gợi ý đầu tiên, 13,7%, rồi thu hẹp dần còn 6,9% ở vị trí thứ 20; ưu thế của DFHF khi đủ dữ liệu vì vậy tập trung ở đầu danh sách. Khi còn một nửa, DirectAU nhỉnh hơn ở vị trí đầu tiên và DFHF chỉ vượt lên từ khoảng vị trí thứ ba. Khi còn một phần tư, đường của DFHF tách hẳn khỏi ba baseline ngay từ đầu. Các điểm được tính lại từ danh sách dự đoán của từng người dùng và khớp với số liệu tổng hợp ở $K = 10$ và $K = 20$; đây là phân tích mô tả, không chọn lại checkpoint cho từng K.



Hình 5.20: NDCG@K, nhóm cần huấn luyện

5.2.3 Chất lượng khi dữ liệu thưa dần

Những hình trên dễ dẫn tới kết luận rằng DFHF bền hơn hẳn khi dữ liệu thưa. Hình 5.21 đặt NDCG@20 của cả nhóm cạnh mốc MostPop: DFHF cao nhất ở mọi mức với khoảng tin cậy không chứa 0 theo bảng 5.7, và khoảng cách với baseline tốt nhất lớn dần khi dữ liệu thưa đi. Nhưng chính mốc MostPop cho thấy cách hiểu "bền hơn" là chưa đúng.



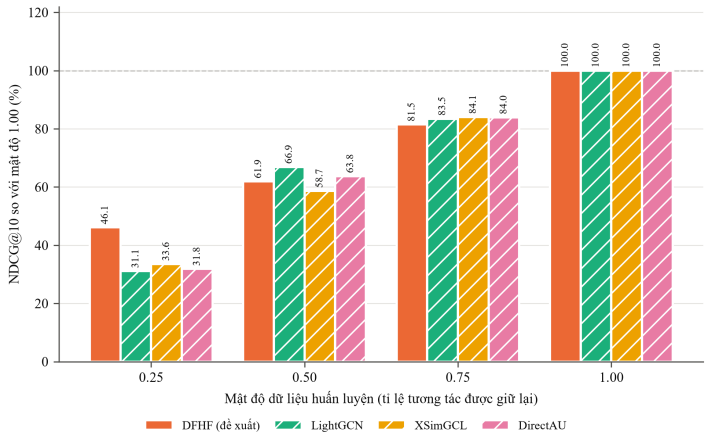
Hình 5.21: NDCG@20 so với MostPop, nhóm cần huấn luyện

Mức vượt MostPop ở bảng 5.8 làm rõ điều đó. Mức vượt của DFHF giảm đều từ 94% xuống 61%, 25% rồi $-0{,}3\%$, nghĩa là ở mức thưa nhất DFHF chỉ còn ngang mốc độ phổ biến, thấp hơn 0,3%, một chênh lệch chưa được kiểm định. Ba baseline thì rơi hẳn xuống dưới, kém MostPop từ 37% đến 53%. Khoảng cách 58% ở mức thưa nhất vì thế không phản ánh khả năng cá nhân hóa tốt hơn, mà phản ánh việc DFHF dừng lại gần mốc độ phổ biến trong khi các baseline tụt xuống dưới, và gợi ý cần xem xét vai trò của hệ số chặn khi lịch sử quá ngắn.

	$d = 1$	$d = 0{,}75$	$d = 0{,}5$	$d = 0{,}25$
MostPop (NDCG@20)	0,01812	0,01805	0,01807	0,01771
DFHF	+94,2%	+60,7%	+25,4%	−0,3%
LightGCN	+46,5%	+25,3%	+1,8%	−52,5%
XSimGCL	+81,7%	+52,9%	+7,0%	−36,9%
DirectAU	+76,9%	+49,5%	+13,4%	−41,9%

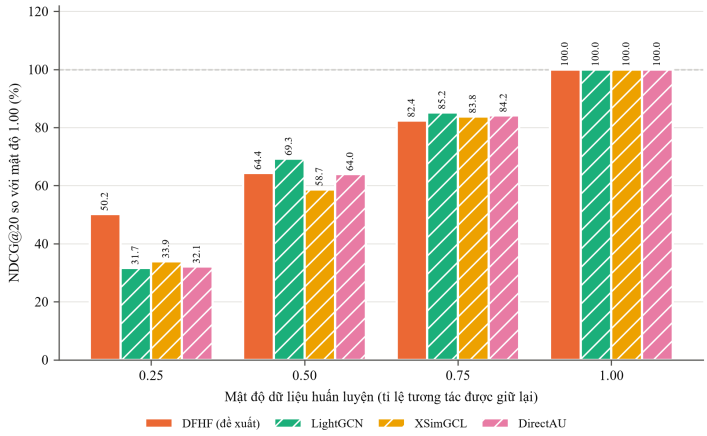
Bảng 5.8: Mức vượt MostPop, nhóm cần huấn luyện

Tỉ lệ duy trì đi tới cùng kết luận từ một góc khác. Theo NDCG@10 ở hình 5.22, DFHF không suy giảm chậm hơn các baseline khi dữ liệu còn khá dày: còn ba phần tư dữ liệu, nó giữ 81,5%, thấp nhất nhóm, và còn một nửa thì xếp sau LightGCN và DirectAU. Chỉ ở mức một phần tư, DFHF mới tách hẳn lên, giữ 46,1% so với khoảng một phần ba ở ba baseline. Sự bền vững của DFHF vì thế chỉ xuất hiện ở mức thưa nhất, đúng nơi điểm số của nó chạm mốc MostPop.



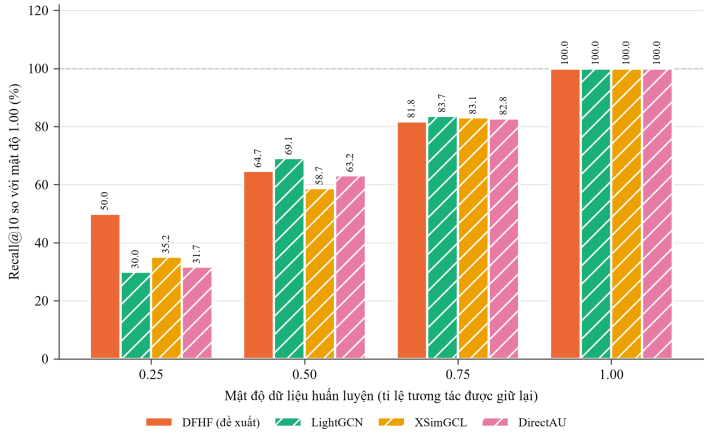
Hình 5.22: Tỉ lệ duy trì NDCG@10, nhóm cần huấn luyện

Theo NDCG@20 ở hình 5.23, DFHF giữ 50,2% chất lượng ban đầu ở mức thưa nhất, so với khoảng một phần ba ở các baseline; nhưng khi còn một nửa dữ liệu, LightGCN lại giữ tốt nhất, 69,3% so với 64,4% của DFHF, chỉ vì nó xuất phát từ mức thấp hơn. Khi các mô hình có điểm khởi đầu và mức sàn khác nhau như ở bảng 5.8, so sánh tỉ lệ duy trì không cho biết mô hình nào học tốt hơn.



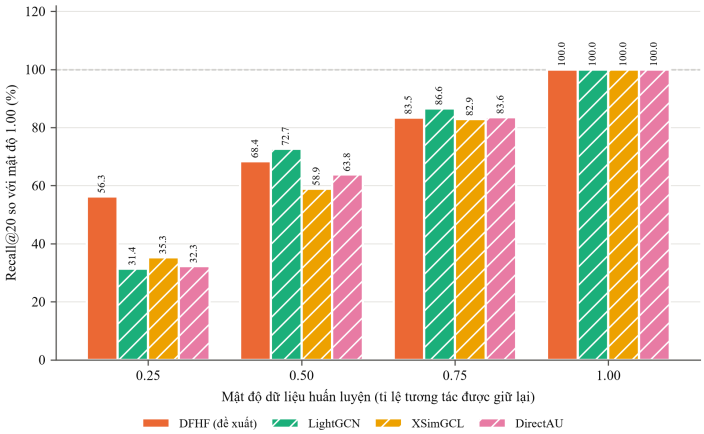
Hình 5.23: Tỉ lệ duy trì NDCG@20, nhóm cần huấn luyện

Recall@10 ở hình 5.24 lặp lại cùng mẫu hình: LightGCN giữ nhiều nhất khi còn một nửa dữ liệu, còn DFHF chỉ vượt lên ở mức một phần tư, giữ 50,0% so với 30–35% của các baseline. Việc giữ được một phần chất lượng không tự phân biệt đóng góp của lịch sử với hệ số chặn; muốn biết mô hình làm gì khi thiếu lịch sử, cần đối chiếu với MostPop và với nhóm người dùng chỉ còn một tương tác.



Hình 5.24: Tỉ lệ duy trì Recall@10, nhóm cần huấn luyện

Với DFHF, Recall@20 ở hình 5.25 cho tỉ lệ duy trì cao nhất trong bốn thước đo, 56,3% ở mức thưa nhất, trong khi các baseline giữ khoảng một phần ba. LightGCN vẫn giữ nhiều nhất ở hai mức ba phần tư và một nửa. Việc Recall@20 của DFHF giữ được nhiều hơn NDCG@20 ở mức thưa nhất, 56,3% so với 50,2%, cho thấy mô hình vẫn đưa được mục tiêu vào danh sách, nhưng ở vị trí thấp hơn trước.



Hình 5.25: Tỉ lệ duy trì Recall@20, nhóm cần huấn luyện

5.2.4 Nguồn tín hiệu khi dữ liệu thưa

Mức sàn gần MostPop của DFHF có cơ chế đã mô tả ở Mục 3.3.1. Người dùng chỉ còn một tương tác nhận vector lịch sử bằng 0, nên được xếp hạng chỉ bằng hệ số chặn b, tức một thứ tự chung do vector chặn đã học quyết định, không nhất thiết trùng MostPop. Ở mức thưa nhất, nhóm này chiếm 68% người dùng warm. Bảng 5.9 xác nhận trực tiếp: trên người dùng bậc 1, DFHF đạt 0,01787, gần như trùng MostPop (0,01789). Các baseline thì phải học một vector người dùng từ đúng một tương tác; vector đó nhiễu và cho xếp hạng kém cả độ phổ biến.

Mô hình	Bậc 1 ($n = 72.944$)	Bậc ≥ 2 ($n = 34.271$)	Tất cả
DFHF	0,01787	0,01720	0,01766
LightGCN	0,00849	0,00826	0,00842
XSimGCL	0,01132	0,01084	0,01117
DirectAU	0,01023	0,01043	0,01029
MostPop (tham chiếu)	0,01789	0,01733	0,01771

Bảng 5.9: NDCG@20 theo số tương tác còn lại ($d = 0{,}25$)

Ngay cả với người dùng còn từ hai tương tác trở lên, DFHF (0,01720) cũng chưa vượt MostPop (0,01733). Ở mức thưa này, vì vậy, chưa có bằng chứng rằng DFHF khai thác lịch sử tốt hơn một cách xếp hạng không cá nhân hóa. Kết quả gợi ý rằng khi dữ liệu rất thưa, một phương án dự phòng tốt có thể quan trọng hơn khả năng biểu diễn của mô hình; nhận định này chưa được kiểm tra bằng cách cho baseline dùng cùng phương án dự phòng.

Nếu phần lớn người dùng được xếp hạng chỉ bằng hệ số chặn, danh sách gợi ý của DFHF phải tập trung hơn vào sản phẩm phổ biến khi dữ liệu thưa, và bảng 5.10 cho

thấy đúng như vậy. Từ toàn bộ dữ liệu xuống mức một phần tư, độ phổ biến trung bình sau biến đổi log của các sản phẩm DFHF gợi ý tăng từ 5,84 lên 7,10, còn độ phủ danh mục trong top-20 giảm từ 32,0% xuống 12,9%. Xu hướng tập trung này không riêng DFHF có: độ phổ biến của XSimGCL cũng tăng từ 5,82 lên 6,46, và độ phủ của LightGCN giảm từ 47,0% xuống 7,5%. Điểm riêng của DFHF là mức tập trung cao nhất nhóm, đi cùng NDCG@20 sát MostPop thay vì thấp hơn. Bảng chưa tách được ảnh hưởng của hệ số chặn, biểu diễn lịch sử và tập sản phẩm ứng viên, và cũng chưa có độ phổ biến của chính MostPop để biết 7,10 đã gần thứ tự độ phổ biến đến đâu.

DirectAU đi theo chiều ngược lại: độ phủ tăng từ 11,9% lên 38,7% dù NDCG@20 giảm. Cùng với diễn biến độ phổ biến, kết quả này cho thấy phạm vi sản phẩm được gợi ý và khả năng đưa đúng mục tiêu lên đầu là hai khía cạnh khác nhau; không thể dùng riêng độ phủ để xếp hạng chất lượng các mô hình.

	$d = 1$	$d = 0{,}75$	$d = 0{,}5$	$d = 0{,}25$
Độ phổ biến trung bình (log)				
DFHF	5,84	6,10	6,67	7,10
LightGCN	5,91	6,18	6,46	6,07
XSimGCL	5,82	5,89	6,02	6,46
DirectAU	5,64	5,66	5,75	5,47
Độ phủ danh mục trong top-20 (%)				
DFHF	32,0	30,8	21,1	12,9
LightGCN	47,0	33,7	26,8	7,5
XSimGCL	6,8	6,7	5,9	2,6
DirectAU	11,9	13,8	18,3	38,7

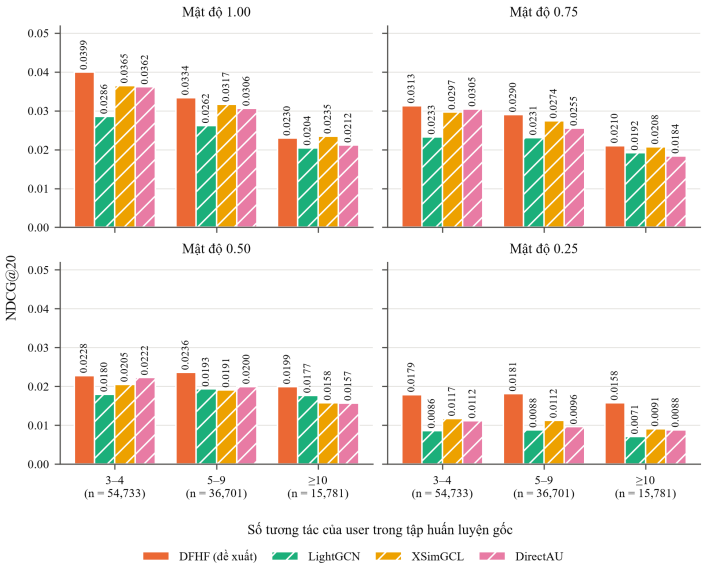
Bảng 5.10: Độ phổ biến và độ phủ, nhóm cần huấn luyện

5.2.5 Chất lượng theo độ dài lịch sử người dùng

Khi chia người dùng theo độ dài lịch sử như ở hình 5.26, hiện tượng người dùng nhiều tương tác được gợi ý kém hơn lại xuất hiện. Với toàn bộ dữ liệu, NDCG@20 của DFHF giảm từ 0,0399 ở nhóm lịch sử ngắn nhất xuống 0,0230 ở nhóm dài nhất, và cả ba baseline có cùng xu hướng; hiện tượng này như vậy lặp lại ở cả tám mô hình của hai nhóm. Điểm riêng ở đây là với người dùng có từ 10 tương tác trở lên, XSimGCL nhỉnh hơn DFHF. Một giả thuyết là DFHF gộp cả lịch sử thành một vector duy nhất bằng phép cộng chuẩn hóa; với lịch sử dài và đa dạng, phép gộp này làm mờ các sở thích khác nhau, trong khi một vector người dùng được học riêng có thể giữ chúng tốt hơn.

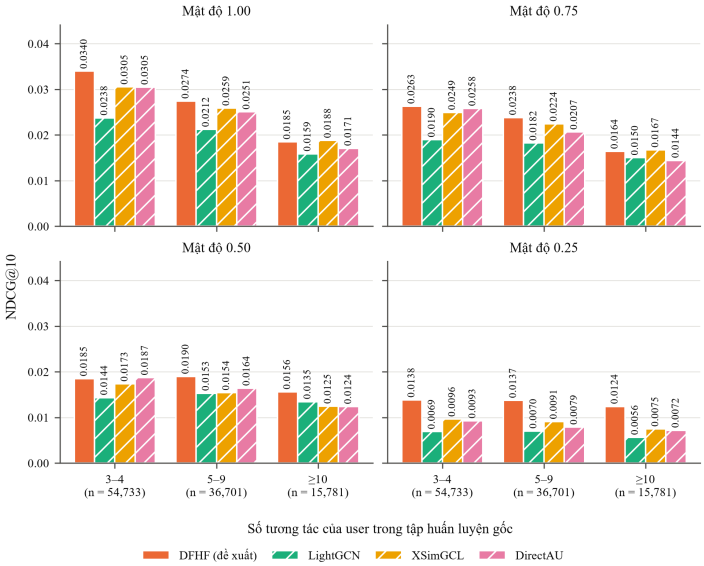
Khi dữ liệu thưa đi, DFHF lại dẫn ở cả ba nhóm người dùng tại mọi mức từ ba

phần tư trở xuống. Ở mức thưa nhất, NDCG@20 của DFHF ở nhóm 3–4 và 5–9 gần như bằng nhau (0,0179 và 0,0181): khi phần lớn người dùng được xếp hạng chủ yếu bằng hệ số chặn, độ dài lịch sử gốc không còn tạo ra nhiều khác biệt. Các nhóm giữ nguyên ở mọi mức dữ liệu, và các giá trị theo nhóm chỉ mang tính mô tả.



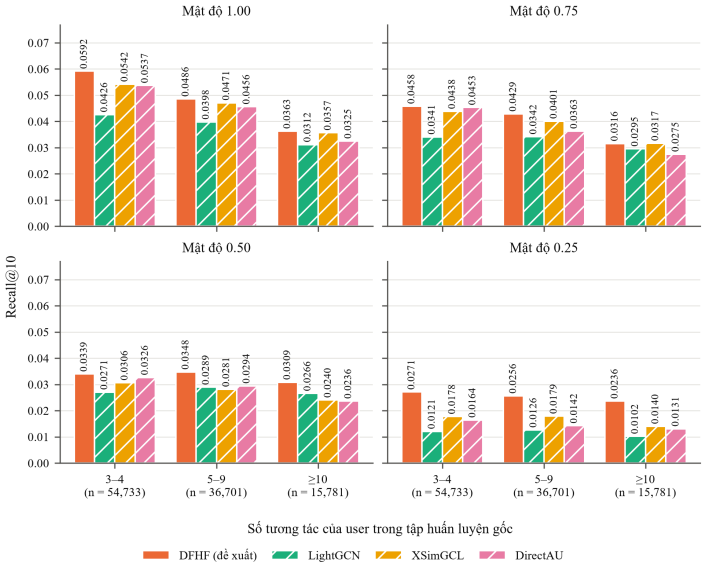
Hình 5.26: NDCG@20 theo độ dài lịch sử, nhóm cần huấn luyện

Khi thu hẹp về mười vị trí đầu ở hình 5.27, DFHF không còn dẫn ở mọi nhóm. Với người dùng lịch sử dài nhất, XSimGCL nhỉnh hơn DFHF ở cả hai mức dữ liệu dày dù thua theo NDCG@20; khi còn một nửa dữ liệu, DirectAU nhỉnh hơn DFHF ở nhóm lịch sử ngắn nhất. Các khoảng cách này đều nhỏ, dưới 2%. Chỉ ở mức một phần tư, DFHF mới dẫn ở cả ba nhóm với khoảng cách lớn, hơn baseline tốt nhất ở mỗi nhóm ít nhất 40%. Điểm trung bình cao nhất vì thế không có nghĩa DFHF cao nhất ở mọi nhóm và mọi phần của danh sách.



Hình 5.27: NDCG@10 theo độ dài lịch sử, nhóm cần huấn luyện

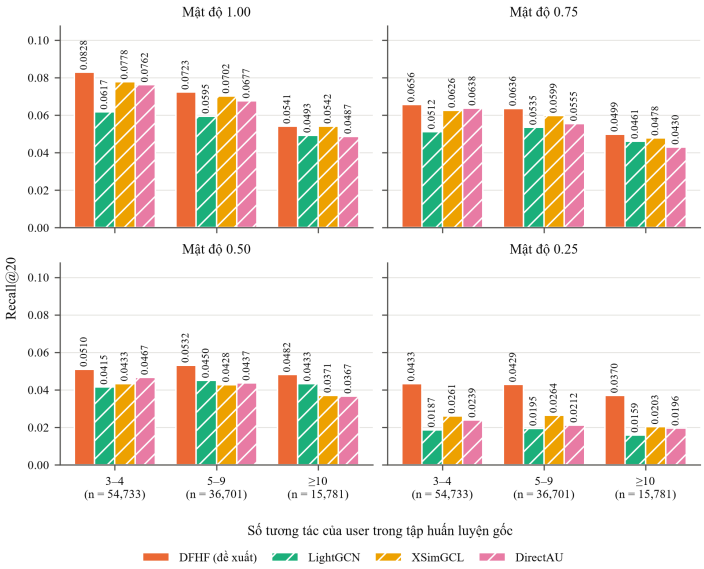
Recall@10 ở hình 5.28 cho biết ưu thế của DFHF đến từ đâu. Với toàn bộ dữ liệu, DFHF dẫn ở cả ba nhóm, nhưng khoảng cách với XSimGCL lớn nhất ở nhóm lịch sử ngắn nhất, hơn 9%, và gần như biến mất ở nhóm dài nhất; khi còn ba phần tư, XSimGCL còn nhỉnh hơn ở nhóm dài nhất. Ưu thế trung bình của DFHF như vậy chủ yếu đến từ người dùng lịch sử ngắn, cũng là nhóm đông nhất, còn với người dùng lịch sử dài, DFHF và XSimGCL gần như ngang nhau khi dữ liệu còn dày.



Hình 5.28: Recall@10 theo độ dài lịch sử, nhóm cần huấn luyện

Ở Recall@20, hình 5.29 cho thấy DFHF vẫn giảm theo độ dài lịch sử khi dùng toàn bộ dữ liệu, từ 0,083 xuống 0,054, và ở nhóm dài nhất XSimGCL gần như bằng

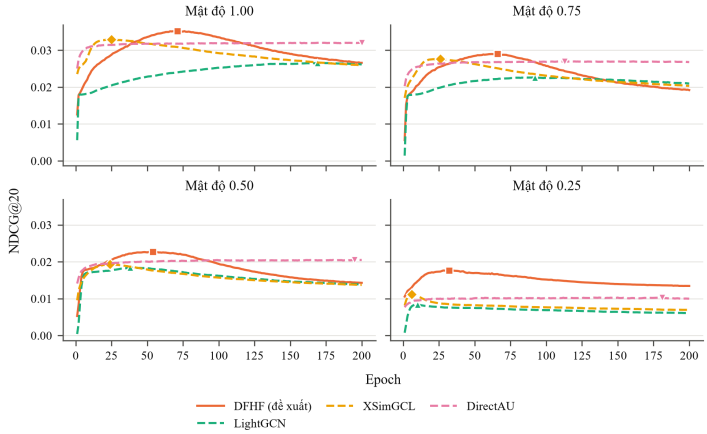
DFHF. Khi còn một nửa, xu hướng này không còn đơn điệu: Recall@20 của DFHF ở nhóm 5–9 cao hơn nhóm 3–4, và của LightGCN ở nhóm lịch sử dài nhất cao hơn nhóm ngắn nhất, giống chiều đảo đã thấy ở nhóm giải trực tiếp. Các hình Recall đo khả năng tìm đúng mục tiêu, chưa đo mức độ hữu ích của những sản phẩm phù hợp khác không trùng với mục tiêu xác thực.



Hình 5.29: Recall@20 theo độ dài lịch sử, nhóm cần huấn luyện

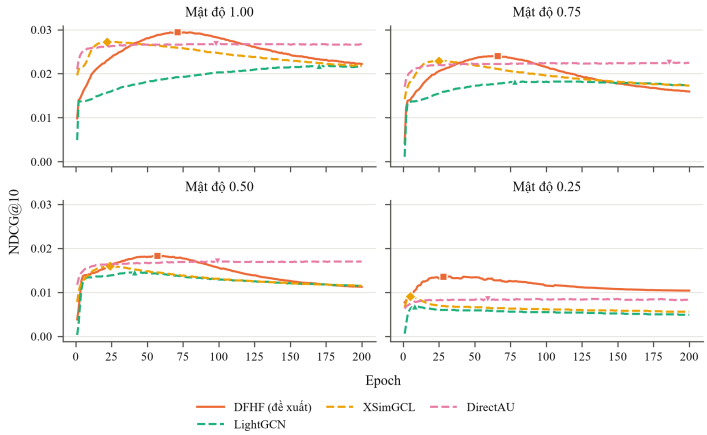
5.2.6 Quá trình huấn luyện và chi phí tính toán

Đường học ở hình 5.30 chia nhóm thành hai kiểu hành vi. DFHF và XSimGCL học nhanh rồi quá khớp: với toàn bộ dữ liệu, DFHF đạt đỉnh NDCG@20 ở epoch 71 rồi giảm dần, đến epoch 200 thấp hơn đỉnh 24,5%; XSimGCL đạt đỉnh còn sớm hơn, ở epoch 25, rồi giảm 21,4%; các số này được tổng hợp ở bảng 5.11. LightGCN và DirectAU thì học chậm và gần như không giảm. Khi dữ liệu thưa đi, đỉnh của DFHF và LightGCN đến sớm hơn: DFHF đạt đỉnh ở epoch 66, 54 và 32 tại ba mức thưa, còn LightGCN, vốn đạt đỉnh ở epoch 169, đạt đỉnh ngay ở epoch 10 khi chỉ còn một phần tư dữ liệu rồi giảm 28%. XSimGCL vẫn đạt đỉnh quanh epoch 24–26 cho đến mức một nửa, và ở epoch 6 tại mức thưa nhất. DirectAU thì ngược lại, đạt đỉnh gần cuối quá trình huấn luyện, phù hợp với nhận xét rằng mô hình này chưa hội tụ trong 200 epoch.



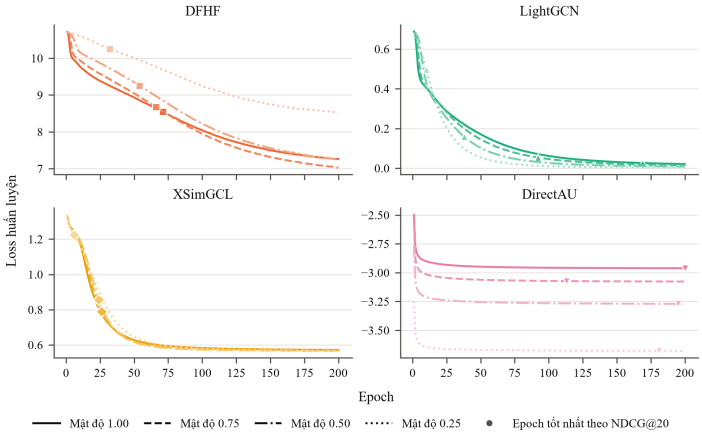
Hình 5.30: Đường học NDCG@20, nhóm cần huấn luyện

Đường học theo NDCG@10 ở hình 5.31 cho cùng hai kiểu hành vi, và ở DFHF lẫn XSimGCL, epoch đạt đỉnh chỉ chênh không quá 4 epoch so với NDCG@20. Riêng DirectAU có đỉnh NDCG@10 thường đến sớm hơn nhiều, chẳng hạn epoch 98 so với 200 khi dùng toàn bộ dữ liệu, nhưng sau đỉnh đường của nó gần như phẳng. Với DFHF, NDCG@10 giảm từ 23,5% đến 38,5% giữa đỉnh và epoch 200 ở mọi mức dữ liệu. Mức giảm không đơn điệu theo lượng dữ liệu, nhưng đủ lớn để việc dừng sớm có thể có ích ở mọi mức.



Hình 5.31: Đường học NDCG@10, nhóm cần huấn luyện

Hàm mất mát trên tập huấn luyện ở hình 5.32 cho thấy rõ hơn hiện tượng quá khớp: DFHF và XSimGCL tiếp tục giảm hàm mất mát sau khi NDCG trên tập xác thực đã qua đỉnh, nên tối ưu tốt hơn trên tập huấn luyện không bảo đảm chất lượng tốt hơn trên người dùng được đánh giá. Các ô con có trục tung riêng vì hàm mục tiêu khác nhau cả về thành phần lẫn thang giá trị, nên không thể so giá trị mất mát giữa các mô hình, và giá trị âm của DirectAU không phải lỗi tối ưu.



Hình 5.32: Hàm mất mát huấn luyện, nhóm cần huấn luyện

Hệ quả là thứ tự trong nhóm phụ thuộc vào cách chọn checkpoint. Nếu báo cáo điểm ở epoch cuối thay vì epoch tốt nhất, DFHF (0,02658) sẽ thấp hơn DirectAU (0,03205) và chỉ nhỉnh hơn LightGCN (0,02617). Vì checkpoint được chọn trên chính tập dùng để báo cáo, điểm của các mô hình đạt đỉnh rồi giảm như DFHF và XSimGCL được lợi nhiều nhất từ việc chọn này, và cần được xác nhận trên dữ liệu chưa dùng để chọn [10, 13].

Mô hình	Epoch chọn	NDCG@20 chọn	NDCG@20 cuối	Giảm	Giây/epoch
DFHF	71	0,03519	0,02658	24,5%	37,9
LightGCN	169	0,02655	0,02617	1,4%	11,2
XSimGCL	25	0,03292	0,02587	21,4%	17,7
DirectAU	200	0,03205	0,03205	0%	24,1

Bảng 5.11: Huấn luyện và chi phí ($d = 1$), nhóm cần huấn luyện

DFHF là mô hình chậm nhất nhóm: mỗi epoch mất 37,9 giây trên GPU Tesla T4, tổng khoảng 127 phút cho 200 epoch với toàn bộ dữ liệu, gấp 1,6 lần DirectAU, 2,1 lần XSimGCL và 3,4 lần LightGCN, theo bảng 5.11. Phần lớn chi phí đến từ softmax trên toàn danh mục và hai lần áp toán tử khuếch tán ở mỗi bước. Tuy vậy, đường học cho thấy phần lớn số epoch này là thừa: nếu dừng ở khoảng epoch 71, DFHF chỉ cần khoảng 45 phút, ít hơn 80 phút mà DirectAU cần cho 200 epoch. Đây chỉ là phép tính minh họa, vì điểm dừng phải được chọn trên một tập riêng và báo cáo chưa thử cách này.

Khi suy luận, cả bốn mô hình đều mất khoảng 0,01 ms cho mỗi người dùng khi chấm theo lô trên GPU Tesla T4. Điều này dễ hiểu vì cả bốn đều chấm điểm bằng tích vô hướng giữa vector người dùng và embedding sản phẩm. Chi phí thêm của DFHF

vì vậy chỉ nằm ở giai đoạn huấn luyện. Đây là trung bình theo lô, không phải độ trễ của một dịch vụ thực tế.

Tóm lại, DFHF có NDCG@20 cao nhất nhóm ở mọi mức dữ liệu. Khi dữ liệu đủ dày, ưu thế này phù hợp với giả thuyết rằng một hàm mất mát gần thước đo xếp hạng có lợi. Khi dữ liệu thưa, ưu thế chủ yếu đến từ việc DFHF dựa vào hệ số chặn và đạt gần mốc độ phổ biến, thay vì cố cá nhân hóa từ một tương tác như các baseline. Đổi lại, DFHF huấn luyện chậm nhất nhóm và nhạy với cách chọn checkpoint.

5.3 Hệ thống demo

5.3.1 Cài đặt môi trường và khởi động

Ứng dụng được xây dựng bằng Streamlit, sử dụng dữ liệu đã xử lý và checkpoint của các mô hình để tạo gợi ý. Các lệnh cài đặt được thực hiện tại thư mục gốc của dự án. Trước hết, tạo và kích hoạt môi trường Python bằng Conda:

```
conda create -n AML python=3.11
conda activate AML
```

Tiếp theo, cài các thư viện được khai báo trong requirements.txt:

```
python -m pip install -r requirements.txt
```

Sau khi đã chuẩn bị dữ liệu và các checkpoint, khởi động ứng dụng bằng lệnh:

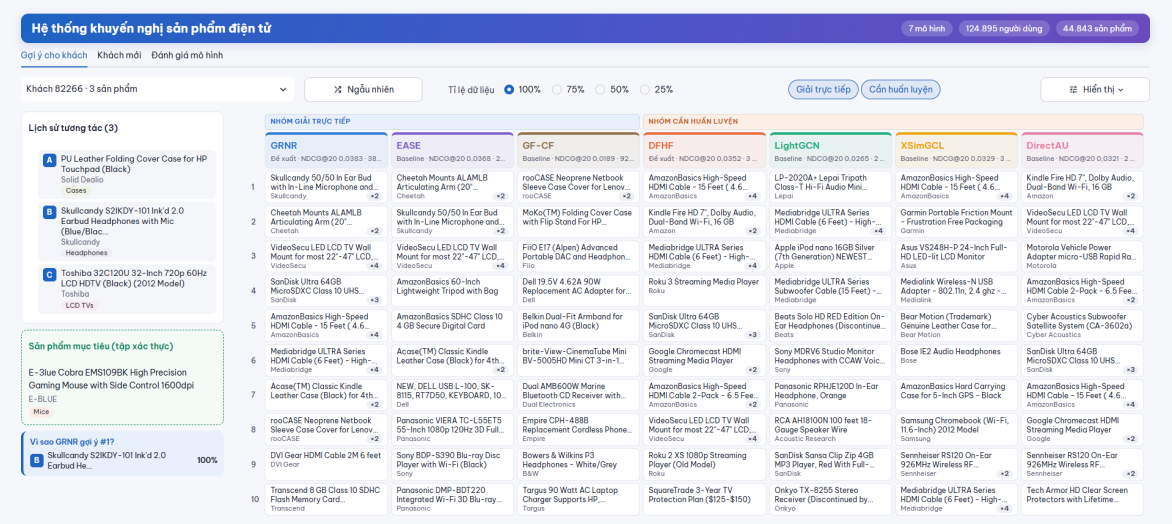
```
python -m streamlit run app/streamlit_app.py
```

Người dùng mở địa chỉ hiển thị trong cửa sổ lệnh để truy cập giao diện. Ứng dụng nạp các mô hình đã lưu, không huấn luyện lại khi đổi người dùng hoặc tỉ lệ dữ liệu. Các bảng và biểu đồ được đọc từ kết quả thực nghiệm đã lưu; dữ liệu phục vụ demo gồm tập huấn luyện, tập xác thực và thông tin mô tả sản phẩm, không sử dụng tập kiểm tra.

5.3.2 Gợi ý cho người dùng có sẵn

Thẻ “Gợi ý cho khách” cho phép chọn một người dùng trong danh sách hoặc nhấn “Ngẫu nhiên”, sau đó chọn tỉ lệ tương tác huấn luyện được giữ lại. Bên trái là lịch sử tương tác và sản phẩm mục tiêu của tập xác thực; bên phải là 10 gợi ý đầu của bảy

mô hình, mỗi mô hình một cột, thứ tự từ trên xuống tương ứng các hạng trong danh sách. Các cột được xếp theo hai nhóm như trong báo cáo: nhóm giải trực tiếp gồm GRNR, EASE và GF-CF, nhóm cần huấn luyện gồm DFHF, LightGCN, XSimGCL và DirectAU. Đầu mỗi cột ghi mô hình là đề xuất hay baseline và NDCG@20 của mô hình trên tập xác thực; cột EASE dùng bản top-128, vì ma trận đầy đủ không được lưu thành checkpoint.



Hình 5.33: Giao diện gợi ý cho người dùng có sẵn

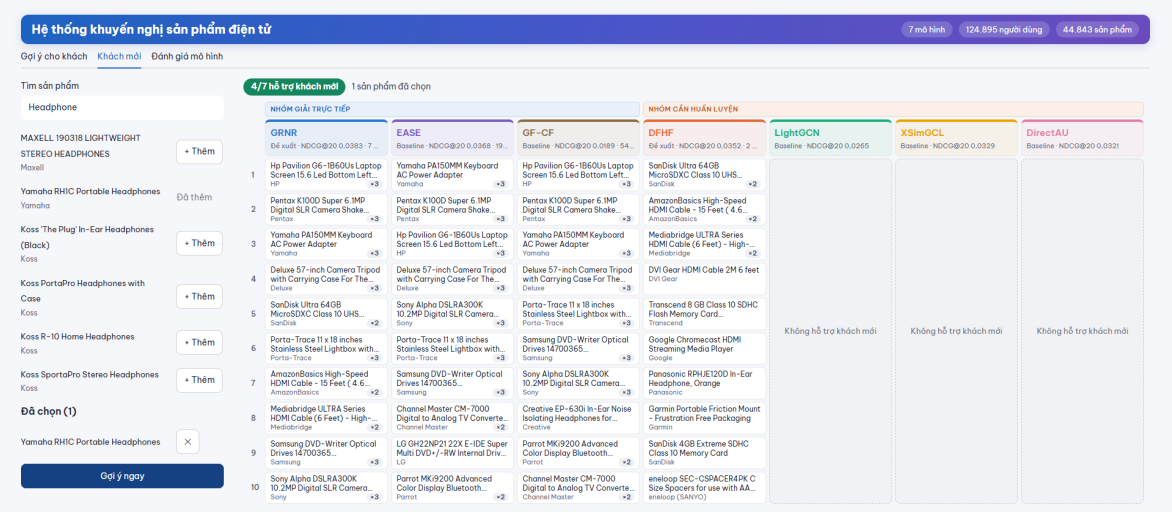
Các nút "Giải trực tiếp" và "Cần huấn luyện" giúp thu gọn số cột cần xem. Nhãn $\times k$ cạnh sản phẩm cho biết có bao nhiêu mô hình đang hiển thị cùng gợi ý sản phẩm đó; khi rê chuột lên một sản phẩm chung, các ô tương ứng được làm sáng. Sản phẩm mục tiêu, nếu có trong danh sách, được tô xanh. Nút "Hiển thị" cho phép ẩn sản phẩm không rõ tên; bộ lọc này chỉ phục vụ giao diện và cần tắt khi đối chiếu danh sách với dự đoán đã lưu. Với GRNR, ô "Vì sao GRNR gợi ý #1?" liệt kê các sản phẩm trong lịch sử có đóng góp dương vào gợi ý đầu tiên; phần này phản ánh các hệ số đã học, không xác nhận quan hệ nhân quả giữa sản phẩm.

Người dùng trong hình 5.33 có ba sản phẩm trong lịch sử: một bao da máy tính bảng, một tai nghe Skullcandy và một tivi Toshiba; sản phẩm mục tiêu là một chuột chơi game. Không mô hình nào đưa chuột này vào 10 gợi ý đầu, nên không ô nào được tô xanh. Trường hợp này không bất thường: NDCG@20 của các mô hình tốt nhất chỉ khoảng 0,035–0,038, tức phần lớn người dùng không có mục tiêu trong danh sách. Gợi ý đầu tiên của GRNR là một tai nghe Skullcandy khác, và ô giải thích cho thấy toàn bộ đóng góp dương đến từ tai nghe Skullcandy trong lịch sử. Một số sản phẩm được bốn mô hình cùng gợi ý, như giá treo tivi VideoSecu, gắn với chiếc tivi trong lịch sử, và cáp HDMI của AmazonBasics, một phụ kiện phổ biến; các mô hình

khác nhau vì thế vẫn chia sẻ một phần danh sách dù dùng cơ chế khác nhau.

5.3.3 Gợi ý từ lịch sử nhập mới

Ở thẻ "Khách mới", người dùng tìm sản phẩm theo từ khóa rồi nhấn "Thêm" để tạo lịch sử. Hình 5.34 minh họa việc tìm bằng từ khóa "Headphone" và chọn một sản phẩm. GRNR, DFHF, EASE top-128 và GF-CF có thể chấm điểm lịch sử vừa nhập; ba baseline LightGCN, XSimGCL và DirectAU hiển thị thông báo không hỗ trợ khách mới vì các cài đặt này dùng embedding của người dùng đã có trong lúc huấn luyện. Tỉ lệ dữ liệu và bộ lọc hiển thị được dùng tiếp từ thẻ "Gợi ý cho khách".



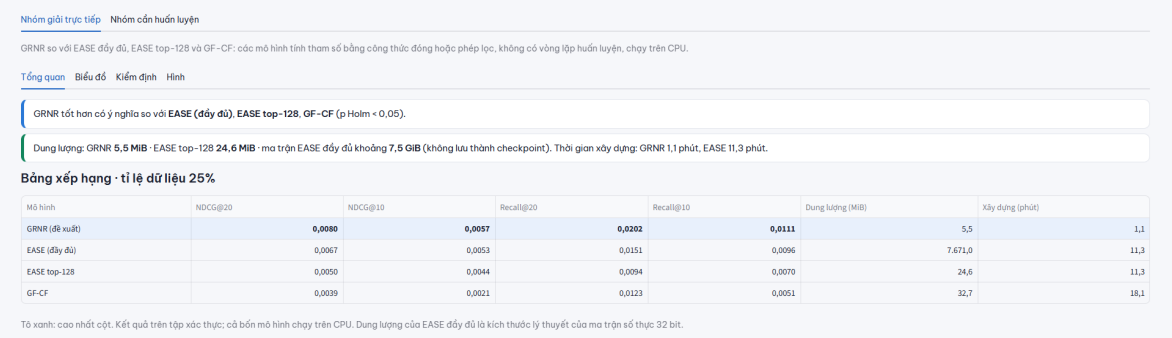
Hình 5.34: Tìm sản phẩm và tạo lịch sử cho người dùng mới

Trong hình 5.34, lịch sử chỉ gồm tai nghe Yamaha RH1C, và dòng "4/7 hỗ trợ khách mới" cho biết bốn mô hình trả về danh sách. Ba mô hình của nhóm giải trực tiếp cho danh sách gần giống nhau, với nhiều sản phẩm mang nhãn $\times 3$ như màn hình máy tính xách tay HP, máy ảnh Pentax hay chân máy ảnh Deluxe. Những sản phẩm này không cùng loại với tai nghe; chúng phản ánh đồng xuất hiện trong lịch sử của những người dùng đã tương tác với chiếc tai nghe này, đúng với cách ba mô hình xây toán tử sản phẩm–sản phẩm. Danh sách của DFHF khác hẳn, gồm thẻ nhớ SanDisk, cáp HDMI và các phụ kiện phổ biến khác. Lý do là lịch sử chỉ có một sản phẩm, nên với $\omega_1 = 0$ vector lịch sử bằng 0 và DFHF xếp hạng chỉ bằng hệ số chặn, cùng cơ chế đã phân tích với người dùng bậc 1 ở mục kết quả của nhóm cần huấn luyện.

Chức năng này minh họa khả năng nhận lịch sử mới mà không cần huấn luyện lại, chưa phải một phép đánh giá định lượng chất lượng gợi ý cho người dùng mới.

5.3.4 Tra cứu kết quả thực nghiệm

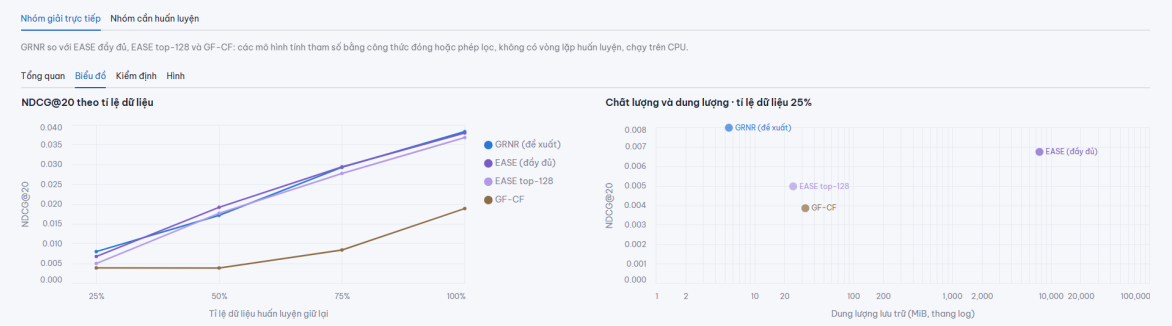
Thẻ "Đánh giá mô hình" cho phép chọn tỉ lệ dữ liệu và thước đo cần tra cứu, rồi xem kết quả theo hai thẻ con "Nhóm giải trực tiếp" và "Nhóm cần huấn luyện". Mỗi thẻ con chỉ chứa mô hình đề xuất của nhóm đó cùng các baseline cùng nhóm, nên GRNR và DFHF không xuất hiện trong cùng một bảng so sánh. Nút "Tải bảng kết quả (CSV)" xuất bảng tổng hợp các lần chạy. Mục "Tổng quan" hiển thị các nhận xét tóm tắt, chỉ số xếp hạng và chi phí tính toán; hình 5.35 minh họa màn hình của nhóm giải trực tiếp khi giữ lại 25% tương tác huấn luyện.



Hình 5.35: Màn hình tổng quan của nhóm giải trực tiếp tại tỉ lệ dữ liệu 25%

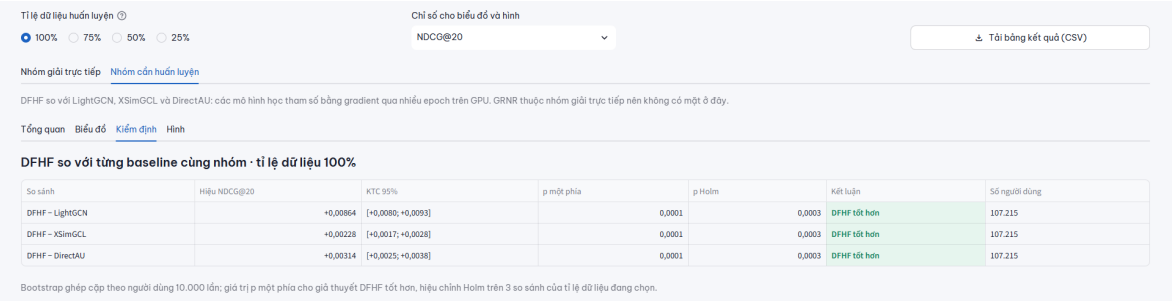
Ở mức này, GRNR có giá trị cao nhất nhóm ở cả bốn thước đo, với NDCG@20 bằng 0,0080 so với 0,0067 của EASE đầy đủ, và cao hơn có ý nghĩa thống kê so với cả ba baseline. Các số này trùng với bảng chất lượng và bảng kiểm định của nhóm giải trực tiếp. Màn hình cũng đặt chất lượng cạnh chi phí: GRNR chiếm 5,5 MiB, EASE top-128 chiếm 24,6 MiB, còn ma trận của EASE đầy đủ khoảng 7,5 GiB.

Mục "Biểu đồ" thể hiện chất lượng theo tỉ lệ dữ liệu và chất lượng theo chi phí tại mức đang chọn, như ở hình 5.36. Với nhóm giải trực tiếp, chi phí là dung lượng lưu trữ; với nhóm cần huấn luyện, chi phí là thời gian huấn luyện. Ở biểu đồ bên trái, ba mô hình hồi quy đi sát nhau trên toàn dải dữ liệu, còn GF-CF nằm thấp hẳn. Ở biểu đồ bên phải, trục dung lượng dùng thang log: tại 25% dữ liệu, GRNR nằm ở góc trên bên trái, tức chất lượng cao nhất với dung lượng nhỏ nhất nhóm, còn EASE đầy đủ nằm tận cùng bên phải. Thời gian chạy cần được đọc cùng loại thiết bị ghi trên giao diện.



Hình 5.36: Biểu đồ chất lượng theo dữ liệu và theo dung lượng, nhóm giải trực tiếp

Mục "Kiểm định" hiển thị, cho mô hình đề xuất của nhóm đang chọn so với từng baseline cùng nhóm, chênh lệch NDCG@20, khoảng tin cậy 95%, giá trị p một phía và giá trị sau hiệu chỉnh Holm trên 3 so sánh, theo đúng giao thức của báo cáo. Hình 5.37 và hình 5.38 là màn hình của nhóm cần huấn luyện khi giữ toàn bộ và 25% dữ liệu huấn luyện. Ở cả hai mức, DFHF cao hơn cả ba baseline với khoảng tin cậy không chứa 0 và $p_{\text{Holm}} = 0{,}0003$, đúng giá trị sàn đã nêu ở giao thức kiểm định. Chênh lệch ở 25% lớn hơn ở 100%, chẳng hạn $+0{,}00649$ so với $+0{,}00228$ khi so với XSimGCL; như đã phân tích ở phần kết quả của nhóm này, ưu thế ở mức thưa chủ yếu đến từ người dùng chỉ còn một tương tác. Đây là các phép tính từ dự đoán đã lưu trên tập xác thực, không phải kết quả trên một tập kiểm tra độc lập.



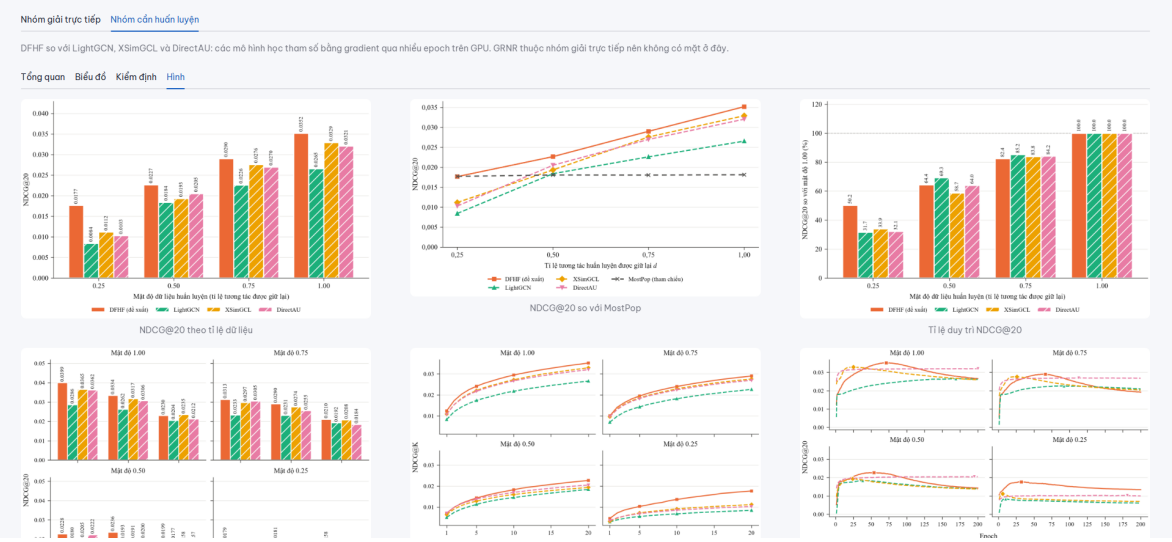
Hình 5.37: Màn hình kiểm định của nhóm cần huấn luyện tại tỉ lệ dữ liệu 100%



Hình 5.38: Màn hình kiểm định của nhóm cần huấn luyện tại tỉ lệ dữ liệu 25%

Mục "Hình" hiển thị chính các hình của báo cáo cho nhóm đang chọn và thước đo

đang chọn, như ở hình 5.39 với nhóm cần huấn luyện và NDCG@20. Các hình gồm chất lượng theo tỉ lệ dữ liệu, so sánh với MostPop, tỉ lệ duy trì, chất lượng theo độ dài lịch sử, NDCG@K, đường học và hàm mất mát; nhóm giải trực tiếp có thêm hình dung lượng lưu trữ. Nhờ đọc thẳng từ thư mục hình của báo cáo, số liệu trong ứng dụng và trong báo cáo luôn trùng nhau. Các ảnh giao diện minh họa thao tác sử dụng; hệ thống chưa được đánh giá với người dùng thật, và thời gian phản hồi trong demo chưa đại diện cho độ trễ của một dịch vụ triển khai thực tế.



Hình 5.39: Thư viện hình của nhóm cần huấn luyện trong ứng dụng

5.4 Thảo luận và hạn chế

5.4.1 Hai chế độ dữ liệu

Gộp kết quả của cả hai nhóm, dữ liệu này chia thành hai chế độ khá rõ.

- Khi dữ liệu đủ dày ($d \geq 0{,}75$), cá nhân hóa chiếm ưu thế. Ở $d = 1$, mô hình tốt nhất của mỗi nhóm đạt gần gấp đôi mốc MostPop, và các chênh lệch giữa mô hình có ý nghĩa thực tế.
- Khi dữ liệu thưa ($d \leq 0{,}5$), tín hiệu cá nhân hóa gần như biến mất. Ở $d = 0{,}5$, mức vượt MostPop của hầu hết mô hình chỉ còn trong khoảng $\pm 15\%$. Ở $d = 0{,}25$, không mô hình nào vượt mốc này.

Chuyển tiếp giữa hai chế độ trùng với hai thay đổi trong dữ liệu, thể hiện ở bảng 4.3 và bảng 5.4: tỉ lệ người dùng chỉ còn một tương tác tăng từ 6% lên 27%, còn số cặp đồng xuất hiện giảm từ 56% xuống 24% so với khi dùng toàn bộ dữ liệu. Đây là cách giải thích chung cho cả hai nhóm. Mô hình giải trực tiếp mất nguyên liệu, vì đồng

xuất hiện cạn nhanh hơn số tương tác; mô hình cần huấn luyện mất ngữ cảnh, vì phần lớn người dùng không còn lịch sử để biểu diễn. Từ cách nhìn này, câu hỏi thứ hai, về độ thưa, có câu trả lời chủ yếu là âm tính: không mô hình nào trong báo cáo, kể cả hai mô hình đề xuất, khai thác được tín hiệu cá nhân hóa ở mức thưa nhất.

5.4.2 Ý nghĩa đối với từng mô hình đề xuất

Với GRNR, giá trị thực tế nằm ở chế độ dữ liệu dày. Tại đó, GRNR thay được EASE đầy đủ mà không có bằng chứng mất chất lượng, với dung lượng nhỏ hơn hai bậc. GRNR cũng tốt hơn cách đơn giản là cắt ma trận EASE. Đây là ưu điểm có ý nghĩa khi danh mục lớn đến mức ma trận đầy đủ không còn vừa bộ nhớ. Với DFHF, giá trị nằm ở hai điểm. Thứ nhất, DFHF có điểm cao nhất nhóm khi có đủ dữ liệu, dù cần dè dặt vì baseline chưa được tinh chỉnh cân bằng. Thứ hai, DFHF đạt điểm gần mốc độ phổ biến khi dữ liệu thưa, dù ở mức thưa nhất vẫn thấp hơn MostPop khoảng 0,3%. Người dùng một tương tác nhận vector lịch sử bằng 0 nên chỉ còn điểm từ hệ số chặn, nhưng sự gần nhau về chất lượng chưa chứng minh thứ tự gợi ý giống MostPop. Một hệ thống thực tế có thể áp dụng cùng nguyên tắc cho bất kỳ mô hình nào: khi lịch sử quá ngắn, chuyển sang xếp hạng theo độ phổ biến.

5.4.3 Các giải thích cạnh tranh

Báo cáo chưa có thí nghiệm loại bỏ từng thành phần, nên các giải thích cơ chế đều là giả thuyết.

(i) DFHF vượt các baseline cùng nhóm ở $d \geq 0{,}5$ có thể nhờ softmax toàn danh mục hoặc bộ lọc khuếch tán. Nhưng cũng có thể do baseline chưa được tinh chỉnh tối ưu, nhất là DirectAU chưa hội tụ. Muốn phân biệt, cần thử DFHF với $F = I$, với BPR thay cho softmax, và tinh chỉnh baseline với cùng ngân sách.

(ii) GRNR hơn EASE top-128 có thể nhờ ước lượng lại hệ số trên tập láng giềng, hoặc nhờ trọng số mẫu và điều chuẩn đồ thị. So GRNR với một biến thể không có điều chuẩn đồ thị sẽ tách được hai yếu tố này.

(iii) So sánh giữa GRNR và EASE đầy đủ đổi chiều theo d. Điều này có thể do giới hạn láng giềng có lợi khi rất thưa nhưng bó hẹp ở mức trung bình, hoặc chỉ là nhiễu của một lần lấy mẫu ở mỗi mức d. Lặp lại việc lấy mẫu với nhiều seed sẽ cho biết chênh lệch $-0{,}00202$ ở $d = 0{,}5$ có ổn định hay không.

(iv) GRNR ít tệ nhất nhóm ở $d = 0{,}25$ có thể vì mô hình dựa nhiều hơn vào hệ số chặn. Nhưng danh sách của GRNR khi đó lại gồm các sản phẩm ít phổ biến hơn so với ở $d = 1$ theo bảng 5.5, trái với điều cách giải thích này dự đoán. Chấm

điểm GRNR chỉ bằng hệ số chặn ở $d = 0{,}25$, rồi so với mô hình đầy đủ, sẽ cho biết phần chất lượng còn lại đến từ đâu.

5.4.4 Đối chiếu với tài liệu

- Việc một xếp hạng theo độ phổ biến trở nên khó vượt khi dữ liệu thưa phù hợp với cảnh báo của Dacrema và cộng sự: các mô hình phức tạp thường không vượt được các phương pháp đơn giản được thiết lập cẩn thận [10].
- EASE đầy đủ là đối thủ khó nhất của GRNR, phù hợp với nhận định của Steck rằng mô hình tuyến tính nông này là một baseline rất mạnh [9].
- Dự án xếp hạng trên toàn bộ danh mục thay vì trên mẫu, nên tránh được sai lệch thứ tự do lấy mẫu mà Krichene và Rendle đã chỉ ra [12].
- Dự án chưa giải quyết được hai vấn đề mà Sun và cộng sự cùng Ji và cộng sự nêu ra: thời gian chỉ chính xác đến ngày, và việc dùng chung một tập để chọn cấu hình và báo cáo [13, 16].

5.4.5 Hạn chế

Các hạn chế được sắp theo loại mối đe dọa đối với kết luận.

1. Độ tin cậy nội tại.
    - Checkpoint và cấu hình được chọn trên chính tập xác thực dùng để báo cáo, nên mọi giá trị tuyệt đối đều lạc quan [26], và các mô hình có đường học đạt đỉnh rồi giảm được lợi nhiều nhất.
    - Ngân sách tinh chỉnh không cân bằng: GRNR và DFHF được tinh chỉnh trong quá trình phát triển, còn baseline dùng cấu hình cố định.
    - DirectAU có dấu hiệu chưa hội tụ.
    - GF-CF cho kết quả thấp bất thường và biến đổi không đều theo d, nên nhiều khả năng cấu hình hoặc cài đặt chưa phù hợp.
2. Độ tin cậy thống kê.
    - Mỗi mô hình và mỗi mức d chỉ chạy một lần, nên khoảng tin cậy chỉ phản ánh biến động theo người dùng.
    - Kiểm định của nhóm cần huấn luyện được thực hiện sau khi đã xem kết quả.
    - Phân tích theo nhóm người dùng và so sánh với MostPop chỉ mang tính mô tả, không hiệu chỉnh đa so sánh.

3. Khả năng khái quát.
    - Chỉ có một bộ dữ liệu.
    - Bộ lọc 5-core làm dữ liệu nghiêng về người dùng và sản phẩm hoạt động nhiều.
    - Thời gian chỉ chính xác đến ngày, và việc chia theo từng người dùng không có mốc thời gian chung, nên tập huấn luyện có thể chứa tương tác của người dùng khác xảy ra sau thời điểm cần dự đoán [16]; giao thức vì vậy không mô phỏng chặt chẽ việc dự đoán tương lai.
    - Phần tổng quan ở Chương 2 chỉ gồm các tài liệu nhóm đã đọc, không phải một tổng quan có hệ thống. Các phương pháp chỉ được nêu làm bối cảnh, gồm lọc cộng tác lân cận, SLIM, BSPM, Turbo-CF, PolyCF, FISM và Mult-VAE, không được chạy, nên chưa biết hai mô hình đề xuất đứng ở đâu so với chúng.
4. Độ đúng của phép đo.
    - Mỗi người dùng chỉ có một sản phẩm mục tiêu, nên một gợi ý phù hợp nhưng không trùng mục tiêu vẫn bị tính là sai.
    - Thời gian chạy được đo trên các máy khác nhau, nên chỉ mang tính tham khảo.

6 Kết luận và hướng phát triển

6.1 Kết luận

Báo cáo đã đề xuất và đánh giá hai mô hình khuyến nghị biểu diễn người dùng hoàn toàn bằng lịch sử tương tác, mỗi mô hình trong nhóm phương pháp của nó, trên bộ dữ liệu Amazon Electronics. Câu trả lời cho bốn câu hỏi nghiên cứu như sau.

Câu hỏi thứ nhất: chất lượng trong nhóm.

- Graph-Regularized Neighborhood Regression. Ở $d = 1$, GRNR có NDCG@20 cao nhất nhóm giải trực tiếp (0,03829). GRNR cao hơn EASE top-128 và GF-CF với khoảng tin cậy không chứa 0, nhưng chưa đủ bằng chứng để nói GRNR tốt hơn EASE đầy đủ. Kết quả có ý nghĩa nhất là so với EASE top-128, vì hai mô hình có cùng ngân sách hệ số: với cùng số hệ số, GRNR tốt hơn EASE top-128 ở ba trong bốn mức d; ở $d = 0{,}5$, GRNR thấp hơn với khoảng tin cậy nằm dưới 0. Khoảng cách với GF-CF cần đọc thận trọng, vì baseline này có dấu hiệu chưa được thiết lập đúng.
- Diffusion-Filtered History Factorization. DFHF có NDCG@20 cao nhất nhóm cần huấn luyện ở cả bốn mức d, với khoảng tin cậy không chứa 0 so với LightGCN, XSimGCL và DirectAU. Các chênh lệch này có thể bị phóng đại vì ba lý do: checkpoint được chọn trên tập xác thực, DirectAU chưa hội tụ, và baseline chưa được tinh chỉnh ngang bằng.

Câu hỏi thứ hai: ảnh hưởng của dữ liệu thưa. Đây là câu hỏi có câu trả lời chủ yếu là âm tính.

- Ở cả hai nhóm, phần chất lượng có được nhờ cá nhân hóa giảm nhanh khi bớt dữ liệu. Ở $d = 1$, mô hình tốt nhất mỗi nhóm đạt gần gấp đôi mốc độ phổ biến. Ở $d = 0{,}5$, phần lớn mô hình chỉ còn quanh mốc này. Ở $d = 0{,}25$, không mô hình nào có điểm trung bình cao hơn nó; DFHF thấp hơn 0,3%, một chênh lệch chưa được kiểm định.
- Với nhóm giải trực tiếp, báo cáo chỉ ra một nguyên nhân đo được: số cặp đồng xuất hiện giảm nhanh hơn nhiều so với số tương tác. Ở $d = 0{,}25$, tập huấn luyện còn 25% số tương tác nhưng chỉ còn 4,2% số cặp đồng xuất hiện.
- Ưu thế lớn của DFHF ở mức thưa nhất chủ yếu đến từ người dùng chỉ còn một tương tác: những người dùng này nhận vector lịch sử bằng 0 nên chỉ được xếp hạng bằng hệ số chặn, và đạt NDCG@20 gần mốc độ phổ biến, trong khi các baseline rơi xuống dưới mốc đó. Ưu thế này không phản ánh khả năng cá nhân hóa tốt hơn.

- Giữa GRNR và EASE đầy đủ, kết quả không đơn điệu theo d, và EASE đầy đủ tốt hơn rõ ở $d = 0{,}5$.

Câu hỏi thứ ba: chi phí.

- Ưu điểm rõ nhất của GRNR là dung lượng: nhỏ hơn ma trận của EASE đầy đủ khoảng 190 lần. Khoảng cách này còn tăng theo quy mô danh mục, vì bộ nhớ của EASE tăng theo bình phương còn của GRNR tăng tuyến tính.
- DFHF chậm nhất nhóm khi huấn luyện (37,9 giây mỗi epoch), nhưng thời gian suy luận cùng cỡ với các baseline. Đường học cho thấy phần lớn số epoch là thừa.
- Số đo thời gian lẫn với khác biệt phần cứng, nên chỉ mang tính tham khảo.

Câu hỏi thứ tư: phục vụ lịch sử mới và giải thích. Cả hai mô hình đều chấm điểm được một lịch sử mới mà không cần huấn luyện lại. Hệ thống demo minh họa điều này, và hiển thị phân rã đại số của điểm GRNR thành đóng góp của từng sản phẩm trong lịch sử. Phân rã này là một mô tả trung thực về cách mô hình tính điểm, không phải một giải thích nhân quả về sở thích của người dùng. Hệ thống cũng chưa được đánh giá với người dùng thật.

Bài học chung.

- Trên dữ liệu này, khả năng cá nhân hóa phụ thuộc vào độ dày dữ liệu nhiều hơn vào lựa chọn mô hình.
- Khi dữ liệu dày, hai mô hình đề xuất có khác biệt đo được so với baseline cùng nhóm. Việc giải thích khác biệt này bằng giới hạn láng giềng trong bài toán hoặc bằng hàm mất mát gần thước đo xếp hạng vẫn là giả thuyết, vì chưa có thí nghiệm loại bỏ thành phần.
- Khi dữ liệu thưa, kết quả gợi ý rằng xếp hạng theo độ phổ biến cho lịch sử quá ngắn có lợi hơn cố cá nhân hóa từ một tương tác. Nhận định này chưa được kiểm tra bằng cách cho baseline dùng cùng phương án dự phòng.
- So mọi mô hình với một mốc không cá nhân hóa là cần thiết. Thiếu mốc này, ưu thế của DFHF ở mức thưa nhất đã có thể bị hiểu sai.

Mọi kết luận trên chỉ đúng trong phạm vi một bộ dữ liệu, một seed, kết quả trên tập xác thực đã dùng để chọn checkpoint và cấu hình, và ngân sách tinh chỉnh không cân bằng giữa mô hình đề xuất và baseline.

6.2 Hướng phát triển

Các hướng dưới đây được sắp theo mức độ ảnh hưởng đến độ tin cậy của kết luận.

1. Xác nhận trên dữ liệu chưa dùng để chọn. Đánh giá các cấu hình đã khóa trên tập kiểm tra, hoặc trên một nửa tập xác thực chưa tham gia vào việc chọn. Việc này cho một ước lượng không bị nâng lạc quan, và cho biết ưu thế của DFHF có còn khi không được chọn checkpoint trên cùng tập hay không.
2. Kiểm tra lại GF-CF và tinh chỉnh baseline cân bằng. Đối chiếu cài đặt GF-CF với kết quả đã công bố. Cho mọi baseline cùng ngân sách tinh chỉnh và đủ số epoch để hội tụ, đặc biệt là DirectAU.
3. Nhiều seed. Lặp lại việc huấn luyện và việc lấy mẫu tập huấn luyện để biết các chênh lệch nhỏ, như $-0{,}00202$ giữa GRNR và EASE đầy đủ ở $d = 0{,}5$, có ổn định hay không.
4. Thí nghiệm loại bỏ thành phần.
    - Với GRNR: bỏ điều chuẩn đồ thị, bỏ trọng số mẫu, và so với EASE được giải lại trên đúng tập láng giềng của GRNR.
    - Với DFHF: thay bộ lọc bằng $F = I$, thay softmax bằng BPR, và gán trọng số khác 0 cho lịch sử đơn.

    Mục tiêu là kiểm tra các giả thuyết cơ chế ở Mục 5.4.
5. Kết hợp có chủ đích với độ phổ biến. Từ phát hiện ở câu hỏi thứ hai, một hướng tự nhiên là chuyển sang xếp hạng theo độ phổ biến, hoặc trộn với nó, khi lịch sử quá ngắn, rồi đánh giá xem cách này có vượt được mốc MostPop ở mức thưa hay không.
6. Mở rộng dữ liệu. Thêm bộ dữ liệu khác, và thiết kế một đánh giá riêng cho người dùng mới thay cho thẻ minh họa trong ứng dụng demo.

TÀI LIỆU THAM KHẢO

[1] Y. Hu, Y. Koren, C. Volinsky. Collaborative Filtering for Implicit Feedback Datasets. In *2008 Eighth IEEE International Conference on Data Mining (ICDM)*, trang 263–272, 2008. DOI: 10.1109/ICDM.2008.22.

[2] S. Rendle, C. Freudenthaler, Z. Gantner, L. Schmidt-Thieme. BPR: Bayesian Personalized Ranking from Implicit Feedback. In *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)*, 2009. arXiv: 1205.2618.

[3] Y. Koren. Factorization Meets the Neighborhood: A Multifaceted Collaborative Filtering Model. In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, trang 426–434, 2008. DOI: 10.1145/1401890.1401944.

[4] X. Ning, G. Karypis. SLIM: Sparse Linear Methods for Top-N Recommender Systems. In *2011 IEEE 11th International Conference on Data Mining (ICDM)*, trang 497–506, 2011. DOI: 10.1109/ICDM.2011.134.

[5] S. Kabbur, X. Ning, G. Karypis. FISM: Factored Item Similarity Models for Top-N Recommender Systems. In *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, trang 659–667, 2013. DOI: 10.1145/2487575.2487589.

[6] J. McAuley, C. Targett, Q. Shi, A. van den Hengel. Image-Based Recommendations on Styles and Substitutes. In *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval*, trang 43–52, 2015. DOI: 10.1145/2766462.2767755.

[7] R. He, J. McAuley. Ups and Downs: Modeling the Visual Evolution of Fashion Trends with One-Class Collaborative Filtering. In *Proceedings of the 25th International Conference on World Wide Web (WWW)*, trang 507–517, 2016. DOI: 10.1145/2872427.2883037.

[8] D. Liang, R. G. Krishnan, M. D. Hoffman, T. Jebara. Variational Autoencoders for Collaborative Filtering. In *Proceedings of the 2018 World Wide Web Conference (WWW)*, trang 689–698, 2018. DOI: 10.1145/3178876.3186150.

[9] H. Steck. Embarrassingly Shallow Autoencoders for Sparse Data. In *The World Wide Web Conference (WWW)*, trang 3251–3257, 2019. DOI: 10.1145/3308558.3313710.

[10] M. Ferrari Dacrema, P. Cremonesi, D. Jannach. Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches. In *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys)*, trang 101–109, 2019. DOI: 10.1145/3298689.3347058.

[11] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, M. Wang. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, trang 639–648, 2020. DOI: 10.1145/3397271.3401063.

[12] W. Krichene, S. Rendle. On Sampled Metrics for Item Recommendation. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, trang 1748–1757, 2020. DOI: 10.1145/3394486.3403226.

[13] Z. Sun, D. Yu, H. Fang, J. Yang, X. Qu, J. Zhang, C. Geng. Are We Evaluating Rigorously? Benchmarking Recommendation for Reproducible Evaluation and Fair Comparison. In *Fourteenth ACM Conference on Recommender Systems (RecSys)*, trang 23–32, 2020. DOI: 10.1145/3383313.3412489.

[14] Y. Shen, Y. Wu, Y. Zhang, C. Shan, J. Zhang, K. B. Letaief, D. Li. How Powerful is Graph Convolution for Recommendation? In *Proceedings of the 30th ACM International Conference on Information & Knowledge Management (CIKM)*, trang 1619–1629, 2021. DOI: 10.1145/3459637.3482264.

[15] C. Wang, Y. Yu, W. Ma, M. Zhang, C. Chen, Y. Liu, S. Ma. Towards Representation Alignment and Uniformity in Collaborative Filtering. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, trang 1816–1825, 2022. DOI: 10.1145/3534678.3539253.

[16] Y. Ji, A. Sun, J. Zhang, C. Li. A Critical Study on Data Leakage in Recommender System Offline Evaluation. *ACM Transactions on Information Systems*, 41(3):75:1–75:27, 2023. DOI: 10.1145/3569930.

[17] J. Yu, X. Xia, T. Chen, L. Cui, N. Q. V. Hung, H. Yin. XSimGCL: Towards Extremely Simple Graph Contrastive Learning for Recommendation. *IEEE Transactions on Knowledge and Data Engineering*, 2023. DOI: 10.1109/TKDE.2023.3288135.

[18] J. Choi, S. Hong, N. Park, S.-B. Cho. Blurring-Sharpening Process Models for Collaborative Filtering. In *Proceedings of the 46th International ACM SIGIR*

Conference on Research and Development in Information Retrieval (SIGIR), trang 1096–1106, 2023. DOI: 10.1145/3539618.3591645.

[19] J.-D. Park, Y.-M. Shin, W.-Y. Shin. Turbo-CF: Matrix Decomposition-Free Graph Filtering for Fast Recommendation. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, trang 2672–2676, 2024. DOI: 10.1145/3626772.3657916.

[20] J. Wu, X. Wang, X. Gao, J. Chen, H. Fu, T. Qiu. On the Effectiveness of Sampled Softmax Loss for Item Recommendation. *ACM Transactions on Information Systems*, 42(4):98:1–98:26, 2024. DOI: 10.1145/3637061.

[21] A. E. Hoerl, R. W. Kennard. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1):55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

[22] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, P. Vandergheynst. The Emerging Field of Signal Processing on Graphs: Extending High-Dimensional Data Analysis to Networks and Other Irregular Domains. *IEEE Signal Processing Magazine*, 30(3):83–98, 2013. DOI: 10.1109/MSP.2012.2235192.

[23] A. van den Oord, Y. Li, O. Vinyals. Representation Learning with Contrastive Predictive Coding. arXiv:1807.03748, 2018. https://arxiv.org/abs/1807.03748.

[24] S. Boyd, L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. DOI: 10.1017/CBO9780511804441.

[25] F. R. K. Chung. *Spectral Graph Theory*. CBMS Regional Conference Series in Mathematics, tập 92. American Mathematical Society, 1997. DOI: 10.1090/cbms/092.

[26] G. C. Cawley, N. L. C. Talbot. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. *Journal of Machine Learning Research*, 11:2079–2107, 2010. https://jmlr.org/papers/v11/cawley10a.html.

[27] Y. Qin, W. Ju, Y. Gu, Z. Qiao, Z. Xiao, M. Zhang. PolyCF: Towards Optimal Spectral Graph Filters for Collaborative Filtering. *ACM Transactions on Information Systems*, 43(4):94:1–94:28, 2025. DOI: 10.1145/3728464.

[28] B. Sarwar, G. Karypis, J. Konstan, J. Riedl. Item-Based Collaborative Filtering Recommendation Algorithms. In *Proceedings of the 10th International Conference on World Wide Web (WWW)*, trang 285–295, 2001. DOI: 10.1145/371920.372071.

[29] Y. Koren, R. Bell, C. Volinsky. Matrix Factorization Techniques for Recommender Systems. *Computer*, 42(8):30–37, 2009. DOI: 10.1109/MC.2009.263.

[30] D. P. Kingma, J. Ba. Adam: A Method for Stochastic Optimization. In *International Conference on Learning Representations (ICLR)*, 2015. arXiv: 1412.6980.

[31] S. Rendle. Evaluation Metrics for Item Recommendation under Sampling. arXiv:1912.02263, 2019. https://arxiv.org/abs/1912.02263.

[32] K. Järvelin, J. Kekäläinen. Cumulated Gain-Based Evaluation of IR Techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. DOI: 10.1145/582415.582418.